

Université de Neuchâtel
Faculté des lettres et sciences humaines
Institut d'histoire de l'art et de muséologie
Espace Tilo-Frey 1
2000 Neuchâtel

ANALYSER L'ÉTAT DES DONNÉES POUR MIEUX LES RELIER

*Conception d'un instrument de diagnostic pour l'agrégation de données
patrimoniales*

Mémoire de master études muséales
Directeur : Francesco Beretta
Date : 30.07.2026

présenté par :
Cristóbal Barria Bignotti
Master of Arts en études muséales
Chemin de sous le crêt 3A, Troinex
cristobal.barria@geneve.ch

Sommaire

Résumé.....	6
Introduction.....	7
1- Cadre théorique.....	13
1.1- Brève histoire de la publication au format ouvert des bases de données muséales.....	13
Introduction.....	13
Origines de la mise à disposition des données patrimoniales.....	14
L'implication des institutions GLAM dans le mouvement Open.....	17
Vers un nouveau paradigme des données muséales : de l'accès à la réutilisation.....	20
La question déontologique du partage et de la mise en libre accès des données patrimoniales.....	24
Conclusion : La valorisation des données patrimoniales comme enjeu muséologique.....	27
1.2- Interopérabilité des données muséales : le web sémantique, le CIDOC-CRM et le Linked Open Data.....	28
1.3- Agrégation et modélisation : un espace de négociation sémantique.....	34
1.4- Curation numérique et publication ouverte interopérable.....	37
1.5- Instruments d'évaluation et diagnostic.....	43
1.6- Présentation du projet de plateforme fédérée de la Ville de Genève.....	45
2- Objectifs.....	50
2.1- Description du problème.....	50
2.2- Objectif principal.....	50
2.3- Objectifs spécifiques.....	51
3- Méthodologie.....	52

4- Design et présentation du questionnaire.....	55
4.1- Choix de l'instrument de collecte de données.....	55
4.2- Univers d'étude.....	56
4.3- Définition de l'unité d'analyse.....	57
4.4- Modalités d'administration.....	58
4.5- Périmètre de réponse.....	59
4.6- Contenu et typologie des questions.....	59
Structure et aspects généraux.....	59
Questions 1.....	60
Questions 2.....	60
Questions 3.....	60
Questions 4.....	61
Questions 5.....	61
État curatorial.....	62
Questions 6.....	62
Questions 7.....	62
Questions 8.....	63
Questions 9.....	63
Pratiques de mise à jour et stabilité des identifiants.....	64
Questions 10.....	65
Gouvernance des données.....	65
Questions 11.....	65
Données sensibles et stratégies déontologiques.....	66

Questions 12.....	66
Évaluation de la publiabilité.....	67
Questions 13.....	68
4.7- Restitution des résultats.....	68
CSVs.....	68
CSV informations générales.....	69
CSV Entités.....	69
CSV Attributs.....	69
CSV Groupes d'attributs.....	71
Visualisation.....	71
Calcul des attributs non curés.....	72
4.8- Ouverture et accès en ligne du formulaire.....	76
5- Validation et application pilote.....	78
5.1- Validation qualitative par une experte du domaine.....	78
Intégration d'un glossaire contextuel.....	78
Simplification de l'introduction et de la définition du concept de jeu de données.....	79
Modalité d'application du questionnaire.....	79
Clarification du concept de modèle de données.....	79
Reformulation des questions relatives aux modèles de données.....	80
Intégration d'exemples de réponse.....	80
Droits associés aux données.....	80
5.2- Application pilote du formulaire.....	81
Évaluation différenciée des modèles de données et des systèmes de gestion.....	81

Caractérisation de l'incertitude.....	82
Évaluation de l'unicité des identifiants.....	82
Ambiguïté sémantique dans l'usage des attributs.....	82
Simplification de la méthode d'évaluation des métriques de curation.....	83
Conclusion.....	84
Bilan de l'utilité du questionnaire.....	84
Limites de l'instrument.....	85
Conditions réelles de scalabilité.....	86
Perspectives d'application.....	87
Bibliographie.....	89
Annexe 1 : Première version du questionnaire.....	98

Résumé

Le développement de plateformes permettant la publication interconnectée de données issues de collections patrimoniales ouvre de nouvelles perspectives pour la valorisation, l'interopérabilité et la réutilisation des données culturelles. Il soulève néanmoins de nombreux défis techniques, politico-administratifs et liés à la gestion des données culturelles. Parmi ceux-ci, la nécessité de comprendre en profondeur l'état des données et les pratiques de curation mises en œuvre par les institutions d'origine apparaît comme un enjeu central. Ces institutions opèrent en effet selon des approches, des cultures organisationnelles et des modèles de gestion hétérogènes.

Si plusieurs instruments ont été développés afin d'accompagner les équipes des institutions GLAM (Galleries, Bibliothèques, Archives et Musées) dans la mise en ligne de leurs collections sous forme de données consultables, ceux-ci se concentrent généralement soit sur les défis internes à une seule institution, soit sur les problématiques propres à l'architecture sémantique et à la modélisation. À ce jour, il n'existe pas d'outil spécifiquement conçu pour collecter et analyser, de manière structurée et systématique, des informations relatives à la gestion et à la curation des données au sein de plusieurs institutions en vue de leur agrégation dans une plateforme fédérée.

Ce projet vise à combler cette lacune par la conception d'un questionnaire structuré destiné à évaluer l'état, la structure et la gouvernance des données au sein de différentes institutions GLAM.

Prenant comme étude de cas le projet de plateforme fédérée des collections patrimoniales actuellement en développement au sein de la Ville de Genève, ce mémoire propose la conception d'un outil flexible, évolutif et adaptable à différents types d'institutions. Il ne vise pas à définir un standard de qualité ni un modèle unique applicable à l'ensemble des institutions, mais à répondre à trois objectifs complémentaires : évaluer l'état, la structure et le niveau de curation des données existantes ; soutenir les décisions relatives à leur modélisation ; et orienter la priorisation des données destinées à être publiées au sein d'une plateforme fédérée.

Introduction

There is a new profession of trail blazers, those who find delight in the task of establishing useful trails through the enormous mass of the common record.

Vannevar Bush, 1945, *As We May Think*.

Pensar es olvidar diferencias, es generalizar, abstraer.

Jorge Luis Borges, 1944, *Funes el memorioso*.

L'exercice consistant à inventorier, gérer et donner un accès organisé à l'information sur les collections patrimoniales est inhérent à l'émergence de la muséologie moderne. Les réflexions de Samuel Quiccheberg sur les « inscriptions »¹ ou l'adoption de l'étiquetage par Félix Vicq d'Azyr² témoignent de la manière dont les changements de paradigme muséologiques ont toujours été liés à une transformation de la gestion de l'information. C'est pourquoi il est essentiel, pour les études muséologiques, d'observer de façon critique et analytique la manière dont se construit, se gère et se donne accès à l'information des collections muséales.

Au cours des dernières décennies, et en réaction à ce que l'on a appelé l'« euphorie » numérique³ ou « Digital Anxiety »⁴, se sont tenues — parfois elles aussi non sans une certaine euphorie — des centaines de conférences, recommandations, accords et publications consacrés à l'analyse de

¹ QUICCHEBERG Samuel. *The First Treatise on Museums: Samuel Quiccheberg's "Inscriptiones"*, 1565, trad. du latin par M. A. Meadow & B. Robertson, Los Angeles : Getty Research Institute, 2014.

² Félix VICQ D'AZYR, *Instruction sur la manière d'inventorier et de conserver, dans toute l'étendue de la République, tous les objets qui peuvent servir aux arts, aux sciences, et à l'enseignement, proposée par la Commission temporaire des arts, et adopté par le Comité d'instruction publique de la Convention nationale*, Paris: an II [1793-1794], p. 1-16.

³ GEMMEKE Claudia, HARTMUT John, and Harald KRÄMER (éd.), *Euphorie digital? : Aspekte der Wissensvermittlung in Kunst, Kultur und Technologie*, Bielefeld: Transcript-Verlag, 2015.

⁴ OWENS Trevor, *The Theory and Craft of Digital Preservation*, Baltimore, Maryland: Johns Hopkins University, 2018.

l'impact des technologies numériques sur les institutions muséales. Ces débats témoignent de l'impact de ces technologies dans les domaines les plus divers de la pratique muséale, tels que les expositions et les espaces muséographiques, la relation avec les publics et les communautés, ou encore la gestion institutionnelle⁵. Cependant, comme nous le verrons au chapitre 1.1 de ce mémoire, le débat sur la manière dont ces technologies influencent les modes de gestion et de publication de l'information des collections muséales possède une histoire bien plus ancienne. Dès le début des années 1960, on relève les premières tentatives d'automatisation des inventaires et des catalogues au moyen d'ordinateurs centraux, et la réflexion sur leurs potentialités, leurs risques et les manières d'articuler leur usage avec le projet muséal fait partie du débat depuis cette époque.

Cependant, l'essor exponentiel des sciences de l'informatique et l'impulsion soutenue en faveur de la numérisation du patrimoine culturel⁶, catalysée par des initiatives internationales telles que le plan d'action *The Lund Principles: Coordination of digitisation mechanisms*⁷, ont radicalement transformé le paysage au cours des deux dernières décennies. Le volume d'informations géré numériquement par les institutions muséales a crû à un rythme sans précédent, engendrant des défis nouveaux et complexes liés à la capture, l'organisation, la modélisation, l'analyse et la publication des données. Parallèlement, la centralité croissante de l'environnement numérique dans la vie quotidienne a redéfini le rôle des données relatives aux collections patrimoniales ainsi que les attentes concernant leur accès et leur réutilisation. Si, il y a quelques décennies, l'accès aux bases de données muséales répondait principalement aux besoins internes de l'institution ou à l'intérêt de spécialistes consultant ponctuellement des informations via le site web de chaque institution, il est aujourd'hui nécessaire que les musées publient et gèrent leurs données de manière à ce qu'elles puissent dépasser les limites des catalogues institutionnels. Plutôt que de

⁵ Voir, entre autres études qui examinent les multiples manières dont les technologies numériques transforment les musées et leurs pratiques : PARRY Ross (dir.), *Museums in a Digital Age*, Hoboken : Taylor and Francis, 2013; MARTY Paul F., BURTON JONES Katherine, *Museum Informatics : People, Information, and Technology in Museums*, New York: Routledge, 2009; BONNEFOIT Régine, RÉRAT Mélissa (éd.), *The Museum in the Digital Age : New Media and Novel Methods of Mediation*, Newcastle upon Tyne: Cambridge Scholars Publishing, 2017; BAUTISTA SMITH Susana, *Museums in the Digital Age : Changing Meanings of Place, Community, and Culture*, Lanham, Maryland: AltaMira Press, 2014.

⁶ TERRAS Melissa, « The Rise of Digitization », in : RIKOWSKI Ruth (éd), *Digitisation Perspectives*, Rotterdam: Sense Publishers, 2011.

⁷ UNION EUROPÉENNE, *The Lund Principles: Coordination of digitisation mechanisms*, Office des publications de l'Union européenne, 2001.

demeurer des ressources isolées, les données doivent pouvoir s'intégrer aux flux d'échange d'information du Web, favorisant leur interopérabilité, leur réutilisation et leur mise en relation avec d'autres sources de connaissance. Comme nous le verrons au chapitre 1.1, ce changement transforme profondément la fonction des systèmes de gestion de collections, qui cessent d'être des outils destinés exclusivement à l'administration interne, à la recherche spécialisée ou à la publication ponctuelle de contenus, pour devenir des infrastructures de production, d'articulation et de circulation de la connaissance à dimension publique. Ces infrastructures permettent de relier des contextes, de construire de nouveaux récits et d'établir des liens avec d'autres champs du savoir au-delà des limites traditionnelles du musée. Ce nouveau scénario transforme le rôle des professionnels chargés de la documentation et de la gestion des données du musée, qui cessent progressivement d'occuper uniquement une fonction de gardien de catalogues autonomes pour participer activement à un écosystème numérique partagé, où les décisions relatives à la description, à la structuration et à la modélisation des données ont une incidence directe sur la visibilité, l'interprétation et l'appropriation sociale du patrimoine.

Dans ce contexte, le web sémantique et l'initiative du *Linked Open Data* (LOD) ont gagné en pertinence en tant que cadre méthodologique et technique permettant que les données muséales soient publiées de manière structurée, interopérable et connectée à d'autres ensembles d'informations sur le web. Comme nous le verrons à la section 1.2, en proposant des modèles de description fondés sur des relations sémantiques explicites, les principes du LOD remettent en question les logiques traditionnelles de catalogage centrées sur des notices fermées et hiérarchiques, en faveur d'une conception des données comme éléments interconnectés au sein de réseaux de connaissance plus vastes.

Toutefois, la publication de données muséales selon les principes du LOD ne constitue pas seulement un défi technique de transformation ou d'exposition de l'information existante. Elle requiert au préalable une évaluation critique de l'état, de la cohérence et de la qualité des données disponibles. Contrairement à d'autres domaines où les données peuvent avoir été produites selon des modèles homogènes dès l'origine, les données muséales résultent de processus documentaires cumulatifs développés sur plusieurs décennies, dans des contextes institutionnels, technologiques et méthodologiques divers. L'évolution des pratiques de catalogage, le remplacement progressif des systèmes de gestion de collections, la coexistence de différents

outils informatiques au sein d'une même institution et entre institutions, ainsi que l'application inégale de normes et de vocabulaires contrôlés, ont produit des ensembles de données caractérisés par une grande hétérogénéité structurelle et descriptive. La persistance de pratiques documentaires divergentes, l'absence de niveaux homogènes de standardisation et l'existence de lacunes ou d'ambiguïtés dans les notices peuvent compromettre non seulement l'interopérabilité technique des données, mais aussi leur interprétation et leur fiabilité une fois intégrées dans le Web de données. Face à cette situation, il devient nécessaire de disposer d'instruments de diagnostic capables d'identifier les incohérences, les lacunes d'information et les degrés d'alignement avec des standards, des vocabulaires et des modèles conceptuels partagés.

Comme nous le montrerons au chapitre 1.5, il n'existe actuellement aucun instrument structuré permettant de recueillir et d'analyser de manière homogène des informations relatives à l'état de préparation de jeux de données patrimoniaux provenant de multiples institutions, avant leur intégration dans une plateforme de Linked Open Data. Les instruments existants se concentrent principalement sur deux dimensions complémentaires : d'une part, l'évaluation de la préparation technique et de la capacité de publication d'une collection considérée isolément, comme c'est le cas des *maturity models* ou des *checklists* développés par des institutions telles qu'Europeana ou le W3C ; d'autre part, l'accompagnement méthodologique des processus de modélisation et de transformation des données. Ces approches ne répondent toutefois pas pleinement au besoin de réaliser un diagnostic comparatif et préalable sur la qualité, la structure et le potentiel d'intégration de jeux de données patrimoniaux hétérogènes.

Ce travail prend comme étude de cas le projet de plateforme fédérée de collections patrimoniales actuellement en développement dans la ville de Genève. Ce projet, décrit plus en détail à la section 1.6, vise à interconnecter les données de diverses institutions patrimoniales de la ville, parmi lesquelles le Musée d'art et d'histoire, le Centre d'iconographie, le Fonds d'art contemporain, l'Institut et Musée Voltaire, le Conservatoire et Jardin botaniques, la Bibliothèque de Genève et le Musée d'ethnographie de Genève. Les institutions participantes présentent des modèles documentaires distincts, des structures de données hétérogènes et des niveaux de curation inégaux, configurant un scénario particulièrement représentatif des défis associés aux projets d'agrégation et d'interopérabilité de données patrimoniales.

Pour répondre aux objectifs fixés, la méthodologie adoptée — présentée au chapitre 3 — a consisté à concevoir un questionnaire structuré à partir d'une revue de la littérature scientifique et professionnelle, de l'étude d'instruments comparables et d'un examen préliminaire de plusieurs bases de données d'institutions patrimoniales genevoises. Cette première version a ensuite été soumise à une évaluation qualitative par une personne experte en gestion de données muséales, ainsi qu'à une application pilote. Les observations issues de ces deux étapes, que nous analysons au chapitre 5, ont donné lieu à un processus itératif de révision ayant permis d'affiner tant la formulation des questions que la structure générale de l'instrument.

Le résultat de ce travail, présenté en détail au chapitre 4, est un questionnaire structuré en six blocs thématiques — structure et aspects généraux, état curatorial, pratiques de mise à jour et stabilité des identifiants, gouvernance des données, données sensibles et stratégies déontologiques, et évaluation de la publiabilité. L'instrument produit des résultats restitués dans un format directement exploitable par les data scientists, conçus pour appuyer concrètement les décisions de curation et de modélisation.

Au-delà de sa dimension technique, cette recherche s'inscrit dans une réflexion proprement muséologique. Comme nous le soulignerons en conclusion du chapitre 1.1, la gestion et la valorisation des données patrimoniales ne peuvent plus être envisagées comme une activité auxiliaire, subordonnée à la gestion des collections physiques : elles engagent des choix épistémologiques, éthiques et politiques qui méritent la même attention critique que celle traditionnellement accordée à la curation des objets et aux commissariats d'exposition. Évaluer l'état des données avant de les relier, c'est aussi rendre visibles les décisions, les silences et les incertitudes qui les composent — et, ce faisant, interroger la manière dont les musées entendent assumer leur rôle de producteurs et de garants de données patrimoniales fiables au sein d'un écosystème numérique partagé.

Ce travail s'organise de la manière suivante. Le chapitre 1 propose un cadre théorique retraçant l'histoire de la publication ouverte des données muséales, les fondements techniques de leur interopérabilité (web sémantique, CIDOC-CRM, Linked Open Data), les enjeux de l'agrégation comme espace de négociation sémantique, les principes de la curation numérique, ainsi qu'une analyse critique des instruments d'évaluation existants et une présentation du projet de plateforme fédérée de la Ville de Genève. Le chapitre 2 expose la problématique et les objectifs,

principal et spécifiques, de la recherche. Le chapitre 3 détaille la méthodologie suivie pour la conception et l'évaluation du questionnaire. Le chapitre 4 présente en détail la conception méthodologique et le contenu du questionnaire, section par section. Le chapitre 5 rend compte du processus de validation qualitative et de l'application pilote, ainsi que des modifications apportées à l'instrument à la suite de ces deux étapes. Enfin, les conclusions proposent un bilan critique de l'utilité et des limites de l'instrument, discutent les conditions réelles de sa scalabilité et esquissent des perspectives d'application future.

1- Cadre théorique

1.1- Brève histoire de la publication au format ouvert des bases de données muséales

Introduction

L'historiographie consacrée à la gestion des bases de données dans les musées a largement documenté l'adoption de nouvelles technologies⁸, l'émergence d'organismes interinstitutionnels⁹, ainsi que la professionnalisation de ce domaine¹⁰. Elle a également abordé les débats idéologiques accompagnant ces transformations et la manière dont celles-ci s'articulent avec différentes traditions muséologiques¹¹.

En revanche, l'histoire des moments, des pratiques et des discours liés à la volonté de publier les bases de données muséales de manière ouverte n'a jamais fait l'objet d'une étude approfondie.

Aujourd'hui, avec l'essor de la publication des données muséales sur des plateformes conçues pour le libre accès aux données, leur interconnexion et leur réutilisation, il devient plus que jamais nécessaire de revisiter cette histoire. Ces données ont, en fait, cessé d'être de simples instruments opérationnels au sein des musées pour se constituer en véritables outils de valorisation et de médiation des collections auprès des communautés en ligne, tout en représentant une nouvelle manière pour les musées de se relier à la société et de participer à la vie culturelle et numérique des communautés.

Cette section se concentre sur cet aspect particulier de l'histoire des bases de données dans les musées. Qu'il s'agisse de prolonger une tradition d'ouverture publique du savoir ou de revisiter

⁸ WILLIAMS David, « A Brief History of Museum Computerisation », in : PARRY Ross (dir.), *Museums in a Digital Age*, Hoboken : Taylor and Francis, 2013, pp. 15-21 ; SARASAN Lenore, « Why museum computer projects fail », in : FAHY Anne (dir.), *Collections Management*, London : Routledge, 2006.

⁹ ROBERTS Andrew, « The Changing Role of Information Professionals in Museums », in : PARRY Ross (dir.), 2013, pp. 22-27 ; SARASAN 2006.

¹⁰ ROBERTS 2013, pp. 22-27.

¹¹ PARRY Ross, *Recording the Museum. Digital Heritage and the Technologies of Change*, London : Routledge, 2007.

des conceptions liées à la collection et à la documentation, la publication en libre accès et interconnectée des bases de données s'inscrit dans des débats historiques et muséologiques, porteurs d'une réflexion théorique majeure sur la fonction du musée dans la société.

Origines de la mise à disposition des données patrimoniales

Pour comprendre comment les musées ont participé aux débats sur l'ouverture des données, il est nécessaire de revenir aux premières étapes de l'intégration de l'informatique dans la gestion des bases de données de ces institutions. Des auteurs tels que Lenore Sarasan¹² et David Williams¹³ soulignent que les changements sociaux et culturels des années 1960 et 1970 dans le monde anglo-saxon — contexte à partir duquel ils écrivent tous deux — ont mis en évidence les lacunes des systèmes traditionnels de gestion de l'information sur les collections, favorisant ainsi l'adoption des technologies informatiques¹⁴. L'un de ces changements fut l'accélération de la rotation des postes au sein des musées. Ce contexte professionnel a généré le besoin d'adopter une gestion collective des enregistrements des collections, qui puisse être facilement transmise de main en main. Le second contexte évoqué par ces auteurs, et qui a des implications majeures pour l'ouverture et la publication des données, concerne l'évolution des attentes du public à l'égard du patrimoine. Selon Williams : « Autrefois sanctuaires silencieux et préservés, réservés aux chercheurs et aux érudits, les musées en vinrent à être envisagés comme des institutions de confiance publique, investies de devoirs et de responsabilités à l'égard de leurs collections, de leurs communautés et des générations futures »¹⁵. Ce changement, en accord avec la révolution dans le monde muséal que l'on a qualifiée de « nouvelle muséologie »¹⁶, a également eu un impact sur la gestion des données dans les musées. Il ne suffisait plus que la documentation serve uniquement à des fins internes de gestion ou de conservation des musées ; ceux-ci devaient

¹² SARASAN 2006.

¹³ WILLIAMS 2013.

¹⁴ Concernant les premiers logiciels de gestion muséale, voir notamment: Smithsonian Institution, *SELGEM* (Self-Generating Master File System), 1970; Museum Computer Network, *GRIPHOS* (General Retrieval and Information Processor for Humanities Oriented Studies), 1968.

¹⁵ « Once the quiet, undisturbed sanctuary of scholars and researchers, museums were seen now as public trusts with duties and responsibilities to their collections, to their communities, and to future generations ». WILLIAMS 2013, p. 16.

¹⁶ DESVALLÉES André (éd.), *Vagues : une anthologie de la nouvelle muséologie*, Paris: Éditions, 1992.

désormais rendre l'information sur leurs collections disponible de manière efficace et transparente.

Bien que l'accès des chercheurs externes à la documentation muséale — qu'il s'agisse d'archives, de bases de données ou de publications sur les expositions — fût déjà une pratique existante depuis deux siècles¹⁷, dans ce nouveau contexte, les musées se sont trouvés soumis à une pression croissante qui les a incité à fournir l'information de manière immédiate, efficace et conforme aux standards émergents de la modernité médiatique. Cette pression se manifesta notamment dans la conférence donnée en 1967 par Marshall McLuhan et Harley Parker¹⁸, au cours de laquelle le musée est analysé non pas comme un simple conteneur d'objets, mais comme un moyen de communication à part entière. Dans cette perspective, le musée devait non seulement repenser ses stratégies de médiation, mais également ses pratiques de documentation, lesquelles ne pouvaient plus prétendre à assurer une connaissance universelle et stable des objets, mais visaient plutôt à fournir à un public diversifié des instruments de médiation permettant des lectures multiples des collections.

Parallèlement aux transformations du rôle des musées dans la société, cette période a également été marquée par un changement analogue dans le domaine de l'informatique. Des figures telles que Ted Nelson promurent une approche de la technologie centrée sur la démocratisation de l'accès, la distribution de l'autorité interprétative et l'autonomie des usagers dans la production et la circulation des sens¹⁹. Cette perspective se concrétise dans l'idée de l'hypertexte, c'est-à-dire une structure d'information non linéaire fondée²⁰, à l'instar de la conception que McLuhan avait du musée, sur les relations entre contenus établies par les utilisateurs eux-mêmes, plutôt que sur la hiérarchie imposée par une autorité centrale. L'hypertexte se présentait ainsi comme une solution plus efficace face aux besoins du « village global »²¹, en contraste avec les systèmes

¹⁷ JONES Mike, « Archives and Museums », in : *Artefacts, Archives, and Documentation in the Relational Museum*, Londres / New York : Routledge, 2022.

¹⁸ MCLUHAN Marshall, PARKER Harley, « The Museum as a Mass Medium », in : *Curator: The Museum Journal*, vol. 10, n° 1, 1967, pp. 1-17.

¹⁹ NELSON Theodor H., *Computer Lib / Dream Machines*, South Bend, Indiana : Mindful Press, 1974.

²⁰ Pour une définition plus approfondie, ainsi que pour une analyse historique de cette notion et de l'évolution de ses significations à différents moments, voir : CASTELLUCCI Paola, *Dall'ipertesto al web. Storia culturale dell'informatica*, Bari : Laterza, 2009.

documentaires traditionnels, où l'information était fragmentée en structures hiérarchiques et où la capacité des utilisateurs à suivre les associations entre documents était limitée.

Au-delà d'une simple transformation technologique, cette révolution informatique s'inscrivait dans un projet historique plus large, partagé notamment par les musées et les institutions GLAM (Galleries, Libraries, Archives, Museums)²², visant à garantir l'accès public au savoir et à en élargir les conditions de circulation et d'accessibilité²³. La conception de l'hypertexte comme continuité ou opposition avec les bibliothèques et les archives est en réalité une constante dans le livre *Literary Machines* de Nelson. Cependant, le lien le plus évident entre la révolution informatique et la tradition des institutions GLAM apparaît dans le volume *Libraries of the Future*, publié par C. R. Licklider en 1965²⁴. Cet auteur, qui fut l'une des grandes influences de Nelson, concevait l'ordinateur non seulement comme un calculateur ou une machine à écrire, mais comme un système de relations interpersonnelles pouvant être orienté vers la facilitation de l'accès, de la recherche et de la circulation du savoir, et par conséquent comme une extension des fonctions traditionnelles des bibliothèques et des institutions GLAM.

Bien que des idées telles que l'hypertexte ou la notion d'informatique contre-hégémonique n'aient pas eu d'impact direct sur la gestion des bases de données muséales à leur époque, elles apparaissent, comme nous le verrons plus loin, conceptuellement proches des débats et des aspirations des institutions GLAM, notamment en raison de l'idée de partager des données sémantiquement interconnectées et de maintenir des politiques d'accès aux données de leurs collections.

²¹ Le terme de « village global » (global village) a été formulé par Marshall McLuhan pour décrire les effets des technologies de communication modernes, qui rapprochent les individus et les communautés à l'échelle planétaire tout en transformant la circulation de l'information. Voir notamment : MCLUHAN Marshall, *Understanding Media: The Extensions of Man*, New York : McGraw-Hill, 1964.

²² L'acronyme GLAM est apparu dans le monde anglo-saxon au début du XXI^e siècle pour désigner collectivement les institutions patrimoniales dédiées à la conservation, à la documentation et à l'accès public aux connaissances. Son usage s'est consolidé dans le cadre des politiques de numérisation et de culture ouverte, notamment à travers des initiatives telles que le programme GLAM-Wiki lancé par la Fondation Wikimedia vers 2010. Pour une histoire du concept et de ses variantes, voir : MARCUM Deanna, « Archives, Libraries, Museums: Coming Back Together? », in : *Information & Culture*, vol. 49, n° 1, 2014, pp. 74-89, DOI : <https://doi.org/10.7560/IC49105>.

²³ POMIAN Krzysztof, *Collectionneurs, amateurs et curieux : Paris, Venise, XVI^e–XVIII^e siècle*, Paris : Gallimard, 1987, pp. 293–312.

²⁴ LICKLIDER J.C.R., *Libraries of the Future*, Cambridge, Massachusetts : MIT Press, 1965.

L'implication des institutions GLAM dans le mouvement Open

Avec la popularisation du World Wide Web dans les années 1990 — fondé sur le protocole HTTP, qui reprend au moins partiellement le principe de l'hypertexte — Internet devint accessible à un large public et facilita des formes inédites d'échange, de recomposition et de circulation des connaissances²⁵. Toutefois, les imaginaires d'ouverture et de partage des connaissances qui traversaient la théorie de l'information dès les années 1960, furent rapidement mis à l'épreuve. La privatisation progressive d'Internet au cours des années 1990, stimulée par l'introduction de systèmes de Digital Rights Management (DRM), la criminalisation du partage entre pairs (peer-to-peer) et la consolidation de modèles économiques fondés sur l'abonnement, compromit une conception du réseau comme expérience cognitive collective et comme infrastructure destinée à la production et à la circulation publiques du savoir²⁶. Ces dynamiques rendirent alors visibles les tensions entre l'idéal historique d'un accès public aux connaissances et les modèles économiques dominants qui commencèrent à réguler l'information numérique.

C'est ainsi qu'au cours de cette même décennie, en réponse aux processus de marchandisation de l'information numérique, commença à se structurer progressivement ce qui allait être désigné comme le mouvement open : un ensemble hétérogène de pratiques, de discours et de communautés visant à défendre l'idée que l'information, l'accès et les ressources puissent être « librement accessibles, utilisables, modifiables et partageables à toute fin utile »²⁷. Ce processus de consolidation connut un premier moment de formalisation avec la Budapest Open Access Initiative (2002), qui formula pour la première fois une définition explicite de l'accès ouvert à la

²⁵ HESS Charlotte, OSTROM Elinor et FERRI Paolo (dir.), *La conoscenza come bene comune. Dalla teoria alla pratica*, Milano : Mondadori, 2009, p. XV.

²⁶ FERRI Paolo, « Introduzione all'edizione italiana. La conoscenza come bene comune nell'epoca della rivoluzione digitale », in : HESS, OSTROM et FERRI, 2009.

²⁷ « freely accessed, used, modified, and shared for any purpose » OPEN KNOWLEDGE FOUNDATION, « Open Definition », *Open Definition*, disponible à l'adresse URL : <https://opendefinition.org/>, consulté en ligne le 23 février 2026.

littérature académique²⁸ et proposa des stratégies concrètes destinées à en garantir la mise en œuvre²⁹.

Bien que cette initiative n'ait pas été institutionnellement souscrite par des organisations GLAM, elle reçut néanmoins l'adhésion de bibliothécaires et de professionnels de l'information liés à des bibliothèques universitaires et de recherche, en particulier dans le monde anglo-saxon³⁰. Ces institutions se trouvaient en effet directement affectées par la crise des abonnements et par la privatisation progressive de l'accès à la littérature scientifique. Dans ce contexte, l'implication de la communauté GLAM répondit moins aux enjeux liés à la publication de collections numériques — encore embryonnaires à cette époque — qu'à sa fonction historique de médiation dans l'accès au savoir.

L'intégration effective des institutions GLAM au mouvement Open s'est opérée, dans une large mesure, en réponse à la croissance soutenue des volumes de données et de métadonnées qu'elles ont commencé à produire à partir du milieu des années 2000. Dans le cadre d'initiatives orientées vers la numérisation, telles que la stratégie *i2010: Digital Libraries*³¹ et la *Recommandation sur la numérisation et l'accessibilité en ligne du matériel culturel et la conservation numérique*³², les bibliothèques, les musées et d'autres institutions patrimoniales ont engagé des processus systématiques de numérisation de leurs collections. Ce processus a confronté ces institutions à de

²⁸ « By "open access" to this literature, we mean its free availability on the public internet, permitting any users to read, download, copy, distribute, print, search, or link to the full texts of these articles, crawl them for indexing, pass them as data to software, or use them for any other lawful purpose, without financial, legal, or technical barriers other than those inseparable from gaining access to the internet itself. » BUDAPEST OPEN ACCESS INITIATIVE, « Read the Declaration », 14 février 2002, disponible à l'adresse URL : <https://www.budapestopenaccessinitiative.org/read/>, consulté en ligne le 23 février 2026.

²⁹ Pour une discussion approfondie sur ce que l'on entend par Open Access, voir : SUBER Peter, *Open Access*, Cambridge, Massachusetts : MIT Press, 2012.

³⁰ La liste complète des signataires peut être consultée à : BUDAPEST OPEN ACCESS INITIATIVE, « Signatures », en ligne https://www.budapestopenaccessinitiative.org/sign/signatures/?b_start:int=600, consulté en ligne le 23 février 2026.

³¹ UNION EUROPÉENNE, « i2010: Digital Libraries — Communication from the Commission of 30 September 2005 to the European Parliament, the Council, the European Economic and Social Committee and the Committee of the Regions (COM(2005) 465 final) », EUR-Lex, disponible à l'adresse URL : <https://eur-lex.europa.eu/EN/legal-content/summary/i2010-digital-libraries.html>, consulté en ligne le 23 février 2026.

³² UNION EUROPÉENNE, Recommandation de la Commission du 27 octobre 2011 sur la numérisation et l'accessibilité en ligne du matériel culturel et la conservation numérique (2011/711/UE). *EUR-Lex: Access to European Union Law*, 27 Oct. 2011, disponible à l'adresse URL : <https://eur-lex.europa.eu/legal-content/FR/TXT/PDF/?uri=CELEX:32011H0711&from=LV>, consulté en ligne le 23 février 2026.

nouveaux défis en matière de droit d’auteur, de régimes de licence et de réutilisation des images numériques, et a favorisé l’émergence de stratégies inédites de gestion, de circulation et de valorisation des données associées aux collections patrimoniales. Ces stratégies se sont progressivement articulées autour des principes d’ouverture et d’accès que ces institutions discutaient et défendaient depuis plusieurs décennies. Il convient de rappeler qu’en 1986 déjà, le *Code de déontologie de l’ICOM* établissait le devoir de faciliter l’accès aux collections ainsi qu’à l’information qui leur est associée³³.

Parmi les premières initiatives de mise en *open access* des collections patrimoniales figurent les mises à disposition d’images numériques. En 2008, par exemple, le Bundesarchiv a versé plus de 80 000 images à Wikimedia Commons, marquant une étape précoce dans l’ouverture des collections patrimoniales au sein d’environnements librement accessibles³⁴. La même année, le Powerhouse Museum de Sydney devint le premier musée à mettre à disposition des photographies historiques issues d’une collection publique sur la plateforme Flickr: The Commons, en publiant initialement 200 images provenant de la Tyrrell Collection³⁵.

Ces expériences, toutefois, sont antérieures à l’introduction et à la diffusion de la licence CC0 par Creative Commons (2009–2010)³⁶ et, par conséquent, l’ouverture s’est opérée dans des cadres juridiques hétérogènes, dépendant des conditions propres à chaque plateforme et sans qu’existe encore un dispositif sectoriel normatif et unifié. Ces premières initiatives ne furent d’ailleurs pas exemptes de controverses et conflits relatifs aux droits des images : en 2009, par exemple, plus de 3 300 images de la National Portrait Gallery furent mises en ligne par un contributeur bénévole sur Wikimedia Commons, ce qui donna lieu à un différend juridique avec

³³ Le principe n° 3.2, intitulé *Disponibilité des collections*, stipulait que: « Les musées ont l’obligation spécifique de rendre les collections et toutes les informations associées aussi librement accessibles que possible, dans des limites liées aux normes de confidentialité et de sécurité ». CONSEIL INTERNATIONAL DES MUSÉES (ICOM), *Code de déontologie de l’ICOM pour les musées*, principe 3.2 « Disponibilité des collections », p. 16, disponible à l’adresse URL : https://www.museums.ch/admin/data/files/media/file_fr/125/icom_ethische_richtlinien_f_web.pdf?lm=1700558444, consulté en ligne le 23 février 2026.

³⁴ WIKIMEDIA COMMONS, « Commons: Bundesarchiv », disponible à l’adresse URL : <https://commons.wikimedia.org/wiki/Commons:Bundesarchiv>, consulté en ligne le 23 février 2026.

³⁵ CREATIVE COMMONS, « Powerhouse Museum joins Flickr The Commons », 8 avril 2008, disponible à l’adresse URL : <https://creativecommons.org/2008/04/08/powerhouse-museum-joins-flickr-the-commons/>, consulté en ligne le 23 février 2026.

³⁶ CREATIVE COMMONS, « CC0 1.0 Universal (CC0 1.0) Public Domain Dedication », disponible à l’adresse URL : <https://creativecommons.org/publicdomain/zero/1.0/>, consulté en ligne le 23 février 2026.

l'institution concernant les droits de reproduction et, simultanément, renforça le débat sur la nécessité d'établir des cadres clairs et cohérents en matière d'*open access*³⁷.

L'introduction de la licence CC0 a marqué un tournant dans l'ouverture des collections patrimoniales numérisées³⁸. À la différence des initiatives antérieures, qui proposaient un accès public dans des cadres juridiques variés et parfois incertains, la licence CC0 a permis aux institutions de renoncer explicitement à tout droit sur les reproductions numériques d'œuvres relevant du domaine public, en offrant un cadre clair, transparent et compréhensible tant pour les institutions que pour les usagers et les tiers amenés à interagir avec les données.

Vers un nouveau paradigme des données muséales : de l'accès à la réutilisation

Dans ce contexte d'ouverture des collections et des données patrimoniales, la Open Knowledge Foundation lança en 2011 l'initiative OpenGLAM, destinée à promouvoir le libre accès au patrimoine culturel numérique³⁹. En 2013, OpenGLAM formula un ensemble de principes opérationnels visant à définir ce que signifie être une institution *open* dans le domaine du patrimoine culturel : (1) rendre accessibles les informations numériques relatives aux artefacts (métadonnées), soit dans le domaine public, soit au moyen d'un instrument juridique approprié; (2) maintenir les représentations numériques d'œuvres relevant du domaine public comme telles, sans leur adjoindre de nouveaux droits; (3) déclarer de manière explicite et sans ambiguïté les conditions et attentes relatives à la réutilisation et à la réaffectation des données publiées; (4) recourir à des formats ouverts et lisibles par machine pour la publication des données; (5) rechercher des modalités innovantes d'engagement des publics sur le web, en documentant et en facilitant la réutilisation des données afin de permettre à des tiers de développer de nouveaux usages à partir des ressources mises à disposition⁴⁰. Ces principes ne se limitent donc pas à orienter l'usage de licences ouvertes. Comme le soulignent les quatrième et cinquième principes,

³⁷ PETRI Grischka, « The Public Domain vs. the Museum: The Limits of Copyright and Reproductions of Two-dimensional Works of Art », in : *Journal of Conservation and Museum Studies*, vol. 12, n° 1, 2014, art. 8, DOI : <https://doi.org/10.5334/jcms.1021217>.

³⁸ Pour une analyse d'une série de cas concrets, voir : SANDERHOFF Merete (dir.), *Sharing is Caring: Openness and Sharing in the Cultural Heritage Sector*, Copenhagen : Statens Museum for Kunst, 2014.

³⁹ OPENDATA.CH AG, « OpenGLAM Working Group », disponible à l'adresse URL : <https://opendata.ch/projects/openglam-working-group/>, consulté en ligne le 23 février 2026.

⁴⁰ OPENGLAM, « OpenGLAM Principles », disponible à l'adresse URL : <https://openglam.org/principles/>, consulté en ligne le 23 février 2026.

il s'agit de créer les conditions pour que ces données puissent être activement réutilisées et intégrées par la communauté. L'objectif final est de favoriser l'engagement des utilisateurs et des tiers, permettant à la fois la création de nouveaux usages, la production culturelle et éducative, et l'enrichissement collaboratif de l'écosystème patrimonial ouvert. En ce sens, l'ouverture implique une conception de l'interconnectivité et de la réutilisation qui n'est pas sans rappeler l'idéal du lien hypertextuel formulé par Nelson.

La mise à disposition non seulement de données pour l'usage du public, mais également de données et de métadonnées dans des formats permettant leur traitement et leur réutilisation libre par des programmes informatiques, possède des antécédents importants dans le domaine muséal. Un premier jalon est le projet *Brooklyn Museum Collection API*, développé par le Brooklyn Museum en 2009. Cette interface permet un accès libre aux données de la collection du musée, incluant des informations sur les œuvres, les artistes, les expositions, ainsi que les images et métadonnées associées. Il s'agit de l'une des premières initiatives à appliquer les principes du mouvement *open* non seulement comme politique d'accès, mais aussi comme infrastructure technique⁴¹. Par cette démarche, le Brooklyn Museum a transformé le rôle traditionnel du musée, passant de fournisseur passif de données à une plateforme valorisant activement les données de ses collections comme matière première pour de nouvelles formes de production culturelle, éducative et critique au sein de l'écosystème de la culture de l'accès libre.

En avril de la même année, le Powerhouse Museum de Sydney adopta une stratégie encore plus radicale en mettant à disposition du public la documentation de ses collections sous forme de *data dump*, c'est-à-dire par la publication massive des données brutes. Cette ouverture incluait non seulement les descriptions, les métadonnées curatoriales et les images, mais également, de manière exceptionnelle, des notes internes, des questionnements, des hypothèses et différents niveaux de certitude⁴². Dans ce cas, l'ouverture ne fut pas comprise uniquement comme une politique d'accès, mais comme un geste de transparence épistémologique, en rendant visible le caractère provisoire, interprétatif et parfois incertain du savoir muséal. Cette stratégie illustre

⁴¹ CREATIVE COMMONS, « Brooklyn Museum's API », 6 mars 2009, disponible à l'adresse URL : <https://creativecommons.org/2009/03/06/brooklyn-museums-api/>, consulté en ligne le 23 février 2026.

⁴² DEARNLEY Louise, « Reprogramming the Museum », in : TRANT Jennifer et BEARMAN David (dir.), *Museums and the Web 2011: Proceedings*, Toronto : Archives & Museum Informatics, 2011.

ainsi comment les pratiques de gestion et de publication des données peuvent également revêtir une dimension critique et réflexive concernant la production du savoir muséal.

Des initiatives telles que celles du Powerhouse Museum ou de la *Brooklyn Museum Collection API* concrétisent une profonde reconceptualisation de la valeur des données des collections et du rôle même du musée dans une *datafied society* (société datifiée)⁴³. Il ne s'agit plus seulement pour le musée de gérer une base de données à usage interne — orientée vers des fonctions élémentaires de recherche d'informations sur les œuvres, telles que leur localisation ou leurs dates —, mais bien de redéfinir la gestion et la valorisation des données en fonction de leur ouverture, de leur réutilisation et de leur capacité à permettre de nouvelles formes d'interaction avec la production culturelle, tout en suscitant des questionnements critiques sur les pratiques muséologiques elles-mêmes.

La vision du musée en tant qu'institution d'information fait l'objet de débats depuis plusieurs décennies⁴⁴, mais dans le contexte actuel, elle a acquis une centralité inédite. Cela va jusqu'au point où certains auteurs, comme Berry, ont égalé l'importance de la gestion de l'information à celle de la préservation et de la valorisation des collections elles-mêmes : « Le musée moderne est une organisation de services d'information où l'information relative aux collections muséales est tout aussi importante que les collections elles-mêmes »⁴⁵. Au-delà de la question de savoir si les données sont considérées comme équivalentes, moins ou plus importantes que les collections, l'essentiel est de reconnaître qu'elles possèdent aujourd'hui une valeur sociale élevée, au point

⁴³ Le terme *datafication* (ou société datafiée) a été popularisé par : Pour une analyse plus critique et moins hyperbolique de l'impact de la datafication sur la société, voir : MAYER-SCHÖNBERGER Viktor, CUKIER Kenneth, *Big Data: A Revolution That Will Transform How We Live, Work, and Think*, Boston : Houghton Mifflin Harcourt, 2013. Pour une analyse plus critique et moins hyperbolique de l'impact de la datafication sur la société, voir : MOSSBERGER Karen, TOLBERT Caroline J. et FRANKO William, *Digital Citizenship in a Datafied Society*, Cambridge, Massachusetts : MIT Press, 2013.

⁴⁴ Depuis des décennies, on parle de la revalorisation des musées non seulement en tant que source d'objets, mais également en tant que source d'information et de connaissances : CANNON-BROOKES Peter, « The Nature of Museum Collections », in : THOMPSON John (éd.), *Manual of Curatorship*, Londres : Butterworths, 1992, pp. 500–512 ; HOOPER-GREENHILL Eileen, *Museums and the Shaping of Knowledge*, Londres : Routledge, 1992 ; MACDONALD George et ALSFORD Stephen, « The Museum as Information Utility », in : *Museum Management and Curatorship*, vol. 10, no 3, 1991, pp. 305–311 ; WASHBURN Wilcomb E., « Collecting Information, Not Objects », in : *Museum News*, vol. 62, no 3, 1984, pp. 5–15.

⁴⁵ « The modern museum is an information service organization where information about museum collections is just as important as the collections themselves », MARTY Paul F., « Museum Informatics », in : BATES Marcia J., MAACK Mary Niles (dir.), *Encyclopedia of Library and Information Sciences*, 3e éd., New York : Taylor & Francis, 2010, p. 3717.

d'être décrites comme « le pétrole du futur »⁴⁶, et que les musées disposent d'un capital informationnel significatif pour répondre à cette demande sociale.

Dans le cas spécifique des institutions GLAM, la revalorisation de leurs données répond en grande partie aux besoins du milieu académique, en particulier à l'émergence des humanités numériques et à ce que l'on a appelé le *computational turn* (tournant computationnel)⁴⁷, dans lequel les données relatives aux objets culturels deviennent une source centrale de recherche et de connaissance⁴⁸. Cependant, la valeur des données patrimoniales ne se limite pas au champ académique. Des applications et plateformes telles que Histropedia⁴⁹, StoryMap JS⁵⁰, CulturePics – On This Day⁵¹ ou Know Your Place – Wiltshire Map⁵² montrent comment la publication de données en libre réutilisation peut se transformer en ressources socialement utiles pour l'éducation, la création culturelle et la médiation patrimoniale⁵³. Par ailleurs, la réutilisation de ces données pour l'entraînement de modèles génératifs, tels que Stable Diffusion⁵⁴, Google

⁴⁶ Formule généralement attribuée à Clive Humby, qui l'aurait prononcée en 2006 lors d'une conférence de l'Association of National Advertisers. Voir : SONDERGAARD Peter, « Data Is the New Oil, in the Telecom Industry as Well », 8 décembre 2011, disponible à l'adresse URL : <https://aronheller.com/articles/data-is-the-new-oil-in-the-telecom-industry-as-well/>, consulté en ligne le 23 février 2026.

⁴⁷ BERRY David M., *The Computational Turn: Thinking about the Digital Humanities*, Basingstoke ; New York : Palgrave Macmillan, 2012 ; SCHÄFER Mirko Tobias et WELTEVREDE Esther (dir.), *The Datafied Society: Studying Culture through Data*, Abingdon ; New York : Routledge, 2019.

⁴⁸ Concernant l'utilisation des données patrimoniales comme sources, voir : TASOVAC Toma, CHAMBERS Sally et TÓTH-CZIFRA Erzsébet, « Cultural Heritage Data from a Humanities Research Perspective », A DARIAH Position Paper, 2020 ; CANDELA Gustavo, SÁEZ María Dolores, ESCOBAR Pilar et MARCO-SUCH Manuel, « Reusing Digital Collections from GLAM Institutions », in : *Journal of Information Science*, vol. 48, n° 2, 2022, pp. 251-267.

⁴⁹ HISTROPEdia, disponible à l'adresse URL : <https://histropedia.com/>, consulté en ligne le 23 février 2026.

⁵⁰ KNIGHT LAB, « StoryMap », disponible à l'adresse URL : <https://storymap.knightlab.com/>, consulté en ligne le 23 février 2026.

⁵¹ CULTUREPICS, « On This Day », disponible à l'adresse URL : <https://culturepics.org/on-this-day/?day=10&month=1>, consulté en ligne le 23 février 2026.

⁵² BRISTOL CITY COUNCIL, « Know Your Place », disponible à l'adresse URL : <https://maps.bristol.gov.uk/kyp/?edition=wilts>, consulté le 23 février 2026.

⁵³ Une liste complète d'exemples d'applications utilisant des données ouvertes et interopérables d'institutions patrimoniales peut être consultée sur : MUSEUM API, « Cool Stuff Made with Cultural Heritage APIs », disponible à l'adresse URL : <http://museum-api.pbworks.com/w/page/21933412/Cool%20stuff%20made%20with%20cultural%20heritage%20APIs?>, consulté en ligne le 23 février 2026.

⁵⁴ STABILITY AI, « Stable Image », disponible à l'adresse URL : <https://stability.ai/stable-image>, consulté en ligne le 23 février 2026.

Imagen⁵⁵ ou des architectures fondées sur CLIP⁵⁶, ouvre un nouveau champ d’usage extra-académique qui, tout en amplifiant leur portée et leur visibilité, soulève de sérieuses questions concernant les limites de la réutilisation des données patrimoniales.

La question déontologique du partage et de la mise en libre accès des données patrimoniales

La publication des données muséales de manière à ce qu’elles puissent être mises à disposition librement pour la réutilisation et l’analyse computationnelle entraîne une série de problématiques non seulement techniques, mais également éthiques et déontologiques. Quels types de données est-il légitime de rendre publics et sous quelles conditions ? Comment gérer les informations sensibles liées aux communautés d’origine, aux contextes coloniaux ou aux mémoires traumatiques ? De quelle manière éviter que l’ouverture des données ne renforce les asymétries de pouvoir, les interprétations décontextualisées ou les usages extractivistes du savoir patrimonial ? Dans quelle mesure l’ouverture des données reproduit-elle les inégalités géopolitiques préexistantes, favorisant les institutions situées dans le Nord global ? Quels risques comporte la médiation par des acteurs technologiques hégémoniques — moteurs de recherche, services d’hébergement ou fournisseurs d’intelligence artificielle — dans la manière dont les données patrimoniales sont ordonnées, hiérarchisées et récupérées ?

C’est précisément à ces questions que répond le mouvement Collections as Data, dont les principes ont été formulés initialement en 2017 dans le *Santa Barbara Statement*⁵⁷ et mis à jour en 2023 dans le *Vancouver Statement*⁵⁸. Au-delà de la simple promotion de l’ouverture des données via des licences appropriées et de leur disponibilité technique pour la réutilisation

⁵⁵ GOOGLE DEEPMIND, « Imagen », disponible à l’adresse URL : <https://deepmind.google/models/imagen/>, consulté en ligne le 23 février 2026.

⁵⁶ OPENAI, « CLIP: Connecting Text and Images », 2021, disponible à l’adresse URL : <https://openai.com/index/clip/>, consulté en ligne le 23 février 2026.

⁵⁷ PADILLA Thomas *et al.*, *Santa Barbara Statement on Collections as Data — Always Already Computational: Collections as Data (Version 2)*, Zenodo, 2019, DOI : <https://doi.org/10.5281/zenodo.3066209>.

⁵⁸ PADILLA Thomas *et al.*, *Vancouver Statement on Collections as Data*, Zenodo, 2023, DOI : <https://doi.org/10.5281/zenodo.8342171>; TERRAS Melissa, « Opening Access to Collections: The Making and Using of Open Digitised Cultural Content », in : BONACCHI Chiara (dir.), *Archaeology and Digital Communication: Towards Strategies of Public Engagement*, Londres / New York : Routledge, 2015, pp. 19–33.

computationnelle, ce mouvement souligne la nécessité d'une ouverture responsable et contextualisée⁵⁹.

Parmi les principes du mouvement *Collections as Data* figure, par exemple, le principe 4, relatif au *participatory design* (conception participative). Ce principe stipule que les institutions ne doivent pas se limiter à imaginer les usages ou les communautés d'utilisateurs depuis leur propre perspective, mais doivent s'efforcer d'intégrer les voix, besoins et attentes des utilisateurs réels, tout en réduisant au minimum les barrières d'accès et d'utilisation des données. Un autre exemple est le principe 3, qui indique que les données « devraient être largement accessibles, dans les limites des exigences éthiques, juridiques et communautaires »⁶⁰. Cela signifie que les conditions d'utilisation doivent être explicites et conçues pour répondre aux besoins des communautés représentées dans les données, en respectant leurs normes culturelles, droits et attentes. La question de la réutilisation des données par des modèles génératifs d'intelligence artificielle est abordée dans le principe 11. Ce principe met en évidence les problématiques liées à la propriété intellectuelle, à la souveraineté des données, à la traçabilité des sources et à la possible amplification de biais par ces technologies. Cependant, aucune directive concrète n'est fournie quant à sa mise en œuvre effective.

Enfin, le principe 2 vise à prévenir le risque que l'ouverture des données ne reproduise ou n'amplifie des asymétries de pouvoir, en affirmant que la publication doit s'inscrire dans une démarche consistant à « œuvrer contre les inégalités historiques et contemporaines inscrites dans les politiques d'acquisition, le périmètre des collections, les pratiques de description, les modalités d'accès et les usages »⁶¹. Parallèlement à cet objectif, ce principe témoigne également d'une nouvelle manière de conceptualiser le rapport entre la valorisation et la gestion des données au sein des institutions muséales et le travail curatorial sur les collections. Il ne s'agit

⁵⁹ Il convient de souligner que *Collections as Data* s'inspire d'autres cadres reconnus en mettant l'accent sur la dimension éthique de la publication et de la gestion des données, tels que les CARE Principles for Indigenous Data Governance de la Global Indigenous Data Alliance, qui promeuvent le respect des valeurs, des normes et des droits des communautés d'origine, ainsi qu'une évaluation attentive des risques associés à la mise en ligne de certains ensembles de données. Voir : CARROLL Stephanie R. *et al.*, « The CARE Principles for Indigenous Data Governance », in : *Data Science Journal*, vol. 19, n° 1, 2020, art. 43, DOI : <https://doi.org/10.5334/dsj-2020-043>.

⁶⁰ « should be widely accessible, within the bounds of ethical, legal, and community expectations » PADILLA Thomas *et al.*, 2023, Principe 3, p. 3, DOI : <https://doi.org/10.5281/zenodo.8342171>.

⁶¹ « working against historic and contemporary inequities represented in collection acquisition, scope, description, access, and use ». PADILLA Thomas *et al.*, 2023, Principe 2, p. 2, DOI : <https://doi.org/10.5281/zenodo.8342171>.

plus d'évaluer le travail sur les données comme étant d'importance supérieure, équivalente ou inférieure à celui portant sur les collections — comme le suggérait, par exemple, Marty — mais de le concevoir comme une pratique qui se déploie en parallèle, et surtout en dialogue, avec le travail sur les collections elles-mêmes. Dans ce principe, l'exercice de publier et d'interconnecter des données apparaît comme un moyen d'identifier et de corriger les inégalités historiques et contemporaines inscrites dans les politiques d'acquisition, le périmètre des collections, les pratiques descriptives, les modalités d'accès et les usages des objets muséaux.

Cette conscience que les collections de données posent un problème en elles-mêmes, parallèlement aux collections physiques, se reflète également dans la reconnaissance par le mouvement *Collections as Data* que toutes les collections ne doivent pas ou ne peuvent pas être représentées sous forme de données⁶². Cela peut être motivé par des raisons éthiques, par exemple lorsqu'elles contiennent des informations offensantes ou préjudiciables pour une communauté, ou par des considérations liées au statut même de la collection et de ses objets, par exemple lorsque la représentation sous forme de données serait contre-productive pour la valorisation de la collection.

Derrière ces dilemmes se cache l'idée que les collections de données ne sont pas un simple reflet des collections physiques, mais constituent le résultat d'une réflexion autonome. Une question évidente, mais qui semble souvent oubliée dans l'organisation interne des musées, ou lorsque l'on tente de comparer l'importance de l'information muséale avec celle des collections physiques.

Dans ce contexte, le rôle des musées cesse de se limiter à la simple ouverture ou publication des données pour se redéfinir autour de pratiques de curation de données qui reconnaissent explicitement leurs propres limites, rendent visibles les décisions qui les structurent et considèrent que les collections de données ne constituent pas un reflet transparent des collections matérielles, mais des constructions situées, traversées par des choix techniques, épistémologiques et éthiques. Par conséquent, de nombreux auteurs se sont consacrés à l'étude critique de la gestion des données muséales, soulignant la persistance de biais, d'héritages

⁶² PADILLA Thomas *et al.*, *Collections as Data: Part to Whole — Final Report*, Zenodo, 2018, p. 3, DOI : <https://doi.org/10.5281/zenodo.3152935>.

coloniaux et de problèmes de représentativité dans les processus de documentation, de description et de circulation de l'information patrimoniale⁶³.

Conclusion : La valorisation des données patrimoniales comme enjeu muséologique

Ce texte a examiné le processus d'ouverture et de mise en circulation en libre accès des bases de données patrimoniales, en considérant ce phénomène comme étroitement lié à la revalorisation des données des collections en tant que capital culturel et social des musées. Il a été montré comment la vocation historique d'ouverture des musées a fonctionné comme un idéal normatif pour ce qui deviendrait plus tard l'ouverture des données sur Internet, et comment les musées ont participé activement au mouvement open par la publication massive de leurs données patrimoniales. Il a également été souligné que cette orientation vers l'ouverture s'est maintenue dans le temps, les poussant à redéfinir leur rôle : d'agents publiant leurs données de manière passive à des acteurs actifs dans la production de données, la revalorisation de celles-ci dans l'écosystème numérique et social, et même dans la remise en question des pratiques de gestion des données patrimoniales dans notre société.

Cette trajectoire historique laisse, néanmoins, ouvertes une série de questions sur les conditions, les limites et les responsabilités associées à la gestion et valorisation de données patrimoniales : Toutes les collections — et tous leurs aspects — doivent-elles nécessairement être traduites dans le langage des données, ou existe-t-il des formes de connaissance, des sensibilités ou des relations aux objets qui résistent à cette modélisation ou la mettent en question ? Quelles sont les implications éthiques liées à l'ouverture des données patrimoniales, notamment en ce qui concerne les droits culturels, les mémoires sensibles ou les communautés concernées ? Quelles bonnes pratiques scientifiques doivent guider la documentation et la curation des données patrimoniales ? Comment les institutions peuvent-elles exercer un certain degré de contrôle, de traçabilité ou de médiation sur la réutilisation de leurs données, par exemple par des modèles génératifs d'intelligence artificielle, notamment lorsque ceux-ci opèrent au sein d'infrastructures opaques et centralisées ?

⁶³ Voir, par exemple : LAWOTHER Hannah, « Documentation as a Site for Critical Decolonial and Anti-Racist Work », in : DALAL-CLAY Anita (dir.), *Doing the Work: Embedding Anti-Racism and Decolonisation into Museum Practice*, pp. 56–70, 2021 ; TURNER Hannah, *Cataloguing Culture: Legacies of Colonialism in Museum Documentation*, Chicago: University of Chicago, 2020 ; WATSON Brian M., « Advancing Equitable Cataloging », in : *Proceedings of the North American Symposium on Knowledge Organization*, vol. 8, 2021 ; CARROLL et al., 2020.; EUROPEANA PRO, « DE-BIAS Project », disponible à l'adresse URL : <https://pro.europeana.eu/project/de-bias>, consulté en ligne le 23 février 2026.

Ces interrogations conduisent, finalement, à une question de plus grande portée : quel doit être le rôle des musées face à ces défis ? Loin d'admettre une réponse univoque, cette question met en évidence que l'ouverture, la gestion et la valorisation des données patrimoniales ne constituent pas uniquement un défi technique, mais un problème institutionnel, politique et épistémologique de premier ordre, qui doit être abordé, en priorité, comme une question proprement muséologique.

1.2- Interopérabilité des données muséales : le web sémantique, le CIDOC-CRM et le Linked Open Data

Les processus d'ouverture des données de collections ont permis d'élargir l'accès aux fonds patrimoniaux et de favoriser de nouvelles formes de réutilisation des données. Parallèlement, ces évolutions ont mis en évidence les limites des modèles de données traditionnels. Les ensembles de données produits par les musées sont généralement profondément marqués par les logiques internes des institutions qui les génèrent : structures de bases de données héritées après plusieurs décennies d'usage, vocabulaires centrés sur une discipline spécifique, décisions curatoriales implicites et conventions documentaires rarement explicitées. En dehors de chaque écosystème institutionnel, ces données perdent une part significative de leur intelligibilité.

Depuis plusieurs années, un effort soutenu de normalisation internationale s'est développé, porté par des organismes tels que la *Museum Documentation Association* (MDA, aujourd'hui *Collections Trust*), le *Museum Computer Network* (MCN), l'International Council of Museums (ICOM) et son comité CIDOC, ainsi que l'European Museums' Information Institute (EMII)⁶⁴. Toutefois, ces efforts de normalisation se sont développés dans un contexte antérieur à la mise en ligne de données ouvertes et interconnectées. Ils répondaient principalement à des enjeux de gestion interne, d'harmonisation documentaire et d'échange bilatéral entre institutions, plutôt qu'à la perspective d'une circulation élargie des données dans un environnement numérique global.

⁶⁴ Pour une étude historique sur les différentes institutions ayant promu une normalisation internationale, voir : BEARMAN David, « Standards for Networked Cultural Heritage », in : PARRY Ross, 2013, pp. 48-63.

Bien que de nombreux musées aient migré, dans les années 1980 et 1990, vers des bases de données relationnelles⁶⁵, celles-ci ont continué à se structurer autour de l'objet individuel comme unité centrale d'enregistrement. Les relations — lorsqu'elles étaient mises en œuvre — prenaient la forme de clés étrangères ou de tables auxiliaires, sans s'appuyer sur une sémantique partagée garantissant leur interopérabilité au-delà du système local. En conséquence, les données circulaient comme des enregistrements relativement autonomes entre des environnements hétérogènes, et l'interopérabilité dépendait d'accords spécifiques et de transformations *ad hoc*.

Dans ce contexte, l'émergence du web sémantique a constitué une transformation profonde dans la manière de concevoir l'interopérabilité. Au début des années 2000, avec James Hendler et Ora Lassila⁶⁶, Tim Berners-Lee a impulsé cette initiative dans le but d'étendre un web principalement centré sur les relations entre documents multimédias — tel qu'il fonctionnait alors et tel qu'il fonctionne encore majoritairement aujourd'hui — vers un web de « Linked Data » orienté vers la représentation de relations signifiantes entre données⁶⁷. À cette fin, le web sémantique repose sur trois piliers:

1. En premier lieu, l'usage d'identifiants persistants (URI), qui permettent d'identifier de manière unique et stable les différentes entités, indépendamment du système ou de l'institution qui les décrit. De cette manière, une même entité — comme un artiste, un lieu ou une œuvre — peut être reconnue, citée et réutilisée à travers différents systèmes ou collections.
2. En second lieu, le modèle de représentation RDF structure l'information à partir de relations exprimées sous forme de triplets (sujet-prédicat-objet), organisant les données non pas en tables fermées, mais comme un réseau d'énoncés interconnectés, au sein duquel chaque assertion peut être liée à d'autres (Ill.1).

⁶⁵ Une base de données relationnelle est un système de gestion de l'information dans lequel les données sont organisées en tables (relations) composées de lignes et de colonnes, et où les relations entre les données sont définies à l'aide de clés primaires et étrangères. Voir : CODD Edgar F., « A Relational Model of Data for Large Shared Data Banks », *Communications of the ACM*, vol. 13, no 6, 1970, pp. 377–387, DOI : <http://doi.org/10.1145/362384.362685>. Un exemple en est l'adoption du programme Museinfo par le Musée d'art et d'histoire de Genève à la fin des années 1990. Ce logiciel permettait de faire interagir cinq tableaux différents : œuvres, auteurs, expositions, lieux et périodes. Voir : CENTRE DE DOCUMENTATION ET RECHERCHE - MAH, « Mode d'emploi debase », Archivio du CDR-MAH, carpeta MuseoInfo, 1999.

⁶⁶ BERNERS-LEE Tim, HENDLER James et LASSILA Ora, « The Semantic Web : A New Form of Web Content That Is Meaningful to Computers Will Unleash a Revolution of New Possibilities », *Scientific American*, mai 2001.

⁶⁷ « The Semantic Web is not a separate Web but an extension of the current one, in which information is given well-defined meaning, better enabling computers and people to work in cooperation ». « The Semantic Web is not a separate Web but an extension of the current one, in which information is given well-defined meaning, better enabling computers and people to work in cooperation ». Voir : BERNERS-LEE *et al.*, 2001.

3. Enfin, le web sémantique s'appuie sur une série de langages formels permettant d'exprimer des ontologies de manière computationnelle. Ces ontologies rendent possible la définition de classes, de hiérarchies et de propriétés structurant les relations entre les données, ainsi que la réalisation d'inférences logiques à partir des liens établis. Elles fournissent ainsi un cadre formel pour la description, la contextualisation et l'interopérabilité des données entre systèmes hétérogènes.

La combinaison de ces trois couches permet que les données ne soient pas seulement reliées, mais que le sens des liens soit formellement explicité. Par exemple, il est possible de déclarer que la relation entre Frida Kahlo et la peinture *La columna rota* relève d'une relation de création ou d'auteur, et cette assertion peut être interprétée aussi bien par des personnes que par des systèmes informatiques, sans dépendre du contexte local d'une base de données spécifique (Ill. 2).

Bien que le web sémantique ait été conçu comme une infrastructure applicable à une grande variété de domaines — commercial, académique, divertissement, entre autres —, les collections de données culturelles et patrimoniales, qui se caractérisent par une « richesse sémantique »⁶⁸ particulière, ont constitué l'un des champs qui y a rapidement trouvé une réponse à des problèmes préexistants d'hétérogénéité descriptive, d'interopérabilité et de modélisation⁶⁹.

Bien avant la formulation du web sémantique, le Comité International pour la Documentation (CIDOC) de l'ICOM travaillait déjà, de manière « instinctive »⁷⁰, au développement d'un modèle conceptuel destiné à faciliter la modélisation, l'analyse et la migration des données entre différents musées⁷¹. À partir de 1996, ce modèle a été formulé comme une ontologie orientée objet, permettant non seulement de décrire des relations statiques, mais aussi de représenter des

⁶⁸ « semantic richness ». Voir : NISHEVA-PAVLOVA Milena, SPYRATOS Nicolas, STANCHEV Peter, « Museum Collections and the Semantic Web », *Digital Presentation and Preservation of Cultural and Scientific Heritage*, vol. 4, 2014, pp. 33–39, DOI : <https://doi.org/10.55630/dipp.2014.4.3>.

⁶⁹ Par « modélisation », on entend le processus de conceptualisation et de structuration d'un domaine de connaissance par la définition d'entités, d'attributs et de relations. Voir : SMITH Barry, WELTY Christopher, « Ontology : Towards a New Synthesis », in : *Formal Ontology in Information Systems*, 2001.

⁷⁰ DOERR Martin, « The CIDOC Conceptual Reference Model : An Ontological Approach to Semantic Interoperability of Metadata », *AI Magazine*, vol. 24, no 3, 2003, pp. 75–92, DOI : <https://doi.org/10.1609/aimag.v24i3.1720>, p.2

⁷¹ Les objectifs du CIDOC visaient à : « to enable information exchange and integration between heterogeneous sources of cultural heritage information. It aims at providing the semantic definitions and clarifications needed to transform disparate, localised information sources into a coherent global resource, be it within a larger institution, in intranets or on the Internet ». Voir : CIDOC, « CIDOC Conceptual Reference Model Version 5.0.4 », disponible à l'adresse URL : https://cidoc-crm.org/sites/default/files/cidoc_crm_version_5.0.4.pdf, p. i, consulté en ligne le 23 février 2026.

processus et des événements, tels que la création d'une œuvre par un auteur ou sa restauration ultérieure par un autre agent. Une première version du CIDOC Conceptual Reference Model (CRM) a été publiée en 1999, et en 2006 le modèle a été reconnu comme norme ISO. Ces caractéristiques — son orientation orientée objet et sa standardisation internationale — ont fourni un cadre conceptuel et formel qui l'a rendu particulièrement apte à être exprimé dans les langages du web sémantique, notamment en OWL et en RDF⁷².

La première version officielle du CIDOC CRM publiée en RDF correspond à la version 5.0.1, datant de 2009⁷³; toutefois, dès 2001, des outils de mapping avaient été développés afin de transformer des représentations en XML vers RDF⁷⁴. Parmi les premiers projets à appliquer le CIDOC-CRM figure REACH (2005)⁷⁵, qui consistait en un portail web capable d'intégrer et de fournir un accès unifié à un ensemble de collections d'inscriptions et de monnaies de la période gréco-romaine provenant de différentes institutions⁷⁶.

Au-delà de son architecture technique, le potentiel du web sémantique réside dans la capacité effective des données à être réutilisées et reliées au-delà des frontières institutionnelles. Lorsque les données ne sont pas ouvertes, le *Linked Data* se réduit à un système d'interconnexion interne, un ensemble de silos indépendants, ce qui contredit sa vocation intrinsèque de réseau. Autrement dit, le *Linked Data* déploie pleinement ses capacités uniquement lorsqu'il s'articule avec des principes d'ouverture, donnant lieu à ce que l'on désigne sous le terme de *Linked Open Data* (LOD). Ce concept s'appuie sur les travaux de Tim Berners-Lee, Tom Heath et Christian Bizer, qui ont formalisé les principes de données liées et ouvertes dès le milieu des années 2000. La

⁷² Voir : CIDOC, « *CIDOC Conceptual Reference Model Version 5.0.4* », p. viii.

⁷³ CIDOC, « Versions of the CIDOC CRM », disponible à l'adresse URL : <https://site2024.cidoc-crm.org/versions-of-the-cidoc-crm>, consulté en ligne le 23 février 2026.

⁷⁴ CIDOC, « CIDOC CRM Tools », disponible à l'adresse URL : <https://web.archive.org/web/20070614123434/http://cidoc.ics.forth.gr/tools.html>, consulté en ligne le 23 février 2026.

⁷⁵ DOULAVERAKIS C., KOMPATSIARIS Y., STRINTZIS M. G., « Ontology-Based Access to Multimedia Cultural Heritage Collections – The REACH Project », *EUROCON 2005*, Belgrade, 2005, pp. 151–154, DOI : <https://doi.org/10.1109/EURCON.2005.1629881>.

⁷⁶ Outre le CIDOC-CRM, d'autres ontologies peuvent s'avérer utiles pour des projets patrimoniaux. Par exemple, FOAF (Friend of a Friend) permet de représenter des personnes, des groupes et leurs relations sociales, tandis que des ontologies propres peuvent également être développées pour répondre aux besoins spécifiques de chaque projet. Par ailleurs, des plateformes telles que OntoME facilitent l'identification, la gestion et l'alignement des éléments ontologiques afin de soutenir la modélisation des données, disponible à l'adresse URL : <https://ontome.net/>, consulté en ligne le 23 février 2026.

notion de LOD a été rendue particulièrement accessible et pédagogique par la proposition des « cinq étoiles » de Berners-Lee (2010), qui définit différents niveaux de publication et d'interconnexion des données (Ill. 3)⁷⁷. Dans ce schéma, une étoile correspond à la publication de données sur le web sous licence ouverte, indépendamment de leur format, par exemple un document PDF ou un fichier texte téléchargeable. Deux étoiles indiquent que les données sont disponibles dans un format structuré permettant leur traitement automatique, comme une feuille de calcul Excel. Trois étoiles signifient que les données sont non seulement disponibles, mais qu'elles sont publiées dans des formats structurés non propriétaires, c'est-à-dire indépendants d'un logiciel commercial spécifique, tels que CSV, facilitant ainsi leur réutilisation par différents systèmes et applications. Quatre étoiles impliquent que les données ont été rendues accessibles en utilisant des standards propres au web sémantique, tels que des URI persistantes et le modèle RDF, permettant d'identifier les données de manière univoque et de les référencer depuis d'autres systèmes ou ensembles de données. Enfin, la cinquième étoile est attribuée lorsque ces données, en plus d'être publiées, structurées et décrites selon des standards sémantiques, sont explicitement liées à d'autres ensembles de données externes, s'intégrant ainsi dans un réseau sémantique plus large qui amplifie leur contexte et leur potentiel interprétatif.

Bien que certains musées aient auparavant déjà expérimenté la publication de leurs catalogues sous forme de *Linked Open Data*⁷⁸, l'adoption de cette approche comme stratégie durable de publication des collections ne se consolide qu'au milieu des années 2010. Un exemple pionnier illustrant le potentiel des principes LOD à l'échelle trans-institutionnelle et transnationale est l'initiative Europeana. Cette initiative est officiellement lancée en 2008 par la Commission européenne, en continuité avec des projets antérieurs tels que The European Library, avec pour objectif de créer un point d'accès unifié au patrimoine culturel numérisé de l'Europe, indépendamment du type d'institution dont il émane. Dès sa création, la plateforme est conçue

⁷⁷ Le « 5-Star Open Data », proposé par BERNERS-LEE Tim, définit un modèle d'évaluation de la qualité de publication des données ouvertes sur le web, disponible à l'adresse URL : <https://5stardata.info/>, consulté en ligne le 23 février 2026.

⁷⁸ Parmi les premières expérimentations de publication sur le web sémantique à partir de données muséales figure une version en Resource Description Framework (RDF) des données du Rijksmuseum en 2003. Cette version initiale comprenait environ 750 œuvres remarquables générées par la conversion d'un datadump provenant d'une base de données éducative du musée. Voir : GUÉRET Christophe, SCHLOBACH Stefan, WIELEMAKER Jan, *et al.*, « The Rijksmuseum Collection as Linked Data », disponible à l'adresse URL : <https://research.vu.nl/en/publications/the-rijksmuseum-collection-as-linked-data/>. Voir également : « Towards Ontology-Driven Discourse : From Semantic Graphs to Multimedia Presentations », doi : 10.1007/978-3-540-39718-2_38.

non seulement comme un portail de consultation, mais également comme une infrastructure destinée à favoriser l'interopérabilité, la réutilisation et la circulation ouverte des données dans le secteur patrimonial européen⁷⁹.

À ce jour, Europeana offre un accès à plus de 55 millions d'objets numériques provenant de plus de 3 500 institutions (désignées comme fournisseurs) réparties dans l'ensemble de l'Europe, comprenant des bibliothèques, des musées, des archives et des collections audiovisuelles. Ces contenus présentent une grande diversité de formats, incluant images, textes, sons, vidéos et objets tridimensionnels⁸⁰. Grâce à l'adoption des principes du Linked Open Data, Europeana ne se limite pas à la publication de ces données, mais procède également à leur enrichissement en croisant les informations issues des différentes institutions. Ce processus d'enrichissement profite tant aux institutions participantes, qui peuvent combler des lacunes ou des manques dans les données de leurs catalogues, qu'aux projets externes, qu'ils soient de nature académique ou d'un autre type, souhaitant exploiter ces données. Par ailleurs, Europeana soutient activement le développement de telles initiatives en mettant à disposition diverses API⁸¹ pour l'interrogation et la réutilisation de ses données⁸².

Enfin, Europeana mène un travail significatif de valorisation et de diffusion des données à travers la production d'expositions numériques, de collections thématiques et de contenus éditoriaux sous forme de blogs⁸³. S'y ajoutent des initiatives visant le développement des compétences et la formation des professionnels du patrimoine culturel⁸⁴. À cet égard, Europeana constitue un exemple illustratif de la manière dont la publication en *Linked Open Data* peut

⁷⁹ EUROPEANA FOUNDATION, « Our Mission », disponible à l'adresse URL : <https://pro.europeana.eu/>, consulté en ligne le 23 février 2026.

⁸⁰ EUROPEANA FOUNDATION, « About Europeana », disponible à l'adresse URL : <https://www.europeana.eu/en/about-us>, consulté en ligne le 8 mars 2026.

⁸¹ Une API (Interface de Programmation d'Applications) est un ensemble de règles et de protocoles permettant à différents systèmes ou applications de communiquer et d'échanger des données entre eux.

⁸² Voir : EUROPEANA FOUNDATION, « Build with Bits 2026 : Building Places to Share », disponible à l'adresse URL : <https://pro.europeana.eu/post/build-with-bits-2026-building-places-to-share>, consulté en ligne le 8 mars 2026.

⁸³ EUROPEANA FOUNDATION, « Europeana Stories », disponible à l'adresse URL : <https://www.europeana.eu/en/stories>, consulté en ligne le 8 mars 2026.

⁸⁴ Voir : Europeana, « Develop New Skills and Build Capacity for 3D in 2026 with Eureka3D-XR », disponible à l'adresse URL : <https://pro.europeana.eu/post/develop-new-skills-and-build-capacity-for-3d-in-2026-with-eureka3d-xr>, consulté le 8 mars 2026.

constituer un instrument efficace de valorisation des collections et de renforcement de leur visibilité, tant dans les sphères scientifique et éducative que dans l'espace numérique au sens large.

1.3- Agrégation et modélisation : un espace de négociation sémantique

L'agrégation constitue l'opération centrale dans un projet d'interopérabilité des données. Elle peut être définie comme l'intégration d'informations provenant de sources diverses, impliquant l'articulation et la mise en relation de leurs significations respectives. À ce titre, l'agrégation suppose à la fois une connaissance approfondie des données — de leur état, des droits qui leur sont associés et des significations qu'elles véhiculent — et une maîtrise des modèles, ontologies et schémas qui structurent le projet. Pour cette raison, l'agrégation se situe à l'interface entre le travail du spécialiste du domaine, qui connaît les données dans leur contexte de production et d'usage, et celui du professionnel de l'information, chargé de la modélisation sémantique.

La modélisation des données, c'est-à-dire la construction explicite d'une structure conceptuelle définissant des entités, des relations et des niveaux d'abstraction⁸⁵, constitue une composante centrale de l'exercice d'agrégation. Qu'il s'agisse d'un projet impliquant une restructuration complète des significations et des relations des données, d'une démarche s'appuyant sur des modèles préexistants, ou encore de données reposant sur des structures minimales, l'agrégation suppose invariablement une série de décisions de modélisation.

En raison de la centralité et de la complexité de l'exercice de modélisation, il n'existe pas de méthode ni de méthodologie unique applicable de manière universelle. Il s'agit plutôt d'un processus étroitement lié aux objectifs spécifiques de chaque projet, à la diversité des fournisseurs de données et au niveau de granularité de l'information impliquée. Cependant, cela ne signifie pas qu'il soit impossible de développer des instruments utiles pour accompagner et confronter cet exercice.

⁸⁵ Par « modélisation », on entend le processus de conceptualisation et de structuration d'un domaine de connaissance par la définition d'entités, d'attributs et de relations. SMITH Barry, WELTY Christopher 2001.

Europeana, par exemple, a développé un modèle de données propre, le Europeana Data Model (EDM)⁸⁶, dont le but n'est pas de modéliser la réalité culturelle et historique des collections — comme le fait le CIDOC-CRM — mais de faciliter l'agrégation des données provenant des modèles les plus couramment utilisés par les institutions GLAM. L'EDM est conçu précisément pour fonctionner comme une couche d'interopérabilité entre des schémas descriptifs hétérogènes. Ainsi, si un musée utilise le système LIDO (*Lightweight Information Describing Objects*) pour partager ses données, qu'un archive décrit ses fonds avec EAD (*Encoded Archival Description*) et qu'une bibliothèque structure ses métadonnées selon METS (*Metadata Encoding and Transmission Standard*), l'EDM permet de les relier au sein d'un cadre commun, suffisamment flexible pour intégrer des descriptions présentant différents niveaux de granularité sémantique.

Comme on peut le prévoir, pour atteindre un tel degré de flexibilité, l'EDM ne s'adapte pas pleinement aux particularités des données d'origine ; il impose plutôt une structure de modélisation unifiée susceptible d'introduire des rigidités et, dans certains cas, d'appauvrir la richesse sémantique des contenus. Cette situation se manifeste en particulier lorsque les données proviennent d'institutions ayant développé des modèles alternatifs ou des schémas propres. Par ailleurs, l'adoption d'un modèle tel que l'EDM peut complexifier la tâche d'agrégation pour les institutions qui produisent et conservent les données, dans la mesure où les distinctions sémantiques introduites par le modèle, ainsi que leur correspondance avec les catégories d'origine, peuvent engendrer des confusions ou des interprétations ambiguës. C'est pourquoi Europeana s'appuie sur un réseau d'agrégateurs composé d'institutions et d'équipes spécialisées issues de différents pays et domaines patrimoniaux⁸⁷. Ces agrégateurs jouent un rôle d'intermédiaires entre Europeana et les fournisseurs de données, en mettant en place un accompagnement à la fois technique et conceptuel auprès des institutions afin de soutenir la préparation, la normalisation et le mappage de leurs métadonnées vers l'EDM.

Europeana ne propose pas de méthodologie formalisée pour l'adaptation conceptuelle du modèle aux données d'origine, ni pour la négociation sémantique qu'implique le processus de mappage

⁸⁶ EUROPEANA FOUNDATION, « EDM Documentation », disponible à l'adresse URL : <https://pro.europeana.eu/page/edm-documentation>, consulté en ligne le 23 février 2026.

⁸⁷ EUROPEANA FOUNDATION, « Aggregators », disponible à l'adresse URL : <https://pro.europeana.eu/page/aggregators>, consulté en ligne le 23 février 2026.

vers l'EDM. En revanche, d'autres projets sont pris en charge cette difficulté inhérente au travail d'agrégation en proposant des outils spécifiques. Dans le domaine des humanités et des sciences sociales, on peut par exemple citer la plateforme "OntoME" (*Ontology Management Environment*)⁸⁸, développée par le laboratoire LARHRA (Laboratoire de recherche historique Rhône-Alpes). Cette plateforme constitue un environnement en ligne de gestion d'ontologies conçu pour faciliter la création, l'administration et l'alignement collaboratif de modèles conceptuels. "OntoME" permet de gérer des classes et des propriétés dans le cadre de modèles orientés objet appliqués à des données structurées, selon une logique collaborative. L'outil prend en charge la définition de profils et de projets, permettant à des équipes distribuées de construire et de partager des modèles sémantiques cohérents entre différentes sources de données.

Une autre méthodologie est le Semantic Reference Data Modelling Method (SRDM)⁸⁹, développé dans le cadre du projet Swiss Art Research Infrastructure (SARI). Cette méthode propose un protocole de collaboration entre des experts en architecture sémantique et des experts du domaine, dans le but de créer un « semantic pattern » destiné à « guider » chaque typologie d'information depuis sa structure d'origine jusqu'à sa modélisation finale.

Contrairement à l'EDM, ces deux propositions méthodologiques ne définissent pas un modèle fermé à priori qui devrait être appliqué de manière uniforme ; elles visent plutôt à accompagner la confrontation avec les données au cours du processus de modélisation. Elles privilégient la construction progressive d'un modèle adapté aux besoins spécifiques de chaque projet. Dans ces deux approches, l'objectif est d'accompagner la modélisation comme un processus méthodologique qui implique d'identifier, de documenter et, surtout, de négocier les différences conceptuelles entre les données d'origine et le ou les modèles de référence. Dès lors, le travail collaboratif y occupe une place centrale : là où des métadonnées sont interconnectées, une

⁸⁸ Voir : ONTOME, *Ontology Management Environment*, disponible à l'adresse URL : <https://ontome.net/>, consulté en ligne le 23 février 2026. Pour plus d'informations voir : ONTOME, *OntoMe wiki*, disponible à l'adresse URL : <https://wiki-arhn.larhra.fr/doku.php?id=ontome:index>, consulté en ligne le 23 février 2026.

⁸⁹ BRUSEKER George, CARBONI Nicola, FIELDING Mark, NENOVA Desislava, HÄNSLI Tobias, « The Semantic Reference Data Modelling Method : Creating Understandable, Reusable and Sustainable Semantic Data Models », *Journal of Open Humanities Data*, vol. 11, 2025, DOI : <https://doi.org/10.5334/johd.282>.

communication effective entre spécialistes issus de différents domaines doit également être assurée.

La modélisation ne se présente donc pas comme une étape automatique, mais comme une pratique réflexive qui accompagne et structure le processus d'agrégation. En ce sens, elle ne constitue pas une phase postérieure à l'analyse des données ; elle s'amorce précisément à ce moment-là, lorsque commencent à être explicitées les catégories, les présupposés et les hiérarchies implicites dans les sources.

1.4- Curation numérique et publication ouverte interopérable

Dans les environnements de Linked Open Data, l'interopérabilité ne se limite pas au seul niveau de la modélisation sémantique des données et de leurs relations, mais implique également la curation numérique, englobant l'utilisation de vocabulaires compatibles avec les principes du LOD, l'alignement sur des autorités externes garantissant cohérence et traçabilité, ainsi que l'application de principes normatifs et éthiques. Ces derniers comprennent notamment la normalisation des formats, le recours à des vocabulaires contrôlés, la cohérence terminologique, la maintenance des données, ainsi que les choix liés à leur interprétation et à leur représentation. Ces pratiques, déjà centrales dans la documentation muséale, prennent une nouvelle ampleur dans les contextes d'ouverture et d'interopérabilité. Toutefois, lorsque les données sont intégrées dans des contextes d'ouverture et d'interopérabilité, ces pratiques acquièrent une ampleur et une complexité significativement accrues.

Parmi les thésaurus, directives ou ressources compatibles avec le Linked Open Data ayant joué un rôle central dans la consolidation d'écosystèmes sémantiques interconnectés, se distingue le Getty Art & Architecture Thesaurus (AAT)⁹⁰. L'initiative du Getty visant à développer un thésaurus contrôlé pour décrire des objets d'art, d'architecture et de culture matérielle est née à la fin des années 1970, dans un contexte d'automatisation croissante des catalogues de musées, bibliothèques et autres institutions culturelles⁹¹. En février 2014, l'AAT a été publié en tant que

⁹⁰ GETTY RESEARCH INSTITUTE, « Art & Architecture Thesaurus (AAT) », disponible à l'adresse URL : <https://www.getty.edu/research/tools/vocabularies/aat/>, consulté en ligne le 23 février 2026.

⁹¹ L'initiative du Getty visant à développer un thésaurus contrôlé et structuré destiné à décrire des objets d'art, d'architecture et de culture matérielle est née à la fin des années 1970, dans un contexte marqué par l'automatisation

Linked Open Data sous la licence Open Data Commons Attribution License (ODC-By) 1.0⁹². Dans cette version, les concepts ont été modélisés en RDF, principalement selon la norme SKOS, complétée par des extensions propres au Getty Vocabulary Program. Chaque terme est alors décrit comme une entité sémantique identifiée par un URI persistant, permettant de formaliser de manière computationnelle les relations hiérarchiques et associatives entre concepts au sein d'un cadre interopérable à l'échelle du web.

Un autre domaine de l'interopérabilité consiste à relier non pas les expressions descriptives, mais les entités elles-mêmes à des autorités externes, de manière à garantir une identification univoque et persistante entre différentes institutions, ainsi qu'entre les différentes dénominations d'une même entité. Un exemple paradigmatique en est le Union List of Artist Names (ULAN), également développé par le Getty. Il s'agit d'une base de données structurée qui rassemble des noms et d'autres informations relatives à des personnes et à des entités corporatives associées à l'art, à l'architecture et à d'autres formes de culture visuelle⁹³. L'ULAN a été publié comme Linked Open Data (LOD) en 2015, dans des formats tels que JSON, RDF, N3/Turtle et N-Triples. Chaque entité peut inclure plusieurs variantes de noms — tels que des pseudonymes, des noms dans différentes langues ou des formes ayant évolué au fil du temps —, dont l'une est désignée comme forme préférée par défaut. En outre, chaque entité se voit attribuer un URI persistant, permettant à différentes institutions de se référer à une même personne ou à un même groupe sans dépendre de la forme textuelle exacte du nom.

À l'instar du Getty, de nombreuses autres institutions ont mis à disposition leurs bases de données d'autorités sous forme de Linked Open Data afin d'en favoriser la réutilisation et l'interopérabilité. Un exemple particulièrement significatif est celui de la Bibliothèque nationale de France, dont le portail data.bnf.fr, développé au début des années 2010, publie des autorités de personnes, d'entités et d'œuvres en LOD, permettant leur alignement avec d'autres systèmes

croissante des catalogues dans les musées, bibliothèques et autres institutions culturelles. Voir : GETTY RESEARCH INSTITUTE, « About the Art & Architecture Thesaurus (AAT) », disponible à l'adresse URL : <https://www.getty.edu/research/tools/vocabularies/aat/about.html>, consulté en ligne le 23 février 2026.

⁹² GETTY RESEARCH INSTITUTE, « About the Art & Architecture Thesaurus (AAT) », disponible à l'adresse URL : <https://www.getty.edu/research/tools/vocabularies/aat/about.html>, consulté en ligne le 23 février 2026.

⁹³ GETTY RESEARCH INSTITUTE, « Union List of Artist Names (ULAN) », disponible à l'adresse URL : <https://www.getty.edu/research/tools/vocabularies/ulan/about.html>, consulté en ligne le 23 février 2026

d'information culturels⁹⁴. Dans le contexte allemand, la Gemeinsame Normdatei (GND) constitue un autre cas paradigmatique : ce fichier d'autorités, maintenu par la Bibliothèque nationale d'Allemagne en collaboration avec d'autres institutions, a été publié comme Linked Data en formats RDF et avec des identifiants persistants, facilitant l'identification univoque et la mise en relation sémantique des entités entre institutions⁹⁵.

Un rôle comparable, bien que fondé sur une logique différente, est joué par Wikidata. Cette initiative, lancée par la Wikimedia Foundation en 2012, stocke des données structurées concernant les sujets traités dans Wikipédia, ainsi que d'autres entités qui ne disposent pas nécessairement d'une représentation encyclopédique. Contrairement à des vocabulaires spécialisés et hiérarchisés de manière centralisée comme ceux du Getty, Wikidata fonctionne comme une base de connaissances collaborative, tant pour la production et la maintenance des données que pour la définition de leurs structures. En effet, de multiples ontologies coexistent au sein de Wikidata, ce qui entraîne certains problèmes de superposition et d'ambiguïté ontologique entre entités. Néanmoins, au-delà de ces difficultés inhérentes à un projet collaboratif, Wikipédia demeure l'une des ressources les plus utilisées dans les projets de Linked Open Data. Son adoption croissante par les musées et les projets patrimoniaux tient moins à sa précision disciplinaire qu'à sa capacité à agir comme point de convergence entre des ensembles de données hétérogènes, opérant comme un hub⁹⁶ d'identification et de liaison au sein de l'écosystème des Linked Open Data. Les fiches de chaque entité incluent en effet des références à un grand nombre d'identifiants permanents provenant d'autres institutions, tels que l'ULAN, le GND, le Virtual International Authority File (VIAF) ou l'International Standard Name Identifier (ISNI), facilitant ainsi l'interopérabilité entre des ressources diverses.

Outre les vocabulaires et les bases de données comportant des entités persistantes, l'interopérabilité implique également une série de questions liées à la qualité, tant épistémologique qu'éthique, des données partagées. En réponse aux difficultés rencontrées pour appliquer des processus de reproductibilité et de répliquabilité scientifique dans des

⁹⁴ GRIMALDI Francesca, « The Evolution of Data.bnf.fr : Past, Present and Future of the BnF Linked Open Data Project », *JLIS.it – Italian Journal of Library, Archives and Information Science*, 2024, disponible à l'adresse URL : <https://www.jlis.it/index.php/jlis/article/view/588>, consulté en ligne le 23 février 2026.

⁹⁵ DEUTSCHE NATIONALBIBLIOTHEK, « Gemeinsame Normdatei (GND) », disponible à l'adresse URL : <https://www.dnb.de/EN/Professionell/Standardisierung/GND/gnd.html>, consulté en ligne le 23 février 2026.

⁹⁶ Un hub est un point central de connexion ou de distribution où convergent et se coordonnent différents éléments.

expérimentations mobilisant de grandes quantités de données issues de sources diverses, un consortium de scientifiques et d'organisations a formulé en 2016 les principes FAIR⁹⁷. FAIR est un acronyme dans lequel le F signifie *Findable*, ce qui implique que les données et leurs métadonnées doivent être facilement localisables, tant par les humains que par les machines, grâce à des identifiants persistants et à des descriptions adéquates. Le A renvoie à *Accessible*, indiquant que les données doivent pouvoir être récupérées au moyen de protocoles standardisés et ouverts, même lorsque des restrictions d'accès clairement définies existent. Le I correspond à *Interoperable*, ce qui désigne la capacité des données à s'intégrer et à se combiner avec d'autres ensembles de données, ce qui suppose l'usage de formats normalisés, de vocabulaires partagés et de références sémantiques explicites. Enfin, le R de *Reusable* renvoie à la possibilité de réutiliser les données dans différents contextes, ce qui implique des métadonnées riches, des licences claires et une documentation permettant de comprendre leur origine, leur qualité et leurs conditions d'utilisation.

Cependant, comme nous l'avons vu dans les principes du mouvement *collections-as-data*, il ne s'agit pas uniquement d'assurer la qualité et la scientificité des données ; leur partage et leur interconnexion impliquent également des enjeux éthiques et déontologiques. Un exemple de principes visant à garantir un cadre éthique minimal autour de l'utilisation des données est celui des principes CARE⁹⁸. Les principes CARE ont été proposés en 2019 par la Global Indigenous Data Alliance comme un cadre orienté vers la gouvernance éthique des données relatives aux peuples et aux communautés autochtones. CARE est également un acronyme : Collective Benefit souligne que l'utilisation des données doit générer des bénéfices collectifs et non uniquement de la valeur académique, économique ou institutionnelle ; Authority to Control affirme le droit des communautés à participer à la prise de décision concernant la manière dont les données qui les concernent sont collectées, gérées, interprétées et diffusées ; Responsibility met l'accent sur l'obligation, pour celles et ceux qui travaillent avec des données, d'agir de manière responsable, en reconnaissant les contextes historiques, les asymétries de pouvoir et les impacts sociaux

⁹⁷ GO FAIR INITIATIVE, « FAIR Principles », disponible à l'adresse URL : <https://www.go-fair.org/fair-principles>, consulté en ligne le 23 février 2026; principes formulés initialement dans : WILKINSON, Mark D. et al. "The FAIR Guiding Principles for scientific data management and stewardship". *Scientific Data*, vol. 3, 2016.

⁹⁸ Voir : CARROLL S. R., GARBA I. FIGUEROA O. L., et al., « CARE Principles for Indigenous Data Governance », *Data Science Journal*, 19, 2020, DOI: <https://doi.org/10.5334/dsj-2020-043>.

potentiels ; Ethics introduit la nécessité de cadres normatifs situés, sensibles aux valeurs culturelles, aux normes communautaires et aux principes de justice.

En Suisse, le groupe Critical GLAM a récemment publié le manuel *Rassismuskritische Dokumentation. Ein Handbuch für GLAM-Institutionen*⁹⁹, conçu comme un guide destiné à accompagner les institutions GLAM dans une réflexion critique sur l'usage du langage et sur l'intégration de récits racistes ou colonialistes dans leurs données. Le guide comprend une série de stratégies spécifiquement orientées vers la publication des données, telles que le marquage de certains titres comme problématiques, la dissimulation ou la censure d'images ou de termes sensibles, la reformulation de titres, ou encore l'ajout d'avertissements individuels ou généraux permettant de contextualiser les contenus. Ces stratégies se révèlent particulièrement pertinentes au moment de concevoir et de gérer des plateformes de données interconnectées, dans la mesure où elles permettent de rendre publics les enregistrements de manière contextualisée et non offensante, sans supprimer les titres historiques ni rompre les relations sémantiques structurelles.

L'utilisation de l'ensemble de ces ressources n'est toutefois pas un processus automatique. Elle implique une série de décisions curatoriales concrètes : quel vocabulaire est le plus pertinent pour chaque champ descriptif ? Comment gérer les cas d'ambiguïté ou de polysémie ? Comment appliquer en pratique des principes tels que le principe CARE ? Quels biais épistémologiques, culturels ou institutionnels sont introduits lors du mappage de termes issus de collections diverses ? À titre d'illustration concernant les vocabulaires adaptés aux LOD, la catégorie d'« art conceptuel » dans un musée d'Amérique latine ne correspond pas nécessairement, ni en termes de périodisation, ni de signification, ou encore de niveau de structuration conceptuelle, à ce qui est entendu par « art conceptuel » aux États-Unis, et donc au Getty. Dans ce contexte, des pratiques qui en Amérique latine pourraient s'inscrire dans des catégories liées à des processus politiques, expérimentaux ou collectifs peuvent se retrouver subsumées ou désalignées lorsqu'elles sont mappées sur des structures taxonomiques conçues à partir d'autres cadres historiques et théoriques¹⁰⁰.

⁹⁹ ISLER D. et al., *Rassismuskritische Dokumentation. Ein Handbuch für GLAM-Institutionen*, 2025, CRITICALGLAM.

¹⁰⁰ Pour une analyse de ce cas, voir : BARRIENDOS Joaquín, « Latinoamericanismo Digital : Arte latinoamericano y humanidades digitales en Estados Unidos », in : BARRIA BIGNOTTI Cristóbal (dir.), *Las artes en Latinoamérica a través de las Humanidades Digitales, Quaderni Culturali IILA*, vol. 3, no 3, 2021, pp. 15–29, DOI : <https://doi.org/10.36253/qciila-1550>.

Le travail de curation des données implique une série de décisions qui, bien que souvent invisibilisées et peu valorisées, sont fondamentales pour que les projets de données ouvertes maintiennent la cohérence entre les données et ne se transforment pas en de simples répertoires dépourvus de contexte interprétatif. Loin d'être une documentation mécanique, cet exercice constitue un processus critique et analytique comparable à la curation des objets physiques des collections. Cependant, comme l'ont exprimé Belteki, Rees et Sichani¹⁰¹ à travers la métaphore de l'iceberg, l'ensemble des opérations décisives qui soutiennent ce processus demeure immergé sous la surface et reste invisibilisé lorsque seule l'interface est visible.

La curation numérique est définie par le Digital Curation Centre¹⁰² comme « la gestion et la préservation des données / informations numériques sur le long terme. La curation numérique implique le maintien, la préservation et l'ajout de valeur aux données de recherche numériques tout au long de leur cycle de vie »¹⁰³. Cela suppose que la curation numérique ne se limite pas aux aspects techniques de la conservation de l'information, mais qu'elle inclut également une série de décisions visant à ajouter de la valeur, telles que l'organisation, la documentation, la contextualisation et la réutilisation des informations dans le temps. Comme le souligne Neil Beagrie, le terme « curation » a été délibérément adopté à partir du domaine des bibliothèques et des musées, « en tant que terme visant à transférer explicitement les approches curatoriales existantes vers les collections numériques »¹⁰⁴. Cette généalogie n'est pas anodine : elle révèle que la curation numérique n'émerge pas uniquement comme une réponse technique aux problèmes de stockage ou de préservation, mais comme une pratique qui hérite de questions

¹⁰¹ BELTEKI Daniel, REES Andrew J., SICHANI Anna-Maria, « Datafication and Cultural Heritage Collections Data Infrastructures : Critical Perspectives on Documentation, Cataloguing and Data-sharing in Cultural Heritage Institutions », *Journal of Open Humanities Data*, vol. 11, 2025, art. 14, DOI : <https://doi.org/10.5334/johd.277>.

¹⁰² Le Digital Curation Centre (DCC) est une organisation de référence internationale dans le domaine de la curaterie numérique, dont la mission est d'aborder des problématiques transversales telles que la promotion de standards, de bonnes pratiques et de définitions communes. Voir : <https://www.dcc.ac.uk/>, consulté en ligne le 23 février 2026.

¹⁰³ « the management and preservation of digital data/information over the long-term. Digital curation involves maintaining, preserving and adding value to digital research data throughout its lifecycle ». Voir : DIGITAL CURATION CENTRE, « What is Digital Curation ? », disponible à l'adresse URL : <https://www.dcc.ac.uk/about/digital-curation>. Voir également : DALLAS Costis, « Digital Curation Beyond the "Wild Frontier" : A Pragmatic Approach », *International Journal of Digital Curation*, 2016 et HIGGINS Sarah, « Digital Curation : The Emergence of a New Discipline », *International Journal of Digital Curation*, 2008.

¹⁰⁴ « as a term to explicitly transfer existing curatorial approaches to digital collection ». Voir : BEAGRIE Neil, « Digital Curation for Science, Digital Libraries, and Individuals », *International Journal of Digital Curation*, vol. 1, no 1, 2006, pp. 3–16, p. 5.

centrales de la tradition muséale, telles que ce qu'il convient de conserver, selon quels critères décrire, comment contextualiser les objets et quelles narrations se construisent à partir d'eux. En ce sens, la curation numérique ne peut être réduite à une question de standards, de formats ou d'infrastructures technologiques. Elle implique des décisions épistémologiques et politiques concernant la sélection, la documentation, l'interprétation et la mise en circulation des données.

1.5- Instruments d'évaluation et diagnostic

L'état des données ainsi que les multiples décisions curatoriales qui ont présidé à leur production, à leur organisation et à leur normalisation exercent une influence déterminante sur le processus d'agrégation. Comme nous l'avons vu précédemment, l'analyse des données et des pratiques de curation, ainsi que la transmission des connaissances entre les gestionnaires des bases de données et les spécialistes de la modélisation, deviennent dès lors des éléments centraux dans leur transformation en données interopérables.

Afin de pouvoir évaluer l'état des données en amont de la modélisation, Europeana propose un « Maturity Model », c'est-à-dire un instrument qui définit le degré de préparation des données des fournisseurs. Ce modèle prend en compte des dimensions telles que la qualité et la complétude des métadonnées, la clarté dans la déclaration des droits et le potentiel de réutilisation, la qualité technique des objets numériques (par exemple, la résolution minimale des images ou la stabilité des liens), ainsi que les possibilités d'enrichissement sémantique. En pratique, le Data Maturity Model établit des exigences minimales de publication, permet d'identifier des axes d'amélioration et définit des niveaux progressifs vers lesquels les fournisseurs peuvent évoluer au sein de l'infrastructure Europeana ; il ne propose toutefois pas d'analyse exploratoire des données destinée à accompagner le processus de modélisation.

De la même manière que le Maturity Model d'Europeana, il existe d'autres modèles de maturité qu'il convient de prendre en considération lors de la publication de données en LOD. Tel est le cas du FAIR Data Maturity Model¹⁰⁵, qui propose un cadre structuré permettant d'évaluer le degré d'adoption des principes FAIR (Findable, Accessible, Interoperable, Reusable) au sein

¹⁰⁵ RESEARCH DATA ALLIANCE, « FAIR Data Maturity Model : Specification and Guidelines », disponible à l'adresse URL : https://www.rd-alliance.org/system/files/FAIR%20Data%20Maturity%20Model_%20specification%20and%20guidelines_v0.90.pdf, consulté en ligne le 23 février 2026.

d'un projet¹⁰⁶. À l'instar du modèle d'Europeana, il s'agit d'un instrument d'évaluation par niveaux, destiné à identifier des axes d'amélioration et à orienter la progression vers les principes, mais il ne constitue toutefois pas un outil d'accompagnement à la modélisation proprement dite.

Alors que les Maturity Models proposent des cadres structurés d'évaluation par niveaux, il existe également des instruments plus ponctuels et opérationnels pour évaluer les données, comme les listes de contrôle (checklists). Un exemple est le *Data on the Web Best Practices* (DWBP) du W3C¹⁰⁷, qui définit 35 bonnes pratiques pour la publication de données dans des environnements web et Linked Data. Ces pratiques portent sur l'évaluation de différents aspects tels que les métadonnées, les licences, le versionnage, la présence d'identifiants persistants, la qualité des données, les formats, les vocabulaires et l'accessibilité via des APIs ou des téléchargements. De manière similaire, et spécifiquement conçu pour les collections GLAM, on trouve le *Checklist to Publish Collections as Data*¹⁰⁸, un outil permettant d'évaluer la préparation des collections en vue de leur publication comme données ouvertes et sémantiquement interopérables. La liste de contrôle inclut des éléments relatifs à : fournir des licences claires favorisant la réutilisation, inclure une documentation, suggérer une manière de citer le jeu de données, structurer les données de manière cohérente, proposer des métadonnées dans des formats lisibles par machine, offrir un accès programmatique via des APIs et partager des exemples d'utilisation ou des prototypes facilitant leur exploitation.

Cependant, ces deux instruments sont principalement orientés vers l'évaluation de la préparation organisationnelle à la publication des données, plutôt que vers l'accompagnement de la modélisation conceptuelle à proprement parler. Par ailleurs, ils ne permettent pas d'établir un diagnostic détaillé de l'état interne des données d'origine et n'abordent pas explicitement des questions telles que les incohérences conceptuelles, les ambiguïtés sémantiques, les doublons ou

¹⁰⁶ Les principes FAIR constituent un ensemble de directives formulées en 2016 visant à améliorer la gestion et la réutilisation des données scientifiques dans les environnements numériques. Voir : GO FAIR, *FAIR Principles*, disponible à l'adresse URL : <https://www.go-fair.org/fair-principles/>, consulté en ligne le 23 février 2026.

¹⁰⁷ WORLD WIDE WEB CONSORTIUM (W3C), « Data on the Web Best Practices », disponible à l'adresse URL : <https://www.w3.org/TR/dwbp/#quality>, consulté en ligne le 23 février 2026.

¹⁰⁸ CANDELA Gianmarco, GABRIËLS Nele, CHAMBERS Sally, *et al.*, « A Checklist to Publish Collections as Data in GLAM Institutions », *Global Knowledge, Memory and Communication*, vol. 74, nos 5–6, 2025, pp. 1323–1355, DOI : <https://doi.org/10.1108/GKMC-06-2023-0195>.

les conditions d'usage spécifiques au sein des structures de données originales, qui sont pourtant centrales dans un processus rigoureux de modélisation.

1.6- Présentation du projet de plateforme fédérée de la Ville de Genève

Le projet de plateforme de données patrimoniales interconnectées de la ville de Genève s'inscrit dans une stratégie de transition numérique, et plus particulièrement de numérisation du patrimoine culturel de la ville, portée par le *Département de la culture et de la transition numérique* (DCTN). Ses antécédents remontent à 2010, lorsqu'un comité de pilotage a entamé l'élaboration d'une stratégie commune pour la numérisation des collections patrimoniales de la ville¹⁰⁹. Ce travail a abouti en 2014 à la publication du rapport *Numérisation du patrimoine intellectuel genevois. Collections imprimées et iconographiques de la Ville de Genève*¹¹⁰, qui proposait la numérisation de 187 ensembles patrimoniaux — équivalant à environ 36 millions de pages — conservés par les Archives de la Ville, quatre bibliothèques dépendant du DCTN (la Bibliothèque de Genève, le Conservatoire et Jardin botaniques, la Bibliothèque d'art et d'archéologie du Musée d'art et d'histoire et la bibliothèque de zoologie, géosciences et archéozoologie du Muséum d'histoire naturelle), ainsi que par les collections du Musée d'ethnographie de Genève.

Bien que cet ambitieux programme ait constitué la première tentative d'articuler une politique coordonnée de numérisation du patrimoine genevois, il n'a pas été mis en œuvre dans les termes prévus. Parmi les réalisations qui en ont découlé figure notamment le portail Mirabilia¹¹¹, destiné à la diffusion en ligne des collections de la ville, mais construit sur un CMS conventionnel (Drupal) dépourvu de toute couche de données sémantiques : il n'expose pas d'URI déréférençables pour ses entités, ne structure pas ses relations au moyen d'une ontologie patrimoniale telle que le CIDOC-CRM, ne publie pas les données dans des formats liés

¹⁰⁹ VILLE DE GENÈVE, DÉPARTEMENT DE LA CULTURE ET DE LA TRANSITION NUMÉRIQUE (DCTN), *Fiche projet — Numérisation des collections patrimoniales de la Ville de Genève*, réf. DCTN_2022_04_29_Fiche_projet_numerisation_vv_cauliez, 29 avril 2022, document interne non publié, pp. 1-2.

¹¹⁰ RIVIER Alexis, *Numérisation du patrimoine intellectuel genevois. Collections imprimées et iconographiques de la Ville de Genève*, 2014, document interne non publié, 92p.

¹¹¹ MIRABILIA, disponible à l'adresse URL : <https://mirabilia.ch/fr>, consulté en ligne le 21 juillet 2026.

(RDF/JSON-LD) et ne permet ni leur interrogation ni leur interopérabilité avec d'autres répertoires¹¹².

Dans le but de relancer le programme de numérisation du patrimoine culturel de la ville, le DCTN a créé, en 2020, le poste de *Conseillère en conservation*, avec pour mandat de réaliser une analyse comparée et de redéfinir le projet à la lumière des expériences accumulées au cours de la décennie précédente par d'autres institutions. Ce processus a conduit, en 2022, à une profonde reformulation tant de la gouvernance que du modèle de financement. Une nouvelle structure a été mise en place, composée d'un *Comité de pilotage* (COPIL) stratégique et d'un *Comité scientifique et technique*, tandis que le financement a été réorganisé en différents portefeuilles de projets¹¹³. La nouvelle feuille de route s'est articulée autour de quatre axes de travail complémentaires : (1) la révision et la priorisation des collections susceptibles d'être numérisées ; (2) la définition d'appels à projets thématiques destinés à financer des projets de valorisation patrimoniale ; (3) la conception de l'infrastructure technologique nécessaire pour garantir l'hébergement, la préservation, l'accessibilité et l'interopérabilité des données numériques ; et (4) l'identification de partenariats institutionnels et de sources de financement externes pour assurer la pérennité du programme¹¹⁴. Cette feuille de route, intégrée au 18e Plan financier d'investissements de la Ville de Genève, a été approuvée le 2 septembre 2025 et constitue le cadre stratégique en vigueur pour la politique de numérisation du patrimoine du DCTN.

Le projet de numérisation avait identifié précocement la nécessité d'interopérabilité des données. Parmi les missions assignées au troisième axe de la feuille de route figurait une analyse des difficultés d'interopérabilité face aux nouveaux contenus numérisés, en termes d'accès, de compréhension et d'intelligibilité¹¹⁵. Le document ne proposait cependant pas de solution technique concrète : il se limitait à souligner la nécessité d'une telle analyse.

¹¹² Il convient de souligner que cette analyse des contenus et du fonctionnement a été réalisée directement à partir de les composants techniques du site, notamment par l'inspection des en-têtes HTTP et du code source. Cette approche a été adoptée en raison de l'absence d'une documentation, ce qui constitue également un indice de son inadéquation avec les principes du Linked Open Data.

¹¹³ VILLE DE GENÈVE, DÉPARTEMENT DE LA CULTURE ET DE LA TRANSITION NUMÉRIQUE (DCTN), 2022, p. 6-8.

¹¹⁴ VILLE DE GENÈVE, DÉPARTEMENT DE LA CULTURE ET DE LA TRANSITION NUMÉRIQUE (DCTN), 2022, p. 9-14.

¹¹⁵ VILLE DE GENÈVE, DÉPARTEMENT DE LA CULTURE ET DE LA TRANSITION NUMÉRIQUE (DCTN), 2022, p. 13.

Le projet de plateforme de données patrimoniales interconnectées de la ville de Genève a été conçu comme la réponse concrète à ce défi. Il vise à développer une infrastructure capable de transformer les données patrimoniales déjà numérisées — ou en cours de numérisation — en un graphe de connaissances interopérable, en intégrant les informations produites par les huit institutions patrimoniales du DCTN : le Musée d'art et d'histoire (MAH), la Bibliothèque de Genève (BGE), le Fonds d'art contemporain de la Ville de Genève (FMAC), le Musée Ariana, le Musée d'ethnographie de Genève (MEG), les Archives de la Ville de Genève (AVG), le Conservatoire et Jardin botaniques de Genève (CJB) et le Muséum d'histoire naturelle (MHN). Au-delà de l'interconnexion entre ces institutions, la plateforme cherche également à relier ses données à d'autres répertoires patrimoniaux publiés en *Linked Open Data*, tels que Wikidata ou Europeana, favorisant ainsi son intégration dans l'écosystème international des données patrimoniales liées.

Afin d'évaluer les conditions nécessaires à la mise en œuvre de cette infrastructure, le DCTN a confié en 2025 à la *Swiss Art Research Infrastructure* (SARI) — infrastructure nationale de recherche rattachée à l'Université de Zurich — une première étude exploratoire¹¹⁶. Cette analyse a porté sur les aspects techniques et méthodologiques du projet, en particulier sur la définition d'une architecture de données pérenne, la mise en œuvre de pipelines de transformation et d'enrichissement, et la modélisation sémantique conforme aux standards internationaux et aux pratiques d'*Open Research Data* (ORD). Ce travail a permis de préciser les exigences nécessaires pour garantir l'interopérabilité, la pérennité et la réutilisation des données patrimoniales dans le cadre des principes FAIR (*Findable, Accessible, Interoperable, Reusable*).

D'un point de vue méthodologique, l'élément central de la plateforme est un ensemble de pipelines destinés à intégrer les données provenant des différentes collections et à les transformer en un graphe de connaissances fondé sur des standards établis tels que le CIDOC-CRM, Linked.Art et les *Semantic Reference Data Models* (SRDM) développés par SARI. Cette approche garantit l'interopérabilité des données et permet leur intégration avec des sources externes telles que Wikidata, la Gemeinsame Normdatei (GND) ou Europeana. Le processus comprend la récupération des données depuis les systèmes de gestion de collections propres à chaque institution — principalement MuseumPlus, ainsi qu'Alma et Ligeo pour les fonds

¹¹⁶ SWISS ART RESEARCH INFRASTRUCTURE, *Project Proposal – Collections Patrimoniales de la Ville de Genève CPVG*, v. 2, document interne non publié, 28 janvier 2025.

bibliographiques et archivistiques —, leur conversion au format CIDOC-CRM/RDF au moyen du framework X3ML, leur ingestion dans un répertoire centralisé de triplets, un processus d'alignement interne destiné à unifier les entités communes à plusieurs collections — personnes, lieux, etc. — au moyen d'identifiants pérennes. S'y ajoute un processus d'enrichissement au moyen de répertoires externes, permettant d'élargir le contexte des données locales. Le graphe de connaissances ainsi obtenu sera accessible via une interface développée sur la plateforme ResearchSpace, ainsi que par un point d'accès SPARQL public¹¹⁷. Le projet explore en outre, de manière exploratoire, l'usage de technologies d'intelligence artificielle pour l'enrichissement automatique de textes et d'images, en particulier la reconnaissance d'entités nommées, la liaison d'entités et la classification automatique d'images¹¹⁸.

Ce projet présuppose toutefois que les données de départ — les extractions issues de MuseumPlus, Alma ou Ligeo — sont suffisamment structurées, compréhensibles et sémantiquement cohérentes entre les différentes institutions pour alimenter la phase de modélisation générique. Or, les données provenant des systèmes de gestion de collections présentent nécessairement des différences liées aux pratiques documentaires, aux modèles de données institutionnels et aux processus historiques de catalogage propres à chaque collection. Avant de procéder à la conception des mappages spécifiques entre les champs locaux et les modèles sémantiques de référence, il est nécessaire de répondre à une série de questions que l'analyse technique du pipeline ne permet pas de résoudre à elle seule : dans quelle mesure les terminologies et expressions utilisées sont-elles normalisées, quel est le volume de doublons ou d'ambiguïtés sémantiques présent dans les données, quelle stabilité présentent les structures documentaires existantes, et quelles restrictions juridiques, éthiques ou institutionnelles conditionnent leur publication et leur réutilisation.

C'est précisément dans ce contexte, et plus spécifiquement dans la phase préparatoire préalable à la modélisation sémantique des données, que s'inscrit l'instrument développé dans ce mémoire. Cet instrument vise à fournir un cadre d'analyse permettant d'évaluer les caractéristiques, les besoins et les défis associés aux ensembles de données patrimoniales avant leur intégration dans

¹¹⁷ SWISS ART RESEARCH INFRASTRUCTURE, *Project Proposal*, 2025, p. 3 ; SWISS ART RESEARCH INFRASTRUCTURE, *Annexe 1 : Pipeline Design*, v1, document interne non publié, 28 janvier 2025, pp. 1-10 ; SEMANTIC REFERENCE DATA MODELS, *Annexe 2 : Internal Alignment Architecture*, v1, document interne non publié, 28 janvier 2025.

¹¹⁸ SWISS ART RESEARCH INFRASTRUCTURE, *Project Proposal*, 2025, pp. 3, 13-14.

une infrastructure interopérable. Sa méthodologie et ses résultats seront présentés en détail au chapitre 4.

2- Objectifs

2.1- Description du problème

L'intégration de données patrimoniales dans des infrastructures fondées sur les principes du Linked Open Data nécessite une connaissance préalable des caractéristiques, de la structure et de la qualité des jeux de données sources. Avant toute étape de modélisation sémantique, il est nécessaire d'évaluer des dimensions telles que l'organisation des données, la définition et l'usage des champs, le degré de normalisation des valeurs, les vocabulaires ou référentiels mobilisés, la présence de doublons ou d'ambiguïtés sémantiques, ainsi que les contraintes juridiques, éthiques ou institutionnelles susceptibles d'influencer leur publication et leur réutilisation.

Lorsque plusieurs institutions patrimoniales sont concernées par un même projet d'agrégation, ces enjeux se complexifient en raison de la diversité des pratiques documentaires, des systèmes de gestion de collections et des choix de catalogage propres à chaque institution. Cette hétérogénéité rend difficile l'évaluation préalable de la faisabilité d'une intégration, l'identification des travaux de préparation nécessaires et la planification des processus de transformation et de modélisation des données.

Or, il n'existe actuellement pas d'outil méthodologique permettant de collecter et de structurer de manière systématique ces informations en amont d'un projet d'intégration de données patrimoniales en Linked Open Data. Cette absence limite la capacité à établir un diagnostic partagé des jeux de données, à anticiper les ressources nécessaires et à orienter les choix de modélisation sémantique.

2.2- Objectif principal

L'objectif de ce mémoire est de concevoir un instrument méthodologique permettant d'évaluer l'état de préparation des jeux de données patrimoniaux en vue de leur intégration dans une plateforme de données interconnectées en Linked Open Data.

Cet instrument a pour fonction de documenter les caractéristiques des jeux de données, leur niveau de curation, ainsi que les contraintes susceptibles d'influencer leur transformation et leur modélisation. À partir de ces informations, il permet d'identifier les besoins en matière de nettoyage, de normalisation, d'enrichissement et d'alignement, afin d'éclairer les décisions relatives à l'intégration sémantique et à la priorisation des jeux de données à publier au sein d'une plateforme fédérée.

Il ne s'agit pas de définir un standard de qualité ou un modèle unique applicable à l'ensemble des institutions¹¹⁹, mais de proposer un cadre d'analyse suffisamment flexible pour s'adapter à la diversité des contextes patrimoniaux. En offrant une description structurée et comparable des jeux de données, cet instrument favorise également le dialogue entre les différents acteurs impliqués dans les projets d'interopérabilité et facilite la planification des travaux de préparation des données.

2.3- Objectifs spécifiques

1. Identifier les dimensions pertinentes pour l'évaluation préalable de jeux de données patrimoniaux dans le cadre de projets d'intégration en Linked Open Data.
2. Définir un ensemble structuré de questions permettant de collecter et de structurer les informations auprès d'une diversité d'institutions patrimoniales.
3. Élaborer une série de questions permettant de recueillir l'expérience et l'opinion des professionnels.
4. Concevoir un pipeline de travail pour l'intégration de l'instrument dans le processus de préparation des données.
5. Tester et évaluer l'applicabilité de l'instrument dans le contexte d'un projet réel d'agrégation de données patrimoniales.

¹¹⁹ Comme nous l'avons vu avec le Maturity Model d'Europeana (1.5).

3- Méthodologie

Cette section expose le cadre méthodologique général retenu pour l'élaboration et l'évaluation du questionnaire utilisé dans cette recherche. Les choix relatifs à la conception méthodologique de l'enquête — notamment la structure du questionnaire, la définition de l'unité d'analyse, la conception de la modalité d'administration, ainsi que les modalités de restitution des résultats — relèvent de la conception même de l'instrument d'enquête et seront présentés dans le chapitre 4 « Design et présentation du questionnaire ».

La conception du questionnaire a reposé sur trois opérations principales : (1) la définition du cadre conceptuel et méthodologique de l'enquête, (2) l'élaboration et la formalisation des questions à partir de la littérature spécialisée, et (3) la validation de l'instrument par expertise et prétest.

La première étape a reposé principalement sur l'analyse de la littérature de référence. Celle-ci comprenait à la fois des questionnaires existants¹²⁰, des méthodes et approches consacrées aux processus d'agrégation et d'intégration de données patrimoniales dans des environnements Linked Open Data¹²¹, ainsi que la documentation relative aux modèles conceptuels largement utilisés dans le domaine patrimonial, en particulier le CIDOC CRM¹²² et Records in Contexts

¹²⁰ Voir: CONCILIO, L'ŒIL DU PUBLIC, *La digitalisation dans les institutions culturelles suisses: État des lieux et perspectives*, disponible à l'adresse URL: https://loeildupublic.com/wp-content/uploads/2023/10/La-digitalisation-dans-les-institutions-culturelles-suissees_sept-23_FR.pdf, consulté en ligne le 20, Juillet 2026 ; ESTERMANN Beat, 2016, p. 134; ESTERMANN Beat, OpenGLAM Benchmark Survey – Measuring the Advancement of Open Data / Open Content in the Heritage Sector, in : *Proceedings of the international symposium on the measurement of digital cultural products*, UNESCO Institute for Statistics, 2016, pp. 121–140. <https://doi.org/10.24451/arbor.9495>; STAUFFER Laurène SUISSE OFFICE FÉDÉRAL DE LA STATIQUE, *Paysage Muséal et Public Des Musées En Suisse : Situation En 2019 et Évolution Sur Cinq Ans*. Neuchâtel: Office fédéral de la statistique, 2021; SCHLÖSSER Magdalene SCHÄFFER Johannes VON HAGEL Frank, et SCHÄFER Felix, *Überblick über das Forschungsdatenmanagement in Museen und Universitätssammlungen*, Zenodo, 2024, <https://doi.org/10.5281/zenodo.13789201>.

¹²¹ En particulier : BRUSEKER George, CARBONI Nicola, FIELDING Mark, NENOVA Desislava, HÄNSLI Tobias, « The Semantic Reference Data Modelling Method : Creating Understandable, Reusable and Sustainable Semantic Data Models », *Journal of Open Humanities Data*, vol. 11, 2025, DOI : <https://doi.org/10.5334/johd.282>; ONTOME, *OntoMe wiki*, disponible à l'adresse URL : <https://wiki-arhn.larhra.fr/doku.php?id=ontome:index>, consulté en ligne le 23 février 2026.

¹²² DOERR Martin *et al.*, *CIDOC Conceptual Reference Model (CIDOC CRM), Version 7.1.3*. ICOM/CIDOC CRM Special Interest Group, 2024, disponible à l'adresse URL : <https://www.cidoc-crm.org/>, consulté en ligne le 23 février 2026.

(RiC)¹²³. Elle s'est également appuyée sur la littérature consacrée à la curation des données et aux cycles de vie des données¹²⁴ et aux principes de gouvernance, d'accès et de réutilisation des données¹²⁵. Cette revue avait pour objectif d'identifier les informations nécessaires à la compréhension des structures de données institutionnelles et des contraintes susceptibles d'affecter leur transformation vers un environnement de type Linked Open Data (LOD).

Cette phase a également été nourrie par la documentation produite dans le cadre du projet pilote mené par le Musée d'art et d'histoire de Genève (MAH) en vue du développement d'une plateforme de données interconnectées¹²⁶. L'analyse de ce projet a permis d'identifier plusieurs difficultés récurrentes dans la transmission des connaissances entre les responsables des collections et les spécialistes chargés de la modélisation des données.

Sur la base des définitions retenues et de la littérature analysée, une première version du questionnaire a été élaborée puis soumise à l'évaluation d'une experte dans la gestion des données muséales et archivistiques. L'objectif de cette expertise était de vérifier que les questions reflétaient adéquatement les pratiques de gestion et de documentation des données patrimoniales, que les informations demandées étaient effectivement disponibles au sein des institutions, et que les concepts ainsi que les formulations employés étaient clairs et pertinents du point de vue des professionnels du domaine (voir: 5.1).

En parallèle à l'expertise du questionnaire, un prétest a été réalisé sur l'instance MuseumPlus de la Ville de Genève. Cette infrastructure regroupe les métadonnées de huit institutions de la ville de Genève aux collections très variées : le Musée d'art et d'histoire, le Musée Ariana, la Bibliothèque d'art et d'archéologie, le Centre d'iconographie, le Fonds d'art contemporain, l'Institut et Musée Voltaire, le Jardin botanique et le Musée d'histoire des sciences. Cette stratégie a été retenue car ce corpus de plus de 700 000 objets traverse des domaines très divers (archéologie, beaux-arts, arts appliqués, histoire, sciences, livres et archives). Une telle

¹²³ INTERNATIONAL COUNCIL ON ARCHIVES, *Records in Contexts Conceptual Model (RiC-CM), Version 1.0*. Paris: ICA, 2023, disponible à l'adresse URL : <https://www.ica.org/standards/RiC/>, consulté en ligne le 23 février 2026.

¹²⁴ HIGGINS, Sarah. *The DCC Curation Lifecycle Model*. Edinburgh: Digital Curation Centre, 2008.

¹²⁵ GO FAIR INITIATIVE, « FAIR Principles », disponible à l'adresse URL : <https://www.go-fair.org/fair-principles>, consulté en ligne le 23 février 2026.

¹²⁶ Voir la documentation associée au projet : CENTRE DE DOCUMENTATION ET RECHERCHE - MAH, *Documentation POC Plateforme de recherche fédérée, réf. PoC_Documentation.pdf*, 07 Janvier 2025, document interne non publié.

hétérogénéité offrait un terrain idéal pour valider la robustesse et la pertinence du questionnaire dans des contextes documentaires distincts (voir 5.2).

Les observations issues de l'expertise et du prétest ont conduit à la révision du questionnaire, notamment par la reformulation, l'ajout ou la suppression de certaines questions. La version résultant de ce processus est présentée dans ce travail, tandis que la version initiale figure en Annexe 1.

4- Design et présentation du questionnaire

Ce chapitre présente la conception du questionnaire développé dans le cadre de ce travail. Il en expose les principaux choix méthodologiques, qui portent sur le type d'instrument, la structuration du questionnaire, le contenu et les types des questions, la définition de l'unité d'analyse, la conception de la modalité d'administration, ainsi que les modalités de restitution des résultats.

4.1- Choix de l'instrument de collecte de données

Le choix de recourir à un questionnaire structuré plutôt qu'à d'autres méthodologies, telles qu'une enquête ouverte ou une évaluation centralisée et directe des bases de données de chaque institution, répond à un ensemble de considérations méthodologiques variées.

Premièrement, l'usage d'un questionnaire permet de garantir un degré de standardisation qui facilite l'analyse transversale et comparative des résultats entre institutions. Deuxièmement, ce dispositif permet d'intégrer la perspective des institutions elles-mêmes, lesquelles possèdent une connaissance plus précise des caractéristiques propres à leurs données et des limitations associées à leur publication. Ainsi, le questionnaire ne se contente pas de recueillir de l'information, mais intègre également la voix des acteurs responsables de la gestion des données, sans renoncer pour autant à la possibilité d'une analyse centralisée et comparative.

De plus, le questionnaire peut remplir une fonction supplémentaire de nature réflexive, en agissant comme un outil de type *checklist* aidant les institutions à évaluer la pertinence de leurs propres données au regard des exigences de la plateforme — une fonction qui ne serait pas possible dans le cadre d'une analyse centralisée.

Un autre argument pertinent est la flexibilité que permet ce type d'instrument. Un questionnaire permet en effet de s'adapter aux besoins spécifiques de chaque institution sans compromettre l'homogénéité de l'instrument ni la comparabilité des résultats. En ce sens, différentes institutions peuvent ne répondre qu'aux sections du questionnaire pertinentes pour leur contexte, tout en conservant un cadre commun qui assure la validité de l'ensemble des données obtenues.

Enfin, l'usage d'un questionnaire présente l'avantage d'être indépendant de la taille des institutions et des systèmes de gestion de données utilisés. S'agissant d'un instrument externe, il n'exige pas que les institutions disposent de leurs données dans un format spécifique pour leur analyse, ce qui permet son application aussi bien dans des contextes disposant de bases de données structurées que dans ceux où l'information se trouve sous des formats moins standardisés, tels que des feuilles de calcul, une documentation non structurée ou des systèmes internes propres.

4.2- Univers d'étude

L'univers d'étude est constitué par les institutions patrimoniales relevant du secteur GLAM qui gèrent des jeux de données liés à leurs collections ou à leurs ressources documentaires, et qui pourraient potentiellement être intégrés dans une plateforme fondée sur le *Linked Open Data*.

Étant donné que l'objectif de l'instrument est d'évaluer l'état de préparation des données et non un niveau spécifique de maturité numérique institutionnelle, le questionnaire a été conçu pour être applicable à des institutions de tailles, de capacités techniques et de degrés de structuration de l'information différents.

Cette approche répond à la grande hétérogénéité observée dans le secteur patrimonial¹²⁷. Les institutions peuvent différer considérablement tant dans leurs pratiques de documentation que dans leurs infrastructures technologiques et leurs modèles de gestion des données. Tandis que certaines disposent de systèmes spécialisés de gestion des collections (tels que MuseumPlus, Alma, AtoM, etc.) et de dépôts structurés, d'autres peuvent travailler avec des solutions plus simples ou des processus partiellement numérisés (comme des feuilles de calcul, des fiches physiques ou des catalogues imprimés).

Cette diversité constitue précisément une caractéristique centrale de l'univers d'étude, car elle permet d'évaluer les conditions réelles des données patrimoniales et d'estimer les efforts

¹²⁷ Voir el analisis de la seccion Differences between various types of heritage institutions del artículo : ESTERMANN Beat, OpenGLAM Benchmark Survey – Measuring the Advancement of Open Data / Open Content in the Heritage Sector, in : *Proceedings of the international symposium on the measurement of digital cultural products*, UNESCO Institute for Statistics, 2016, pp. 121–140. <https://doi.org/10.24451/arbor.9495>.

nécessaires à leur transformation, à leur enrichissement et à leur intégration dans une infrastructure sémantique.

4.3- Définition de l'unité d'analyse

Les enquêtes destinées à évaluer les politiques publiques de gestion des données ont tendance à retenir l'institution comme unité d'analyse¹²⁸. Cependant, cette approche peut occulter la complexité de la gestion, de la curation et de la nature même des données, ce qui constitue précisément ce que ce questionnaire cherche à saisir.

En effet, au sein d'une même institution, les données peuvent suivre des normes curatoriales différentes, recourir à des modèles distincts ou être gérées au moyen de systèmes variés. De la même manière, plusieurs institutions peuvent partager des outils, des pratiques ou des vocabulaires communs. Analyser l'institution comme une unité homogène reviendrait à invisibiliser des différences structurelles et méthodologiques dans le traitement des données. C'est pourquoi l'unité d'analyse du questionnaire ne peut se réduire ni à l'institution ni au système de gestion des données. Elle ne pouvait pas non plus se fonder sur des typologies d'objets de collection — telles que des œuvres, des documents d'archives ou des publications — car cela aurait supposé d'établir au préalable toute une série de définitions sémantiques.

En ce sens, et étant donné que le questionnaire se concentre sur l'état et les conditions des données elles-mêmes, l'unité d'analyse proposée est le *dataset* ou jeu de données. Un jeu de données est entendu ici comme une collection structurée de données comportant au moins un attribut relationnel permettant de relier différentes entités entre elles. Cette capacité d'articulation permet de représenter des relations, des interactions ou des dépendances entre les éléments documentés, transformant un ensemble d'enregistrements en une structure signifiante susceptible d'être analysée.

Ces relations peuvent revêtir différentes formes selon la nature des données et les pratiques documentaires de chaque institution. Par exemple, un attribut tel que « Auteur » au sein de l'entité « Œuvre » établit une relation entre une œuvre et une entité « Personne », représentant la relation « a été créée par ». De même, un attribut tel que « Événement associé » au sein de

¹²⁸ Voir note n° 119.

l'entité « Document » peut relier ce document à une entité « Événement », représentant la relation « a eu lieu pendant ». De la même façon, un attribut tel que « Fonds » ou « Unité de provenance » au sein de l'entité « Document d'archives » peut mettre en relation différents documents entre eux en indiquant qu'ils appartiennent au même fonds d'archives ou qu'ils proviennent du même producteur documentaire.

Il n'est pas nécessaire que toutes les entités soient directement reliées entre elles. Dans de nombreux cas, les relations s'établissent de manière indirecte, à travers d'autres entités intermédiaires. Ce qui importe pour cette définition, c'est l'existence d'une structure relationnelle minimale permettant de comprendre l'ensemble comme un système d'information interconnecté, et non comme une simple accumulation isolée d'enregistrements.

En résumé, cette recherche entend par jeu de données tout ensemble d'informations interconnectées, même en présence de différences internes dans leurs niveaux de standardisation, de curation ou de complétude. Cette définition permet ainsi d'établir une unité d'analyse suffisamment flexible pour s'adapter à l'hétérogénéité des pratiques documentaires des institutions patrimoniales, tout en étant suffisamment précise pour permettre des comparaisons structurées entre différents jeux de données.

4.4- Modalités d'administration

Le questionnaire a été conçu pour être appliqué dans des institutions patrimoniales présentant différents niveaux de maturité dans la gestion des données. Cependant, une partie importante de ses questions aborde des concepts techniques de haute complexité, de sorte que l'on ne peut pas supposer que ces concepts soient interprétés de manière homogène, y compris parmi les professionnels responsables de la documentation et de la gestion des collections.

Pour cette raison, l'instrument a été conçu pour être administré selon une modalité assistée, en présence d'une personne de référence ou d'un facilitateur technique. Cette modalité vise à garantir la fiabilité de l'information recueillie, à réduire le taux d'abandon du questionnaire et à assurer une interprétation cohérente des questions.

Les fonctions de cet accompagnement sont les suivantes :

- Clarifier les concepts : expliquer de manière homogène les termes techniques liés au Web sémantique et au Linked Open Data aux participants des différentes institutions.
- Guider la navigation : orienter les utilisateurs à travers la structure du questionnaire, contribuant ainsi à éviter l'abandon du processus de réponse.
- Valider le contexte : s'assurer que les réponses reflètent avec précision la réalité technologique et l'état actuel des données de l'institution évaluée.

4.5- Périmètre de réponse

Le questionnaire doit être rempli en considérant l'ensemble des données et des attributs que l'institution identifiée comme candidats potentiels à la publication sur une plateforme de données interconnectées. Cependant, l'inclusion d'un attribut dans la réponse n'implique pas nécessairement qu'il soit immédiatement publiable.

En cas de doute quant à la possibilité de diffusion de certains éléments, il est recommandé de les inclure également dans le questionnaire. Cela permet d'évaluer de manière comparative leur degré de publiabilité, d'identifier d'éventuelles restrictions et de déterminer les conditions nécessaires à leur publication éventuelle, en tenant compte des résultats obtenus dans les différentes sections de l'instrument.

4.6- Contenu et typologie des questions

Six blocs de questions ont été définis, chacun répondant aux objectifs secondaires de la recherche. Nous analyserons ci-après chacun de ces blocs en détaillant leurs objectifs et leur composition, tout en argumentant sur la méthodologie appliquée et la typologie de questions retenue pour répondre à ces objectifs.

Structure et aspects généraux

Cette première section du questionnaire a pour objectif de recueillir des informations générales sur le jeu de données, applicables à l'ensemble du dataset. Elle vise à offrir une vision globale de la structure, de la composition et des caractéristiques générales du corpus de données analysé.

Les aspects que cette section permet de recueillir sont les suivants :

- Institution et personne responsable du jeu de données
- Description thématique de la (des) collection(s)
- Système de gestion des données
- Modèles, ontologies, standards ou normes de description compatibles avec la structuration du dataset
- Volume estimé de données
- Structure du jeu de données (champs, relations entre entités, présence de champs multivalués, etc.)
- Typologies de données (booléens, identifiants, texte libre, etc.)

Cette section est composée des questions suivantes : 1- Informations sur la personne répondante, 2- Thématiques des collections, 3- Modèles et systèmes de gestion, 4- Entités, 6- Attributs / champs.

Questions 1

Les questions 1.1 à 1.3, relatives à l'identification de l'institution, de la personne de contact et de son adresse électronique, sont formulées comme des questions ouvertes à réponse courte.

Questions 2

La question 2.1, portant sur les domaines thématiques des collections, adopte le format d'une sélection multiple non exclusive au sein d'une liste fermée. Ce choix reconnaît qu'un même jeu de données peut réunir des collections relevant de plusieurs domaines disciplinaires simultanément ; une question à réponse unique aurait imposé une simplification induite. La question 2.2, en revanche, est formulée comme une question ouverte et facultative : sa fonction n'est pas classificatoire mais exploratoire, permettant de nuancer qualitativement la réponse précédente sans compromettre la comparabilité du jeu de données.

Questions 3

Les questions 3.1 et 3.2 reproduisent la même logique de sélection multiple afin d'identifier, respectivement, les systèmes de gestion utilisés et les modèles, ontologies ou normes de description que la personne répondante reconnaît comme employés ou compatibles avec le jeu de données. La décision de regrouper au sein d'une seule question (3.2) des catégories conceptuellement distinctes — telles que les modèles de données, les ontologies et les normes

descriptives — répond à l’objectif de réduire la complexité du questionnaire et d’en faciliter la compréhension par les participants.

De même, le format de sélection multiple reconnaît qu’un même jeu de données peut intégrer simultanément différents modèles, ontologies, standards ou normes de description. Cette diversité rend nécessaire d’identifier non seulement leur présence dans le dataset, mais également l’étendue de leur application. À cette fin, les réponses obtenues sont réutilisées dynamiquement dans la section de description des entités, permettant de préciser, pour chaque groupe d’entités, lesquels de ces modèles ou normes leur sont effectivement applicables. Le questionnaire peut ainsi représenter des situations dans lesquelles différentes entités d’un même dataset répondent à des structures conceptuelles différentes.

Questions 4

La question 4.1, qui recense les entités du jeu de données, adopte le format d’un tableau dynamique à lignes répétables. Ce choix découle du fait que le nombre d’entités varie sensiblement d’un jeu de données à l’autre, et que chacune présente des exigences propres. Les aspects à décrire pour chaque entité sont le nom, le volume, les modèles, ontologies ou normes reconnus comme compatibles, ainsi que le système de gestion.

Questions 5

La question 5.1, consacrée aux attributs/champs associés à chaque entité, constitue l’une des questions centrales du questionnaire, car elle aborde le niveau de granularité le plus fin du jeu de données et sert de base à la caractérisation ultérieure de sa structure et de son état de curation. Comme la question 4.1 relative aux entités, elle adopte un format de tableau dynamique, dû au fait que le nombre et la nature des attributs varient considérablement d’un jeu de données à l’autre. Les données recueillies pour chaque champ comprennent sa dénomination, sa typologie, le volume estimé de valeurs enregistrées, son appartenance éventuelle à un groupe de champs multivalués, ainsi que son caractère obligatoire ou facultatif au sein de la description d’une entité. La classification du composant « Type de donnée » revêt une importance particulière. Il s’agit d’une classification fermée et délibérément exhaustive¹²⁹, car elle permet d’identifier les caractéristiques structurelles de chaque attribut et de déterminer l’activation de sections

¹²⁹ Les catégories considérées sont les suivantes : Booléen, Date, Identifiant interne, Identifiant ou lien externe, Lien vers une ressource numérique, Lien vers une autre entité/table, Texte libre, Vocabulaire contrôlé.

spécifiques du questionnaire à des étapes ultérieures, en particulier celles liées à l'état de curation des données (question 9).

État curatorial

Cette section permet d'analyser le niveau de maturité curatoriale des données, c'est-à-dire dans quelle mesure elles ont été traitées, normalisées et préparées en vue de leur réutilisation et de leur interopérabilité. Cette section est centrale pour évaluer la faisabilité et identifier le travail préparatoire nécessaire sur les données.

Les aspects que cette section permet d'analyser sont :

- Volume de doublons possibles des entités
- La manière dont les incertitudes sont exprimées et gérées dans l'information
- Ambiguïtés dans l'interprétation des valeurs des champs
- État de normalisation des expressions
- Existence et usage de vocabulaires contrôlés
- Application d'identifiants uniques et persistants
- Liaisons avec des entités internes et externes

Cette section regroupe les questions : 6- Recensement des doublons, 7- Expression des incertitudes, 8- Ambiguïtés, 9- État de normalisation des données.

Questions 6

La question 6.1 permet d'indiquer, pour chacune des entités décrites à la question 4.1, le nombre d'enregistrements dupliqués associés à cette entité. Lorsque la valeur exacte n'est pas connue, une estimation approximative fondée sur la connaissance du jeu de données par la personne répondante est acceptée. Afin de faciliter l'identification et la quantification des doublons, la question demande d'indiquer le nombre total d'enregistrements concernés, et non le nombre de paires, de triplets ou d'autres regroupements d'enregistrements dupliqués. Ce choix permet une mesure plus homogène, indépendamment du nombre d'éléments dupliqués, triplés, etc.

Questions 7

La question 7.1, consacrée à l'expression des incertitudes, a pour objectif d'identifier les différents mécanismes par lesquels celles-ci sont enregistrées dans le jeu de données. La question

permet de sélectionner les différentes formes d'expression présentes dans les attributs, telles que l'usage de points d'interrogation, de préfixes comme « ca. », d'intervalles approximatifs ou d'autres conventions employées par l'institution. Cette question vise à détecter les attributs dont l'incertitude n'a pas été modélisée de manière explicite, mais s'exprime directement dans la valeur du champ, plusieurs conventions pouvant coexister au sein d'un même attribut selon l'enregistrement. Elle prévoit également l'identification des attributs dont le contenu consiste exclusivement à exprimer un degré d'incertitude associé à un autre attribut (par exemple, un champ spécifique destiné à indiquer qu'une date est approximative ou incertaine). Les informations recueillies permettent d'identifier les différentes modalités d'expression de l'incertitude et de quantifier le nombre de valeurs correctement curées et le nombre de valeurs non curées.

Questions 8

Les trois sous-questions de la section 8 partagent cette même logique de réponse multiple par ligne, appliquée à trois niveaux de granularité distincts : 8.1 examine l'ambiguïté à l'intérieur d'une même cellule lorsque celle-ci admet plusieurs valeurs simultanées ; 8.2 examine l'hétérogénéité sémantique entre différents enregistrements d'un même attribut ; et 8.3, l'hétérogénéité des relations sémantiques entre les attributs composant un même groupe. Cette dernière n'est activée que lorsqu'il a été déclaré, à la question 5.1, au moins un « groupe d'attributs ». La progression entre les trois sous-questions n'est pas arbitraire : elle reproduit les trois niveaux — valeur, enregistrement, relation entre attributs — auxquels peut se manifester l'ambiguïté sémantique au sein d'un jeu de données, permettant un diagnostic curatorial stratifié et non simplement global.

Questions 9

La section 9, *État de normalisation des données*, constitue le cœur du questionnaire pour l'évaluation de l'état de curation des données. Elle vise à analyser, pour chacune des typologies d'attributs identifiées à la question 5.1, le degré de normalisation, de structuration et de standardisation atteint. La structure conditionnelle de cette section permet d'adapter le questionnaire à la composition spécifique de chaque jeu de données, offrant un diagnostic exhaustif sans intégrer de questions non pertinentes pour des attributs inexistants.

Le type de réponse demandé dans chaque sous-question varie selon la nature de l'attribut et la dimension de curation évaluée. Les questions 9.1, 9.3 et 9.4 utilisent des listes fermées de formats, de standards ou de conventions largement consolidées dans le domaine patrimonial, facilitant ainsi la comparabilité des réponses. La question 9.2 recourt également à une liste fermée pour caractériser la structure des identifiants, en intégrant en outre des informations sur leur unicité au sein du jeu de données et, le cas échéant, sur la composition de clés composées.

La question 9.5 n'évalue pas un format de normalisation, mais l'entité de destination des relations établies par les attributs relationnels, permettant de caractériser la structure sémantique du jeu de données. La question 9.6, consacrée aux attributs de texte libre, demande uniquement une estimation quantitative du degré de variabilité des valeurs, la nature non structurée de ce type d'information rendant inapplicable une classification fermée. Enfin, la question 9.7 combine une liste fermée d'options avec la possibilité de joindre une documentation complémentaire, reconnaissant que les thésaurus, listes d'autorité ou vocabulaires contrôlés ne peuvent être adéquatement décrits qu'au moyen de la ressource documentaire elle-même. De même, lorsqu'il s'agit de ressources internes, la question exige de caractériser leur structure, permettant d'indiquer, par exemple, s'il s'agit d'une liste plate ou si elle intègre des relations hiérarchiques entre les termes.

De manière transversale, toutes les sous-questions de la section 9 demandent d'indiquer le volume de valeurs normalisées ou curées pour chaque attribut. Cette information permet de comparer ces valeurs avec le volume total enregistré pour l'attribut à la question 5.1, et de calculer ultérieurement des indicateurs quantitatifs sur le degré de curation du jeu de données (voir: 4.7).

Pratiques de mise à jour et stabilité des identifiants

Cette section a pour objectif de comprendre l'évolution des données dans le temps, en mettant particulièrement l'accent sur leur degré de stabilité, afin de planifier les processus de mise à jour et de synchronisation d'une plateforme de données interconnectées.

Cette section vise à identifier l'existence et l'usage d'identifiants persistants (permalien), à caractériser leur structure et à recueillir des informations sur la périodicité de mise à jour du jeu

de données. Ces éléments constituent une information essentielle pour définir une stratégie de mise à jour et de synchronisation de la plateforme.

Cette section regroupe la question 10 (*Pratiques de mise à jour et stabilité des identifiants*), ainsi que les sous-questions 9.2 (*Attributs de type « Identifiant interne »*) et 9.3 (*Attributs de type « Identifiant ou lien externe »*).

Questions 10

La question 10.1 est formulée comme une question fermée à choix unique, car, à l'échelle du jeu de données, une seule modalité de mise à jour prédomine généralement. La sous-question 10.1b, de nature facultative et activée uniquement selon la réponse précédente, permet de recueillir une information complémentaire lorsque cela est pertinent.

La question 10.2 s'adresse exclusivement aux attributs préalablement typés comme identifiants internes ou identifiants ou liens externes, car la notion de stabilité temporelle n'étant significative que pour ce type d'attributs. Il en va de même pour la question 10.3, qui s'adresse exclusivement aux attributs de type Lien vers une ressource numérique. Tandis que la question 9.4 caractérise le type ou le format de ces liens, la question 10.3 analyse leur stabilité opérationnelle dans le temps. En effet, une ressource peut voir sa disponibilité ou son accessibilité changer sans que le format du lien utilisé pour la référencer ne soit modifié.

Gouvernance des données

Cette section a pour objectif d'identifier les politiques d'accès et de réutilisation régissant le jeu de données, ainsi que l'existence de conditions ou de restrictions spécifiques applicables à certains attributs.

L'information recueillie permet de caractériser le régime de gouvernance du dataset au regard de ses conditions d'accès, de diffusion et de réutilisation, des aspects fondamentaux pour évaluer son intégration dans une plateforme fondée sur le Linked Open Data (LOD).

Cette section regroupe la question 11 : *Droits et licences*.

Questions 11

La question 11.1 adopte, comme la question 10.1, un format à choix unique, car, en règle générale, un même régime de licence s'applique de manière uniforme à l'ensemble du dataset.

La sous-question 11.1b permet d'identifier les attributs soumis à des conditions particulières de réutilisation qui diffèrent du régime général de licence, tels que des droits de propriété intellectuelle de tiers, des clauses contractuelles spécifiques ou d'autres restrictions d'usage.

La question intègre également une référence spécifique aux éventuelles restrictions relatives à la réutilisation des données par des systèmes d'intelligence artificielle. Bien qu'il n'existe actuellement ni cadre normatif consolidé ni typologie standardisée pour ce type de clauses, il a été jugé pertinent de les inclure de manière générale, en raison de leur importance croissante dans les politiques d'accès et de réutilisation des données patrimoniales. Cette formulation permettra, dans de futures versions du questionnaire, de remplacer cette catégorie générique par une classification plus précise, à mesure qu'émergeront des standards ou des recommandations largement adoptés par la communauté.

Données sensibles et stratégies déontologiques

Cette section a pour objectif d'identifier la présence de contenus sensibles ou potentiellement problématiques, tant du point de vue éthique que déontologique. Elle vise également à recueillir les recommandations de la personne experte répondant au questionnaire quant aux stratégies les plus appropriées pour le traitement, la publication et l'éventuelle diffusion de ces contenus.

Cette section regroupe la question 12 : *Données sensibles et stratégies déontologiques*.

Questions 12

Les questions 12.1 et 12.2 partagent une même structure méthodologique, fondée sur une question initiale à choix unique qui détermine l'activation de questions complémentaires uniquement lorsque la présence de contenus sensibles est identifiée.

La question 12.1 a été élaborée à partir des catégories de données personnelles définies par le *Règlement général sur la protection des données* (RGPD) de l'Union européenne¹³⁰. Afin de favoriser une interprétation homogène de ces concepts par les institutions participantes, le questionnaire intègre un lien vers le guide explicatif publié par la Commission nationale de

¹³⁰ HIGGINS, Sarah. *The DCC Curation Lifecycle Model*. Edinburgh: Digital Curation Centre, 2008.

l'informatique et des libertés (CNIL)¹³¹, considéré comme l'une des références les plus complètes et accessibles pour l'application pratique du règlement.

Lorsque la réponse aux questions 12.1 ou 12.2 est affirmative, le questionnaire affiche un tableau conditionnel destiné à caractériser le type de contenu sensible identifié et à consigner la stratégie de traitement recommandée. Les catégories proposées pour ces stratégies s'appuient sur les recommandations publiées dans le *Rassismuskritische Dokumentation. Ein Handbuch für GLAM-Institutionen* pour aborder les problématiques de racisme et de contenus sensibles dans la documentation patrimoniale¹³². L'intégration de cet espace permet de recueillir l'avis des personnes expertes de chaque institution et de documenter les solutions actuellement considérées comme les plus appropriées pour la publication de ces contenus, sans imposer une stratégie d'action unique.

Évaluation de la publiabilité

Cette dernière section a pour objectif de recueillir une évaluation préliminaire de la possibilité de publication des différents attributs du jeu de données, ainsi que de la priorité estimée pour leur éventuelle diffusion sur une plateforme de données interconnectées.

Bien qu'il soit recommandé de remplir le questionnaire en ne considérant que le répondant identifie comme candidates potentielles à la publication, il est possible que certains éléments du jeu de données présentent des conditions de curation, de structuration, de gouvernance ou des restrictions spécifiques empêchant leur publication immédiate ou nécessitant des actions préalables de mise en conformité.

En ce sens, cette section ne vise pas à établir un engagement formel de publication, mais à recueillir une évaluation experte initiale fondée sur la connaissance de l'état actuel des données, de leurs conditions de gestion et des limitations éventuelles identifiées tout au long du questionnaire.

¹³¹ UNION EUROPÉENNE, « Règlement (UE) 2016/679 du Parlement européen et du Conseil du 27 avril 2016 relatif à la protection des personnes physiques à l'égard du traitement des données à caractère personnel et à la libre circulation de ces données (Règlement général sur la protection des données) », in : *Journal officiel de l'Union européenne*, 2016, disponible à l'adresse URL : [_https://www.cnil.fr/fr/reglement-europeen-protection-donnees?utm_source=chatgpt.com](https://www.cnil.fr/fr/reglement-europeen-protection-donnees?utm_source=chatgpt.com), consulté en ligne le 23 février 2026, consulté en ligne le 23 février 2026.

¹³² COMMISSION NATIONALE DE L'INFORMATIQUE ET DES LIBERTÉS (CNIL), « RGPD : de quoi parle-t-on ? », disponible à l'adresse : <https://www.cnil.fr/fr/rgpd-de-quoi-parle-t-on>, consulté le 23 février 2026.

Cette section regroupe la question 13 : *Évaluation de la publiabilité*.

Questions 13

La question 13.1 se distingue des précédentes par son caractère principalement évaluatif, dans la mesure où elle ne vise pas à décrire une caractéristique objective du jeu de données, mais à recueillir l'appréciation experte de la personne répondante quant à son potentiel de publication. Cette différence méthodologique justifie le recours à une échelle ordinale pour évaluer le niveau de priorité de diffusion de chaque attribut.

De même, la distinction introduite entre les motifs de publication différée de nature juridique et les motifs de nature curatoriale permet d'interpréter les résultats de manière différenciée. Cette séparation permet de distinguer, d'une part, les obstacles liés aux droits, aux licences ou aux données sensibles — relevant des sections 11 et 12 — et, d'autre part, ceux découlant de l'état de structuration, de normalisation ou de curation des données — relevant des sections 7, 8 et 9.

4.7- Restitution des résultats

Ce questionnaire n'a pas été conçu dans le but d'établir une échelle de qualité des données, ni de générer un classement ou une évaluation normative, comme c'est le cas par exemple du Maturity Model d'Europeana (voir: 1.5). Il vise au contraire à recueillir une information permettant de comprendre la complexité des données patrimoniales à différents niveaux. C'est pourquoi les résultats sont livrés bruts, sous la forme d'une série de gabarits CSV, conçus pour être immédiatement utilisables comme instruments de travail pour la prise de décisions de curation et pour la modélisation.

CSVs

Les résultats de l'enquête seront fournis sous la forme de quatre fichiers CSV : l'un contenant les informations générales de contact et sur la collection, un deuxième regroupant les données relatives aux entités identifiées, un troisième présentant les informations concernant les attributs identifiés, et un quatrième rassemblant les réponses concernant les relations entre les groupes d'attributs.

CSV informations générales

- Il s'agit d'un tableau simple comportant une seule ligne, dont les colonnes sont :

```
[  
"1.1.- Institution",  
"1.2.- Email",  
"1.3.- Personne",  
"2.1.- Domaine",  
"2.2.- Description_Domain",  
]
```

CSV Entités

Chaque ligne correspond à une entité du jeu de données.

Les colonnes du fichier contiennent les informations suivantes :

```
[  
"4.1.- Entité",  
"4.1.- Volume",  
"4.1.- Modèle",  
"4.1.- Système_gestion",  
"6.1.- Volume_doublons",  
"6.1.- Commentaires_doublons"  
]
```

CSV Attributs

Chaque ligne correspond à un attribut du jeu de données.

Chaque colonne contient la réponse à une des questions du formulaire concernant cet attribut. Dans les cas où les questions permettent de répondre plusieurs fois pour un même attribut, chacune des réponses est dupliquée dans le CSV sous forme de colonnes distinctes. Les attributs ayant moins de réponses laissent simplement les colonnes excédentaires vides.

Les neuf premières colonnes, fixes, identifient l'attribut lui-même :

```
[  
"4.1.- Entité_Modèle",  
"5.1.- Attribut_Nom",  
"5.1.- Attribut_Nom_interne",  
"5.1.- Attribut_ObliOpti",  
"5.1.- Attribut_Type",  
"5.1.- Attribut_Groupe",  
"5.1.- Attribut_Langue",  

```

"5.1.- Attribut_Volume",
"5.1.- Attribut_Description"
]

Viennent ensuite, dans l'ordre, les blocs de colonnes correspondant à chacune des sections curatorielles du questionnaire :

[
"7.1.- Incertitude_TypeExpression",
"7.1.- Incertitude_Expression",
"7.1.- Incertitude_Volume",
"7.1.- Incertitude_Exemple",
"8.1.- Ambiguïté_cardinalité_RelationType",
"8.1.- Ambiguïté_cardinalité_Volume",
"8.2.- Ambiguïté_valeurs_RelationType",
"8.2.- Ambiguïté_valeurs_Volume",
"9.1.- Normalisation_Dates_Formats",
"9.1.- Normalisation_Dates_Volume",
"9.2.- Normalisation_Identifiant_Structure",
"9.2.- Normalisation_Identifiant_Unicité",
"9.2.- Normalisation_Identifiant_Clé",
"9.2.- Normalisation_Identifiant_Volume",
"9.3.- Normalisation_LienExterne_Type",
"9.3.- Normalisation_LienExterne_Volume",
"9.4.- Normalisation_LienRessource_TypeLien",
"9.4.- Normalisation_LienRessource_Ressource",
"9.4.- Normalisation_LienRessource_Volume",
"9.5.- Normalisation_LienEntite_Entités",
"9.5.- Normalisation_LienEntite_Volume",
"9.6.- Normalisation_TextLibre_NFacettes",
"9.7.- Normalisation_Vocabulaire_Type",
"9.7.- Normalisation_Vocabulaire_Volume",
"9.7.- Normalisation_Vocabulaire_NValeurs",
"9.7.- Normalisation_Vocabulaire_DocumentInterne",
"10.1.- Cycle_Périodicité_globale",
"10.1b.- Cycle_Périodicité_Périodicité",
"10.1b.- Cycle_Commentaires",
"10.2.- Cycle_Lien_Durabilité",
"10.2.- Cycle_Lien_Commentaires",
"10.3.- Accessibilité_Ressource",
"10.3.- Accessibilité_Commentaires",
"11.1.- Licence_globale",
"11.1b.- Restriction_Type",
"11.1b.- Restriction_Commentaires",
"12.1.- DonnéesPerso_Type",
"12.1.- DonnéesPerso_Solution",
]

```
"12.1.- DonnéesPerso_Commentaires",  
"12.2.- Cultsensibles_Type",  
"12.2.- Cultsensibles_Solution",  
"12.2.- Cultsensibles_Commentaires",  
"13.1.- Publiabilité_Publicable",  
"13.1.- Publiabilité_Priorité",  
"13.1.- Publiabilité_Commentaires"  
]
```

CSV Groupes d'attributs

Ce CSV reproduit le tableau de la question 8.3. Chaque ligne représente une relation déclarée entre deux attributs d'un même groupe.

Les colonnes sont :

```
[  
"8.3.- Ambiguïté_Groupe_Entité",  
"8.3.- Ambiguïté_Groupe_Groupe",  
"8.3.- Ambiguïté_Groupe_Attribut1",  
"8.3.- Ambiguïté_Groupe_Attribut2",  
"8.3.- Ambiguïté_Groupe_Type de relation",  
"8.3.- Ambiguïté_Groupe_Volume"  
]
```

Visualisation

Afin d'obtenir un aperçu rapide des principales difficultés liées au corpus de données, l'application du questionnaire a également été conçue pour offrir une visualisation interactive des données.

La visualisation interactive représente chaque entité du jeu de données sous la forme d'un nœud foncé, et chacun de ses attributs sous la forme d'un nœud satellite qui lui est relié ; les relations déclarées entre entités (question 9.5) sont représentées par des flèches. La taille de chaque nœud est proportionnelle au volume de données déclaré pour l'entité ou l'attribut correspondant (selon une échelle en racine carrée, de sorte que ce soit l'aire du cercle — et non son rayon — qui soit proportionnelle au volume), ce qui permet de distinguer d'un coup d'œil les entités et attributs les plus volumineux de ceux qui sont marginaux au sein du jeu de données.

La couleur de chaque attribut code son état de publiabilité, tel que déclaré à la question 13.1 : vert pour les attributs immédiatement publiables, orange et jaune pour ceux publiables

ultérieurement pour des raisons respectivement légales ou curatoriales, rouge pour les non publiables, et gris pour les attributs dont la publiabilité n'a pas été renseignée. En passant le curseur sur un attribut, une infobulle affiche ses détails, y compris, le cas échéant, le détail du pourcentage d'expressions non curées au sein de l'attribut.

Calcul des attributs non curés

Pour chaque attribut, un pourcentage de données non curées (% NC) est directement visible dans la visualisation interactive du jeu de données.

Le calcul du % NC repose sur une logique de calcul : dans les sections 7 à 9 du questionnaire (incertitudes, ambiguïtés et état de normalisation), pour chaque attribut du type de donnée correspondant (date, identifiant, vocabulaire contrôlé, etc.), il est demandé à la personne répondante d'indiquer combien d'enregistrements (volume) se trouvent dans une situation précise et vérifiable — par exemple, combien d'enregistrements d'un attribut de type « Date » suivent tel ou tel format normalisé, ou combien de valeurs portent une incertitude exprimée en texte libre. À partir de cette réponse, l'application calcule, pour chacune de dix dimensions curatoriales indépendantes, un volume de données « non curées » propre à cette dimension. Selon le cas, ce volume est obtenu de deux manières : directement (lorsque la question documente explicitement les enregistrements problématiques, ceux-ci sont comptés tels quels), ou par différence (lorsque la question documente les enregistrements correctement normalisés, ce volume est soustrait du volume total de l'attribut — déclaré à la question 5.1 —, et ce qui reste inexpliqué est considéré comme non curé). Chacun de ces volumes est ensuite exprimé comme un pourcentage du volume total de l'attribut.

Le tableau suivant détaille, pour chacune des dix dimensions, le problème de curation qu'elle cherche à détecter, la question du questionnaire sur laquelle elle repose, et la manière dont la réponse de l'utilisateur se traduit en un pourcentage de données non curées, avec un exemple numérique illustratif (attribut hypothétique de 500 enregistrements).

Dimension	Question	Quel problème de curation détecte-t-elle ?	Comment se calcule-t-il ? (exemple avec 500 enregistrements)
------------------	-----------------	---	---

Incertitude	7.1	L'attribut contient des valeurs marquées comme incertaines au moyen de texte libre (p. ex. « peut être Courbet ») plutôt que d'un marqueur structuré et reconnaissable automatiquement.	Le volume d'enregistrements dont l'expression d'incertitude a été déclarée comme « Texte libre » est additionné directement ; ce volume est compté comme non curé. Exemple : 40 des 500 enregistrements avec incertitude en texte libre → $40/500 = 8\%$ NC.
Ambiguïté cardinalité	8.1	L'attribut admet plusieurs valeurs dans un même enregistrement (p. ex. « Peinture à l'huile, Collage ») et la relation sémantique entre ces valeurs n'est pas claire.	Le volume d'enregistrements pour lesquels une relation valide a bien été déclarée et clarifiée est soustrait du volume total de l'attribut. Exemple : 350 des 500 enregistrements avec relation clarifiée → $500 - 350 = 150$ non curés = 30% NC.
Ambiguïté valeurs	8.2	Au sein d'un même attribut coexistent des enregistrements dont les valeurs ne partagent pas la même signification sémantique (hétérogénéité de contenu, au-delà de simples variantes de rédaction).	Le volume déclaré à la question 8.2 est compté directement comme non curé, cette question documentant explicitement les cas problématiques. Exemple : 25 enregistrements identifiés comme hétérogènes sur 500 = 5% NC.
Ambiguïté groupe	8.3	L'attribut appartient à un « groupe » d'attributs qui devraient être liés de manière cohérente (logique, hiérarchique, etc.), mais cette relation n'est pas vérifiée pour tous les enregistrements.	Pour chacun des deux attributs de la paire déclarée à la question 8.3, le volume pour lequel la relation a été clarifiée est soustrait du volume total ; le résultat le plus élevé entre les deux est retenu. Exemple : 300 des 500 enregistrements clarifiés → $500 - 300 = 200$

			non curés = 40 % NC.
Dates	9.1	Les valeurs de date de l'attribut ne suivent pas un format unique et normalisé (mélange de « 1850 », « XIXe siècle », « ca. 1850-1860 », etc.), ce qui empêche de les trier ou de les filtrer chronologiquement de manière fiable.	La somme des volumes d'enregistrements correspondant aux formats de date reconnus et déclarés à la question 9.1 est soustraite du volume total de l'attribut. Par exemple, si 200 des 500 enregistrements suivent un format déclaré et 220 un autre format reconnu, le volume non normalisé est calculé comme suit : $500 - (200 + 220) = 80$ enregistrements non normalisés, soit 16 % NC.
Identifiant interne	9.2	L'identifiant interne de l'attribut n'est pas unique au sein du jeu de données, avec le risque de confondre des enregistrements distincts entre eux.	Si la réponse à « Unicité » est « Non », le volume déclaré sur cette ligne est intégralement compté comme non curé. Exemple : 500 enregistrements marqués comme non uniques $\rightarrow 500/500 = 100$ % NC ; si l'unicité est « Oui », cette dimension n'apporte aucun NC.
Identifiant externe	9.3	Plusieurs types distincts d'identifiants ou de liens externes coexistent pour représenter le même attribut (p. ex. certains enregistrements utilisent un DOI,	Si l'attribut compte deux lignes ou plus à la question 9.3 (plus d'un type d'identifiant coexistant), les volumes de toutes ces lignes sont additionnés comme non curés ; une seule

		d'autres un ARK), sans système unifié.	ligne (un seul type) est considérée comme curée. Exemple : 300 enregistrements dans VIAF + 200 dans Wikidata (2 lignes) → $500/500 = 100\%$ NC ; une seule ligne de 500 dans VIAF → 0% NC.
Ressource numérique	9.4	Comme à la question 9.3, mais pour les liens vers des ressources numériques (images, documents) : coexistence de plusieurs types de lien ou de format pour un même attribut.	Même règle qu'à la question 9.3 : deux lignes ou plus → NC = somme des volumes de ces lignes ; une seule ligne → curé.
Lien entité	9.5	L'attribut relie chaque enregistrement à une autre entité du jeu de données (p. ex. un objet lié à son « Créateur » dans l'entité Personnes), et ce lien n'est pas résolu ou documenté pour tous les enregistrements.	La somme des volumes de liens normalisés déclarés à la question 9.5 vers les différentes entités de destination est soustraite du volume total de l'attribut. Exemple : 480 des 500 enregistrements avec un lien résolu vers « Personnes » → $500 - 480 = 20$ non résolus = 4% NC.
Vocabulaire contrôlé	9.7	Les valeurs de l'attribut ne proviennent pas d'un vocabulaire contrôlé normalisé (interne ou externe, p. ex. AAT, RAMEAU), mais de texte libre non normalisé.	La somme des volumes normalisés déclarés à la question 9.7 pour chaque vocabulaire utilisé est soustraite du volume total. Exemple : 300 des 500 enregistrements normalisés selon un thésaurus interne → $500 - 300 = 200$ non normalisés = 40% NC.

La question 9.6 (attributs de type « Texte libre ») ne contribue pas au calcul du % NC : contrairement aux autres, elle ne documente ni un état de normalisation ni une relation sémantique, mais uniquement une estimation du nombre de valeurs distinctes possibles (facettes) que peut prendre l'attribut.

Étant donné qu'un même attribut peut présenter simultanément plusieurs de ces conditions — et qu'il n'est pas possible de déterminer, à partir des réponses au questionnaire, si les enregistrements concernés par chacune d'elles coïncident entre eux —, additionner les pourcentages de chaque dimension surestimerait systématiquement le volume réel de données non curées. C'est pourquoi le % NC finalement affiché correspond à la dimension la plus problématique parmi toutes celles déclarées pour cet attribut, et non à la somme de l'ensemble d'entre elles. Ce critère garantit que le chiffre présenté constitue toujours une estimation prudente par défaut : au minimum ce pourcentage des données n'est pas curé, cette proportion pouvant être plus élevée.

4.8- Ouverture et accès en ligne du formulaire

Le questionnaire a été implémenté comme une application web statique, accessible directement depuis un navigateur, sans installation ni compte préalable requis pour y répondre. Son interface a été développée au moyen de SurveyJS, une bibliothèque libre sous licence MIT, plutôt qu'au moyen d'une plateforme d'enquête propriétaire fermée.

Cette décision d'implémentation cherche à répondre, au moins partiellement, aux mêmes principes d'ouverture examinés au chapitre 1 à propos des données patrimoniales elles-mêmes, appliqués ici à l'instrument de diagnostic lui-même. Conformément au quatrième principe opérationnel d'OpenGLAM — le recours à des formats ouverts et lisibles par machine — et dans la continuité du principe de participatory design du mouvement Collections as Data, qui invite à réduire au minimum les barrières d'accès et d'utilisation des instruments mis à disposition des communautés concernées (chapitre 1.1), le code source du questionnaire est publié dans un dépôt ouvert sur GitHub sous double licence : le code sous licence MIT, et le contenu du questionnaire — textes et méthodologie — sous licence Creative Commons Attribution 4.0 International (CC

BY 4.0). L'instrument est déployé gratuitement au moyen du service GitHub Pages, à l'adresse suivante : <https://cristobalbarria.github.io/glam-data-diagnostic/>.

Cette cohérence avec les principes d'ouverture demeure toutefois partielle. La centralisation des réponses recueillies repose actuellement sur Google Sheets, via Google Apps Script — un service propriétaire choisi pour des raisons pragmatiques, notamment l'absence de coût et la possibilité de centraliser les réponses de plusieurs institutions sans devoir développer ni maintenir une infrastructure serveur dédiée.

La page d'accueil du questionnaire présente le formulaire à l'utilisateur en s'adressant spécifiquement à un collaborateur ou une collaboratrice d'une institution de la Ville de Genève, plutôt que de proposer une formulation générique et universelle valable pour n'importe quelle institution GLAM. Ce choix a été privilégié afin d'illustrer concrètement, par un cas d'usage réel, la manière dont l'instrument peut être adapté au contexte spécifique d'un projet donné — une version générique de cette page d'accueil demeure toutefois conservée dans le dépôt du projet, afin de faciliter sa réutilisation pour d'autres institutions ou contextes.

5- Validation et application pilote

Comme indiqué dans la section 3 *Méthodologie*, le processus d'élaboration du questionnaire a comporté deux étapes complémentaires d'évaluation : une validation qualitative réalisée par une professionnelle spécialisée¹³³ dans la gestion des données muséales et une application pilote (prétest) de l'instrument à partir de l'instance MuseumPlus de la Ville de Genève. Ces deux étapes ont permis d'identifier des problèmes de formulation, de détecter d'éventuelles ambiguïtés et d'évaluer l'applicabilité de l'instrument dans un contexte réel.

Le matériel soumis à examen correspondait à la première version complète du questionnaire, achevée en septembre 2025 et présentée en format texte (Annexe 1). Afin de se rapprocher de l'expérience finale de réponse, l'une des questions a en outre été mise en œuvre en format web, ce qui a permis d'évaluer préliminairement la présentation de l'instrument et sa structure de navigation.

Les observations recueillies au cours de ces deux étapes ont donné lieu à une série de modifications destinées à optimiser la conception du questionnaire. Les sections suivantes présentent les principales observations formulées, les modifications introduites et leur justification méthodologique.

5.1- Validation qualitative par une experte du domaine

Intégration d'un glossaire contextuel

L'experte a relevé que plusieurs questions comportaient une terminologie spécialisée dont la compréhension ne pouvait pas être tenue pour acquise chez l'ensemble des personnes appelées à répondre au questionnaire. En outre, certains concepts pouvaient être interprétés différemment selon le profil professionnel de la personne participante, ce qui risquait d'affecter l'homogénéité des réponses.

En réponse à cette observation, un glossaire contextuel a été intégré, accessible au moyen de fenêtres surgissantes (*pop-up*) associées aux termes nécessitant une définition supplémentaire, tels qu'entité ou attribut. Cette solution a été préférée à un glossaire unique placé en début de

¹³³ Gabriella Lini, responsable du centre de documentation et recherche, MAH. gabriella.lini@geneve.ch

questionnaire, car elle permet d'accéder à l'information uniquement lorsque cela est nécessaire, réduisant ainsi la complexité et améliorant l'expérience d'utilisation de l'instrument.

Simplification de l'introduction et de la définition du concept de jeu de données

L'experte a observé que la définition de l'unité d'analyse présentait un niveau de complexité élevé. Bien que cette précision fût nécessaire pour délimiter correctement le concept de jeu de données (*dataset*) d'un point de vue méthodologique, il n'était pas indispensable que les personnes participantes comprennent l'ensemble des éléments théoriques sous-tendant cette définition.

En conséquence, l'introduction a été reformulée dans un langage plus simple et davantage orienté vers l'application pratique.

Modalité d'application du questionnaire

L'experte a recommandé que l'application future du questionnaire soit réalisée, dans la mesure du possible, avec l'accompagnement d'une personne familiarisée à la fois avec l'enquête et avec la gestion des données muséales. Cet accompagnement permettrait de résoudre les doutes d'interprétation, d'homogénéiser les critères de réponse et de diminuer le risque d'abandon en cours de remplissage du questionnaire.

À la suite de cette recommandation, la nature de l'instrument et sa modalité d'application ont également été reconsidérées. Dans la mesure où sa diffusion n'est pas envisagée comme une enquête autoadministrée, mais plutôt comme un remplissage conjoint entre la personne responsable des données et un facilitateur connaissant l'instrument, il a été décidé de remplacer la dénomination « enquête » par « formulaire » tout au long du projet.

Clarification du concept de modèle de données

L'examen a permis d'identifier une ambiguïté dans l'usage du concept de modèle de données. Dans la version initiale du questionnaire, ce concept remplissait simultanément deux fonctions : faire partie de la définition d'un jeu de données et constituer un aspect évalué au sein même du questionnaire.

Pour éviter ce chevauchement conceptuel, l'exigence selon laquelle tous les enregistrements devaient être structurés selon un modèle de données unique a été retirée de la définition du jeu de

données. La définition met désormais l'accent uniquement sur l'existence de relations entre les données constituant l'ensemble. L'évaluation de l'usage des modèles de données a été maintenue comme un aspect spécifique du questionnaire, quoique avec une reformulation de la question correspondante.

Reformulation des questions relatives aux modèles de données

L'experte a observé que l'identification de modèles de données tels que CIDOC CRM, LIDO ou Dublin Core requiert des connaissances techniques que ne possèdent pas nécessairement toutes les personnes chargées de répondre à l'enquête. En conséquence, la formulation initiale pouvait conduire à des réponses incomplètes ou peu fiables.

C'est pourquoi la question a été reformulée de manière à ce que les personnes participantes indiquent les modèles ou standards qu'elles reconnaissent comme compatibles avec leurs données, plutôt que de leur demander l'identification précise du modèle d'implémentation utilisé par le système de gestion.

Intégration d'exemples de réponse

Afin de faciliter la compréhension du questionnaire et de réduire la variabilité dans l'interprétation des questions, l'experte a recommandé d'intégrer des exemples de réponse directement dans les tableaux et formulaires de l'instrument. Ces exemples permettent d'illustrer le type d'information attendu et le niveau de détail requis pour chaque question, favorisant une plus grande cohérence entre les réponses sans en conditionner le contenu.

Droits associés aux données

Enfin, l'examen a mis en évidence la nécessité d'intégrer de manière plus explicite les aspects liés aux droits associés aux données. En conséquence, de nouvelles questions ont été ajoutées afin d'identifier les conditions juridiques et administratives susceptibles d'influencer la publication, la diffusion et la réutilisation des jeux de données.

5.2- Application pilote du formulaire

La seconde étape d'évaluation a consisté en une application pilote du formulaire à partir de l'instance MuseumPlus utilisée par la Ville de Genève pour la gestion des collections de ses institutions muséales. Cette infrastructure technologique unique regroupe les métadonnées de huit institutions aux collections très variées : le Musée d'art et d'histoire (MAH), le Musée Ariana, la Bibliothèque d'art et d'archéologie, le Centre d'iconographie, le Fonds d'art contemporain, l'Institut et Musée Voltaire, le Jardin botanique et le Musée d'histoire des sciences et traverse des domaines très divers comme l'archéologie, beaux-arts, arts appliqués, histoire, sciences, livres et archives.

Bien que ces jeux de données partagent un même système de gestion, ils présentent des modèles documentaires distincts et des structures d'information hétérogènes. De plus, de nombreuses entités — telles que des personnes, des lieux, des organisations ou des événements — sont partagées entre les différentes institutions, ce qui génère des relations et des dépendances accroissant la complexité du système.

Dans ce contexte, l'objectif de l'application pilote n'était pas d'évaluer la qualité des données gérées dans MuseumPlus, mais de vérifier si le formulaire proposé était suffisamment flexible pour décrire des jeux de données présentant des caractéristiques documentaires, des modèles d'organisation et des degrés de curation différents. À cette fin, chacune des questions a été appliquée à des jeux de données appartenant à différentes institutions et typologies documentaires, incluant des collections d'art, d'archéologie, d'arts appliqués, d'archives et de fonds bibliographiques.

Cette application pilote a permis d'identifier des situations non prévues lors de la phase de conception et a donné lieu à diverses modifications destinées à améliorer la capacité du formulaire à s'adapter à des contextes muséaux hétérogènes.

Évaluation différenciée des modèles de données et des systèmes de gestion

L'application pilote a permis de constater qu'un même jeu de données peut être composé d'entités répondant à des modèles documentaires distincts, voire gérées au moyen de systèmes différents. La version initiale du formulaire supposait implicitement une correspondance unique entre jeu de

données, modèle de données et système de gestion, une hypothèse qui ne s'est pas toujours vérifiée dans les jeux de données analysés.

En conséquence, la possibilité d'identifier le modèle de données et le système de gestion pour chaque entité considérée a été intégrée, permettant de décrire des configurations hybrides et de refléter plus fidèlement l'organisation réelle des données.

Caractérisation de l'incertitude

La coexistence de jeux de données présentant différents niveaux de curation a permis d'identifier une grande variété de manières de représenter l'incertitude. Parmi celles-ci figurent des dates approximatives, des attributions incertaines, des identifications provisoires, des valeurs incomplètes et d'autres stratégies employées pour documenter une information dont le degré de certitude varie.

À partir de cette observation, la section consacrée à l'évaluation de l'incertitude a été révisée et reformulée afin de proposer une typologie plus structurée, permettant de mieux regrouper les différentes formes sous lesquelles celle-ci s'exprime au sein d'un jeu de données.

Évaluation de l'unicité des identifiants

L'application pilote a mis en évidence que les numéros d'inventaire ne constituent pas toujours des identifiants uniques au sein du système. Cette situation s'explique, entre autres facteurs, par la coexistence de différents systèmes historiques d'identification et par l'intégration de collections provenant de contextes administratifs distincts.

En conséquence, des questions spécifiques destinées à évaluer l'unicité des identifiants utilisés et les mécanismes mis en place pour garantir l'identification univoque des enregistrements ont été intégrées.

Ambiguïté sémantique dans l'usage des attributs

Le fait que plusieurs institutions partagent une même infrastructure technologique a permis d'identifier des différences dans l'interprétation et l'utilisation de certains attributs. Dans certains cas, un même champ était utilisé pour enregistrer des informations conceptuellement distinctes selon l'institution responsable ou la nature du jeu de données.

Cette observation a conduit à l'intégration de nouvelles questions destinées à évaluer l'existence d'ambiguïtés sémantiques dans l'usage des attributs, un aspect susceptible d'affecter tant l'interopérabilité que la réutilisation des données.

Simplification de la méthode d'évaluation des métriques de curation

L'application pilote a permis de reconsidérer la méthodologie utilisée pour évaluer le niveau de curation des jeux de données. La version initiale du formulaire demandait une identification manuelle des différentes typologies de données non curées, ce qui représentait une charge importante pour les personnes chargées de répondre.

En conséquence, la procédure de calcul a été simplifiée, en demandant uniquement les volumes de données correctement curées ou, le cas échéant, les données non curées. Les métriques sont ensuite calculées à partir du volume total associé à chaque attribut au moyen de processus automatiques d'extraction et d'analyse, ce qui réduit la complexité de la réponse et favorise la comparabilité entre les jeux de données évalués.

Conclusion

Bilan de l'utilité du questionnaire

Ce travail est parti d'un vide méthodologique précis : l'absence d'un instrument capable de recueillir, de manière systématique et comparable, des informations sur l'état des données de différentes institutions patrimoniales en vue de leur intégration dans une plateforme fédérée de Linked Open Data. Les instruments existants examinés au chapitre 1.5 n'offrent pas de diagnostic détaillé de l'état interne des données d'origine : leurs incohérences conceptuelles, leurs ambiguïtés sémantiques, leur volume de doublons ou leurs conditions d'usage, dans une perspective comparative entre institutions hétérogènes.

Le questionnaire présenté au chapitre 4 répond directement à ce vide. En définissant le *dataset* — et non l'institution ni le système de gestion — comme unité d'analyse, l'instrument permet de rendre compte de l'hétérogénéité interne des pratiques curatoriales, y compris au sein d'une même institution. Les six blocs thématiques (structure et aspects généraux, état curatorial, pratiques de mise à jour et stabilité des identifiants, gouvernance des données, données sensibles et stratégies déontologiques, évaluation de la publiabilité) couvrent de manière articulée les objectifs secondaires fixés au chapitre 2 : identification des entités et des attributs, quantification des doublons, état de normalisation des expressions, gestion des incertitudes et des ambiguïtés, pratiques de mise à jour et stabilité des identifiants, droits associés et recommandations expertes de mise en ligne.

La double évaluation décrite au chapitre 5 — la validation qualitative menée par une experte en gestion des données muséales et l'application pilote réalisée sur l'instance MuseumPlus de la Ville de Genève — confirme que l'instrument remplit raisonnablement sa fonction. La validation qualitative a permis d'améliorer l'applicabilité du questionnaire afin de ne pas exiger une connaissance technique que toutes les personnes interrogées ne possèdent pas nécessairement. L'application pilote, quant à elle, a montré que le formulaire est suffisamment flexible pour décrire des jeux de données présentant des caractéristiques documentaires, des modèles d'organisation et des degrés de curation distincts. Ces observations ont donné lieu à des ajustements concrets — évaluation différenciée du modèle et du système par entité, typologie

élargie d'expression de l'incertitude, questions sur l'unicité des identifiants, questions sur l'ambiguïté sémantique des attributs — qui ont renforcé la capacité diagnostique de l'instrument sans compromettre son applicabilité transversale.

En somme, le questionnaire atteint son objectif principal : constituer un support préalable à la modélisation, capable d'évaluer la viabilité d'un jeu de données, d'identifier le travail préparatoire nécessaire et d'apporter des éléments structurés au processus de modélisation sémantique, sans prétendre se substituer à la prise de décision institutionnelle ni établir une hiérarchie normative de la qualité des données.

Limites de l'instrument

Plusieurs limites doivent néanmoins être reconnues :

En premier lieu, la validation et le prétest ont été évalués jusqu'à présent du seul point de vue d'une experte en gestion des données muséales. Si cette évaluation a permis de recueillir des observations pertinentes, une validation complémentaire menée depuis d'autres perspectives professionnelles, en particulier la modélisation sémantique et la gestion des données bibliographiques et archivistiques, permettrait d'élargir la portée des résultats et d'enrichir l'évaluation qualitative.

En second lieu, l'application pilote a été réalisée sur une seule instance technologique — MuseumPlus — et un seul fournisseur de données — la Ville de Genève —, bien qu'appliquée à plusieurs typologies documentaires au sein de cette instance. Cette diversité interne a permis de mettre à l'épreuve la flexibilité de l'instrument, mais ne permet pas encore de vérifier son comportement face à des systèmes de gestion de collections différents (Alma, AtoM ou autres), ni face à des institutions qui documentent leurs collections au moyen de feuilles de calcul, de fiches physiques ou de catalogues imprimés — des situations que le questionnaire devrait être en mesure d'accueillir (chapitre 4.2), mais qui n'ont pas été effectivement testées.

En troisième lieu, la modalité d'administration assistée — justifiée au chapitre 4.4 par la nécessité d'homogénéiser l'interprétation de concepts techniques complexes — constitue en même temps une limitation structurelle : l'instrument n'est pas conçu comme une enquête

autoadministrée, mais comme un remplissage conjoint entre la personne responsable des données et une personne facilitatrice familiarisée avec le questionnaire et avec la gestion des données muséales. Cette condition implique un coût en temps expert qu'il n'est pas anodin de multiplier dans un contexte de plusieurs institutions ou de dizaines de jeux de données.

En quatrième lieu, certains éléments du questionnaire demeurent délibérément ouverts ou incomplets. La question 12.2, relative aux stratégies de traitement des contenus sensibles ou problématiques du point de vue racial ou colonial, renvoie à des catégories dont la source bibliographique reste encore à compléter. De la même manière, la référence aux restrictions de réutilisation par des systèmes d'intelligence artificielle (question 11.1b) est formulée de manière générique, faute d'un cadre normatif ou d'une typologie consolidée au sein de la communauté, avec l'attente explicite que de futures versions du questionnaire puissent préciser cette catégorie.

Enfin, l'indicateur de pourcentage de données non curées (% NC) présenté au chapitre 4.7 constitue, par construction méthodologique, une estimation prudente et non une mesure exhaustive : en ne retenant que la dimension la plus problématique parmi les dix évaluées — et non la somme de l'ensemble d'entre elles —, l'indicateur évite de surestimer le volume de données non curées, mais peut, pour cette même raison, le sous-estimer lorsque plusieurs conditions de non-curation coexistent sans se recouvrir complètement au sein des mêmes enregistrements.

Conditions réelles de scalabilité

L'extension de l'instrument à d'autres projets d'agrégation fédérée est conditionnée par au moins trois facteurs identifiés tout au long de ce travail.

Le premier est la disponibilité de personnes facilitatrices capables d'accompagner le remplissage du questionnaire. Dans la mesure où la modalité d'administration assistée a été validée comme condition de fiabilité de l'information recueillie (chapitres 5.4 et 6.1, aspect 3), la scalabilité de l'instrument dépend directement de l'existence d'un rôle de coordination méthodologique au sein du projet de plateforme fédérée, capable de maîtriser tant le questionnaire que les concepts de web sémantique et de Linked Open Data.

Le second facteur est l'hétérogénéité réelle des systèmes de gestion de collections entre institutions. Le prétest a été réalisé sur une infrastructure technologique partagée (MuseumPlus) ; l'extension vers des institutions qui ne partagent pas cette infrastructure — ou qui gèrent leurs données dans des formats moins structurés — nécessitera de vérifier si la flexibilité du questionnaire, jusqu'ici seulement argumentée, se confirme empiriquement.

Le troisième facteur concerne l'ouverture et la pérennité technique de l'instrument. Cette préoccupation a été partiellement prise en compte dès la phase de développement du questionnaire, en cohérence avec les principes d'ouverture examinés au chapitre 1 : son code source est publié sous licence libre dans un dépôt ouvert sur GitHub, et l'instrument est déployé gratuitement au moyen du service GitHub Pages, à l'adresse <https://crislobalbarria.github.io/glam-data-diagnostic/> (voir chapitre 4.8). Cette ouverture demeure cependant partielle, dans la mesure où la centralisation des réponses repose sur un service propriétaire (Google Sheets), ce qui limite pour l'heure l'indépendance technique complète de l'instrument. La publication ouverte du code et de l'interface permet néanmoins de faciliter la réutilisation, l'adaptation et la contribution d'autres initiatives souhaitant évaluer l'état de leurs données patrimoniales, sans dépendre d'une infrastructure serveur ou d'un financement institutionnel spécifique pour héberger le formulaire lui-même.

Dans ces conditions, l'instrument paraît davantage adapté à une scalabilité progressive et accompagnée — institution par institution, jeu de données par jeu de données — qu'à un déploiement massif ou autoadministré à court terme.

Perspectives d'application

Au-delà de son application immédiate au projet de plateforme fédérée de la Ville de Genève, l'instrument développé dans ce travail ouvre plusieurs perspectives.

Une première perspective est longitudinale : dans la mesure où le questionnaire constitue, comme cela a été souligné au chapitre 2.3, une photographie de l'état des données à un moment donné, sa réapplication périodique sur les mêmes jeux de données permettrait d'évaluer l'impact réel de la plateforme fédérée sur les pratiques de gestion et de curation des données des

institutions participantes — une utilité qu'aucun des instruments existants examinés au chapitre 1.5 n'envisage explicitement.

Une deuxième perspective est comparative : la standardisation qu'offre le questionnaire permet, en principe, de comparer l'état des données selon les typologies institutionnelles, les tailles de collection ou les domaines disciplinaires, ce qui pourrait orienter des décisions de priorisation au sein d'un projet d'agrégation aux ressources limitées — par exemple, pour décider quels jeux de données aborder en premier en fonction de leur degré de préparation relatif.

Une troisième perspective concerne la relation entre l'instrument et le travail de modélisation proprement dit. Tout comme le SRDM du projet SARI ou la plateforme OntoME accompagnent la négociation sémantique entre experts de domaine et spécialistes de la modélisation (chapitre 1.3), le questionnaire pourrait, dans une version future, s'articuler plus étroitement avec ces méthodologies, de sorte que ses résultats — par exemple les relations déclarées à la question 9.5 ou les typologies d'attributs identifiées à la question 5.1 — alimentent directement la construction d'un modèle sémantique partagé, au lieu de demeurer un intrant préalable et séparé de ce processus.

Enfin, l'instrument présenté dans ce travail ne prétend pas être exclusif au contexte genevois. Sa définition du dataset comme unité d'analyse — fondée sur l'existence d'une structure relationnelle minimale, et non sur l'appartenance à une institution ou à un système de gestion particulier — le rend, en principe, transférable à tout projet d'agrégation multi-institutionnelle dans le secteur patrimonial cherchant à comprendre, avant de modéliser, la complexité réelle des données qu'il entend interconnecter. Il reviendra à un travail futur de mettre à l'épreuve cette transférabilité dans des contextes institutionnels, technologiques et culturels différents de celui dans lequel l'instrument a été conçu, testé et affiné.

Bibliographie

- BARRIENDOS Joaquín, « Latinoamericanismo Digital : Arte latinoamericano y humanidades digitales en Estados Unidos », in : BARRIA BIGNOTTI Cristóbal (dir.), *Las artes en Latinoamérica a través de las Humanidades Digitales, Quaderni Culturali IILA*, vol. 3, no 3, 2021, pp. 15–29. DOI : <https://doi.org/10.36253/qciila-1550>.
- BAUTISTA SMITH Susana, *Museums in the Digital Age : Changing Meanings of Place, Community, and Culture*, Lanham, Maryland : AltaMira Press, 2014.
- BEAGRIE Neil, « Digital Curation for Science, Digital Libraries, and Individuals », *International Journal of Digital Curation*, vol. 1, no 1, 2006, disponible à l'adresse URL : https://www.researchgate.net/publication/32895209_Digital_Curation_for_Science_Digital_Libraries_and_Individuals, consulté en ligne le 23 février 2026.
- BEARMAN David, « Standards for Networked Cultural Heritage », in : PARRY Ross (dir.), *Museums in a Digital Age*, Hoboken : Taylor and Francis, 2013.
- BELTEKI Daniel, REES Andrew J., SICHANI Anna-Maria, « Datafication and Cultural Heritage Collections Data Infrastructures : Critical Perspectives on Documentation, Cataloguing and Data-sharing in Cultural Heritage Institutions », *Journal of Open Humanities Data*, vol. 11, 2025, art. 14. DOI : <https://doi.org/10.5334/johd.277>.
- BERNERS-LEE Tim, HENDLER James, LASSILA Ora, « The Semantic Web : A New Form of Web Content That Is Meaningful to Computers Will Unleash a Revolution of New Possibilities », *Scientific American*, mai 2001.
- BERNERS-LEE Tim, « 5-Star Open Data », disponible à l'adresse URL : <https://5stardata.info/>, consulté en ligne le 23 février 2026.
- BERRY David M., *The Computational Turn: Thinking about the Digital Humanities*, Basingstoke; New York : Palgrave Macmillan, 2012.
- BONNEFOIT Régine, RÉRAT Mélissa (éd.), *The Museum in the Digital Age : New Media and Novel Methods of Mediation*, Newcastle upon Tyne : Cambridge Scholars Publishing, 2017.
- BRISTOL CITY COUNCIL, « Know Your Place », disponible à l'adresse URL : <https://maps.bristol.gov.uk/kyp/?edition=wilts>, consulté en ligne le 23 février 2026.
- BRUSEKER George, CARBONI Nicola, FIELDING Mark, NENOVA Desislava, HÄNSLI Tobias, « The Semantic Reference Data Modelling Method : Creating Understandable, Reusable and Sustainable Semantic Data Models », *Journal of Open Humanities Data*, vol. 11, 2025. DOI : <https://doi.org/10.5334/johd.282>.
- BUDAPEST OPEN ACCESS INITIATIVE, « Read the Declaration », 14 février 2002, disponible à l'adresse URL : <https://www.budapestopenaccessinitiative.org/read/>, consulté en ligne le 23 février 2026.

- BUDAPEST OPEN ACCESS INITIATIVE, « Signatures », disponible à l'adresse URL : https://www.budapestopenaccessinitiative.org/sign/signatures/?b_start:int=600, consulté en ligne le 23 février 2026.
- CANDELA Gianmarco, GABRIËLS Nele, CHAMBERS Sally, *et al.*, « A Checklist to Publish Collections as Data in GLAM Institutions », *Global Knowledge, Memory and Communication*, vol. 74, nos 5–6, 2025, pp. 1323–1355. DOI : <https://doi.org/10.1108/GKMC-06-2023-0195>.
- CANDELA Gustavo, SÁEZ María Dolores, ESCOBAR Pilar et MARCO-SUCH Manuel, « Reusing Digital Collections from GLAM Institutions », in : *Journal of Information Science*, vol. 48, n° 2, 2022, pp. 251-267.
- CANNON-BROOKES Peter, « The Nature of Museum Collections », in : THOMPSON John (éd.), *Manual of Curatorship*, Londres : Butterworths, 1992.
- CARROLL Stephanie R. *et al.*, « The CARE Principles for Indigenous Data Governance », *Data Science Journal*, vol. 19, n° 1, 2020, art. 43, DOI : <https://doi.org/10.5334/dsj-2020-043>.
- CASTELLUCCI Paola, *Dall'ipertesto al web. Storia culturale dell'informatica*, Bari : Laterza, 2009.
- CENTRE DE DOCUMENTATION ET RECHERCHE - MAH, « Mode d'emploi debase », Archivo du CDR-MAH, carpeta MuseoInfo, 1999, document interne non publié.
- CENTRE DE DOCUMENTATION ET RECHERCHE - MAH, *Documentation POC Plateforme de recherche fédérée*, réf. PoC_Documentation.pdf, 07 janvier 2025, document interne non publié.
- CIDOC, « CIDOC Conceptual Reference Model Version 5.0.4 », disponible à l'adresse URL : https://cidoc-crm.org/sites/default/files/cidoc_crm_version_5.0.4.pdf, consulté en ligne le 23 février 2026.
- CIDOC, « CIDOC CRM Tools », disponible à l'adresse URL : <https://web.archive.org/web/20070614123434/http://cidoc.ics.forth.gr/tools.html>, consulté en ligne le 23 février 2026.
- CIDOC, « Versions of the CIDOC CRM », disponible à l'adresse URL : <https://site2024.cidoc-crm.org/versions-of-the-cidoc-crm>, consulté en ligne le 23 février 2026.
- CODD Edgar F., « A Relational Model of Data for Large Shared Data Banks », *Communications of the ACM*, vol. 13, no 6, 1970, pp. 377–387. DOI : <https://doi.org/10.1145/362384.362685>.
- COMMISSION NATIONALE DE L'INFORMATIQUE ET DES LIBERTÉS (CNIL), « RGPD : de quoi parle-t-on ? », disponible à l'adresse URL : <https://www.cnil.fr/fr/rgpd-de-quoi-parle-t-on>, consulté le 23 février 2026.
- CONCILIO, L'ŒIL DU PUBLIC, *La digitalisation dans les institutions culturelles suisses : État des lieux et perspectives*, disponible à l'adresse URL : https://loeildupublic.com/wp-content/uploads/2023/10/La-digitalisation-dans-les-institutions-culturelles-suisses_sept-23_FR.pdf, consulté en ligne le 20 juillet 2026.

- CONSEIL INTERNATIONAL DES MUSÉES, *Code de déontologie de l'ICOM pour les musées*, disponible à l'adresse URL : https://www.museums.ch/admin/data/files/media/file_fr/125/icom_ethische_richtlinien_f_web.pdf?lm=1700558444, consulté en ligne le 23 février 2026.
- CREATIVE COMMONS, « Brooklyn Museum's API », 6 mars 2009, disponible à l'adresse URL : <https://creativecommons.org/2009/03/06/brooklyn-museums-api/>, consulté en ligne le 23 février 2026.
- CREATIVE COMMONS, « CC0 1.0 Universal (CC0 1.0) Public Domain Dedication », disponible à l'adresse URL : <https://creativecommons.org/publicdomain/zero/1.0/>, consulté en ligne le 23 février 2026.
- CREATIVE COMMONS, « Powerhouse Museum joins Flickr The Commons », 8 avril 2008, disponible à l'adresse URL : <https://creativecommons.org/2008/04/08/powerhouse-museum-joins-flickr-the-commons/>, consulté en ligne le 23 février 2026.
- CRITICALGLAM, « Vorwort », disponible à l'adresse URL : <https://criticalglam.ch/vorwort>, consulté en ligne le 23 février 2026.
- CULTUREPICS, « On This Day », disponible à l'adresse URL : <https://culturepics.org/on-this-day/?day=10&month=1>, consulté en ligne le 23 février 2026.
- DALLAS Costis, « Digital Curation Beyond the “Wild Frontier” : A Pragmatic Approach », in : *Proceedings of the 6th International Conference on Digital Curation*, 2010.
- DEARNLEY Louise, « Reprogramming the Museum », in : TRANT Jennifer et BEARMAN David (dir.), *Museums and the Web 2011: Proceedings*, Toronto : Archives & Museum Informatics, 2011.
- DESVALLÉES André (éd.), de BARY Marie-Odile et WASSERMAN Françoise (dirs.), *Vagues : une anthologie de la nouvelle muséologie*, Mâcon / Savigny-le-Temple : Éditions W / Muséologie nouvelle et expérimentation sociale (MNES), 2 vols., 1992-1994.
- DEUTSCHE NATIONALBIBLIOTHEK, « Gemeinsame Normdatei (GND) », disponible à l'adresse URL : <https://www.dnb.de/EN/Professionell/Standardisierung/GND/gnd.html>, consulté en ligne le 23 février 2026.
- DIGITAL CURATION CENTRE, « Digital Curation Centre », disponible à l'adresse URL : <https://www.dcc.ac.uk/>, consulté en ligne le 23 février 2026.
- DIGITAL CURATION CENTRE, « What is Digital Curation ? », disponible à l'adresse URL : <https://www.dcc.ac.uk/about/digital-curation>, consulté en ligne le 23 février 2026.
- DOERR Martin, « The CIDOC Conceptual Reference Model : An Ontological Approach to Semantic Interoperability of Metadata », *AI Magazine*, vol. 24, no 3, 2003, pp. 75–92. DOI : <https://doi.org/10.1609/aimag.v24i3.1720>.
- DOULAVERAKIS C., KOMPATSIARIS Y., STRINTZIS M. G., « Ontology-Based Access to Multimedia Cultural Heritage Collections – The REACH Project », *EUROCON 2005*, Belgrade, 2005, pp. 151–154. DOI : <https://doi.org/10.1109/EURCON.2005.1629881>.

- ESTERMANN Beat, *OpenGLAM Benchmark Survey – Measuring the Advancement of Open Data / Open Content in the Heritage Sector*, in : Proceedings of the international symposium on the measurement of digital cultural products, UNESCO Institute for Statistics, 2016, pp. 121–140, DOI : <https://doi.org/10.24451/arbor.9495>.
- EUROPEANA FOUNDATION, « About Europeana », disponible à l'adresse URL : <https://www.europeana.eu/en/about-us>, consulté en ligne le 23 février 2026.
- EUROPEANA FOUNDATION, « Aggregators », disponible à l'adresse URL : <https://pro.europeana.eu/page/aggregators>, consulté en ligne le 23 février 2026.
- EUROPEANA FOUNDATION, « Build with Bits 2026 – Building Places to Share », disponible à l'adresse URL : <https://pro.europeana.eu/post/build-with-bits-2026-building-places-to-share>, consulté en ligne le 23 février 2026.
- EUROPEANA FOUNDATION, « Develop New Skills and Build Capacity for 3D in 2026 with Eureka3D XR », disponible à l'adresse URL : <https://pro.europeana.eu/post/develop-new-skills-and-build-capacity-for-3d-in-2026-with-eureka3d-xr>, consulté en ligne le 23 février 2026.
- EUROPEANA FOUNDATION, « EDM Documentation », disponible à l'adresse URL : <https://pro.europeana.eu/page/edm-documentation>, consulté en ligne le 23 février 2026.
- EUROPEANA FOUNDATION, « Europeana Stories », disponible à l'adresse URL : <https://www.europeana.eu/en/stories>, consulté en ligne le 23 février 2026.
- EUROPEANA FOUNDATION, « Our Mission », disponible à l'adresse URL : <https://pro.europeana.eu/>, consulté en ligne le 23 février 2026.
- EUROPEANA PRO, « DE-BIAS Project », disponible à l'adresse URL : <https://pro.europeana.eu/project/de-bias>, consulté en ligne le 23 février 2026.
- FERRI Paolo, « Introduzione all'edizione italiana. La conoscenza come bene comune nell'epoca della rivoluzione digitale », in : HESS Charlotte, OSTROM Elinor et FERRI Paolo (dir.), *La conoscenza come bene comune. Dalla teoria alla pratica*, Milano : Mondadori, 2009.
- FOAF Project, « Friend of a Friend (FOAF) Vocabulary Specification », disponible à l'adresse URL : <https://xmlns.com/foaf/spec/>, consulté en ligne le 23 février 2026.
- GEMMEKE Claudia, JOHN Hartmut, KRÄMER Harald (éd.), *Euphorie digital? : Aspekte der Wissensvermittlung in Kunst, Kultur und Technologie*, Bielefeld : Transcript-Verlag, 2015.
- GETTY RESEARCH INSTITUTE, « About the Art & Architecture Thesaurus (AAT) », disponible à l'adresse URL : <https://www.getty.edu/research/tools/vocabularies/aat/about.html>, consulté en ligne le 23 février 2026.
- GETTY RESEARCH INSTITUTE, « Art & Architecture Thesaurus (AAT) », disponible à l'adresse URL : <https://www.getty.edu/research/tools/vocabularies/aat/>, consulté en ligne le 23 février 2026.

- GETTY RESEARCH INSTITUTE, « Union List of Artist Names (ULAN) », disponible à l'adresse URL : <https://www.getty.edu/research/tools/vocabularies/ulan/about.html>, consulté en ligne le 23 février 2026.
- GLOBAL INDIGENOUS DATA ALLIANCE, « CARE Principles for Indigenous Data Governance », disponible à l'adresse URL : <https://www.gida-global.org/care>, consulté en ligne le 23 février 2026.
- GO FAIR INITIATIVE, « FAIR Principles », disponible à l'adresse URL : <https://www.go-fair.org/fair-principles>, consulté en ligne le 23 février 2026.
- GOOGLE DEEPMIND, « Imagen », disponible à l'adresse URL : <https://deepmind.google/models/imagen/>, consulté en ligne le 23 février 2026.
- GRIMALDI Francesca, « The Evolution of Data.bnf.fr : Past, Present and Future of the BnF Linked Open Data Project », *JLIS.it – Italian Journal of Library, Archives and Information Science*, 2024, disponible à l'adresse URL : <https://www.jlis.it/index.php/jlis/article/view/588>, consulté en ligne le 23 février 2026.
- GUÉRET Christophe, SCHLOBACH Stefan, WIELEMAKER Jan, *et al.*, « The Rijksmuseum Collection as Linked Data », *Semantic Web*, vol. 9, no 2, 2018, pp. 221–230. DOI : <https://doi.org/10.3233/SW-170257>.
- GUÉRET Christophe, SCHREIBER Guus, WIELEMAKER Jan, « Towards Ontology-Driven Discourse : From Semantic Graphs to Multimedia Presentations », in : *The Semantic Web – ISWC 2006*, Berlin : Springer, 2006. DOI : https://doi.org/10.1007/978-3-540-39718-2_38.
- HESS Charlotte, OSTROM Elinor et FERRI Paolo (dir.), *La conoscenza come bene comune. Dalla teoria alla pratica*, Milano : Mondadori, 2009.
- HIGGINS Sarah, « Digital Curation : The Emergence of a New Discipline », *International Journal of Digital Curation*, vol. 3, no 2, 2008, pp. 134–148. DOI : <https://doi.org/10.2218/ijdc.v3i2.69>.
- HIGGINS Sarah, *The DCC Curation Lifecycle Model*. Edinburgh: Digital Curation Centre, 2008.
- HISTROPEDIA, disponible à l'adresse URL : <https://histropedia.com/>, consulté en ligne le 23 février 2026.
- HOOPER-GREENHILL Eilean, *Museums and the Shaping of Knowledge*, Londres : Routledge, 1992.
- ISLER D. *et al.*, *Rassismuskritische Dokumentation. Ein Handbuch für GLAM-Institutionen*, 2025, CRITICALGLAM.
- JONES Mike, « Archives and Museums », in : *Artefacts, Archives, and Documentation in the Relational Museum*, Londres / New York : Routledge, 2022.
- KNIGHT LAB, « StoryMap », disponible à l'adresse URL : <https://storymap.knightlab.com/>, consulté en ligne le 23 février 2026.

- LAWTHER Hannah, « Documentation as a Site for Critical Decolonial and Anti-Racist Work », in : DALAL-CLAY Anita (dir.), *Doing the Work: Embedding Anti-Racism and Decolonisation into Museum Practice*, 2021.
- LICKLIDER J.C.R., *Libraries of the Future*, Cambridge, Massachusetts : MIT Press, 1965.
- MACDONALD George et ALSFORD Stephen, « The Museum as Information Utility », *Museum Management and Curatorship*, vol. 10, no 3, 1991.
- MARCUM Deanna, « Archives, Libraries, Museums: Coming Back Together? », *Information & Culture*, vol. 49, no 1, 2014.
- MARTY Paul F., « Museum Informatics », in: *Encyclopedia of Library and Information Sciences*, 3rd ed., 2010.
- MARTY Paul F., BURTON JONES Katherine, *Museum Informatics : People, Information, and Technology in Museums*, New York : Routledge, 2009.
- MAYER-SCHÖNBERGER Viktor et CUKIER Kenneth, *Big Data: A Revolution That Will Transform How We Live, Work, and Think*, Boston : Houghton Mifflin Harcourt, 2013.
- MCLUHAN Marshall et PARKER Harley, « The Museum as a Mass Medium », *Curator: The Museum Journal*, vol. 10, n° 1, 1967, pp. 1-17.
- MCLUHAN Marshall, *Understanding Media: The Extensions of Man*, New York : McGraw-Hill, 1964.
- MIRABILIA, disponible à l'adresse URL : <https://mirabilia.ch/fr>, consulté en ligne le 21 juillet 2026.
- MOSSBERGER Karen, TOLBERT Caroline J. et FRANKO William, *Digital Citizenship in a Datafied Society*, Cambridge, Massachusetts : MIT Press, 2013.
- MUSEUM API, « Cool Stuff Made with Cultural Heritage APIs », disponible à l'adresse URL : <http://museum-api.pbworks.com/w/page/21933412/Cool%20stuff%20made%20with%20cultural%20heritage%20APIs?>, consulté en ligne le 23 février 2026.
- NELSON Ted, *Computer Lib / Dream Machines*, South Bend, Indiana : Mindful Press, 1974.
- NISHEVA-PAVLOVA Milena, SPYRATOS Nicolas, STANCHEV Peter, « Museum Collections and the Semantic Web », *Digital Presentation and Preservation of Cultural and Scientific Heritage*, vol. 4, 2014, pp. 33–39. DOI : <https://doi.org/10.55630/dipp.2014.4.3>.
- OPEN KNOWLEDGE FOUNDATION, « Open Definition », disponible à l'adresse URL : <https://opendefinition.org/>, consulté en ligne le 23 février 2026.
- OPENAI, « CLIP: Connecting Text and Images », 2021, disponible à l'adresse URL : <https://openai.com/index/clip/>, consulté en ligne le 23 février 2026.
- OPENDATA.CH, « OpenGLAM Working Group », disponible à l'adresse URL : <https://opendata.ch/projects/openglam-working-group/>, consulté en ligne le 23 février 2026.

- OPENGLAM, « OpenGLAM Principles », disponible à l'adresse URL : <https://openglam.org/principles/>, consulté en ligne le 23 février 2026.
- OWENS Trevor, *The Theory and Craft of Digital Preservation*, Baltimore, Maryland : Johns Hopkins University, 2018.
- PADILLA Thomas *et al.*, *Collections as Data: Part to Whole — Final Report*, Zenodo, 2018, DOI : <https://doi.org/10.5281/zenodo.1217649>.
- PADILLA Thomas *et al.*, *Santa Barbara Statement on Collections as Data — Always Already Computational: Collections as Data (Version 2)*, Zenodo, 2019, DOI : <https://doi.org/10.5281/zenodo.3066209>.
- PADILLA Thomas *et al.*, *Vancouver Statement on Collections as Data*, Zenodo, 2023, DOI : <https://doi.org/10.5281/zenodo.8342171>.
- PARRY Ross, *Recording the Museum: Digital Heritage and the Technologies of Change*, London : Routledge, 2007.
- PETRI Grischka, « The Public Domain vs. the Museum: The Limits of Copyright and Reproductions of Two-dimensional Works of Art », *Journal of Conservation and Museum Studies*, vol. 12, n° 1, 2014, pp. 1-12, DOI : <https://doi.org/10.5334/jcms.1021217>.
- POMIAN Krzysztof, *Collectionneurs, amateurs et curieux. Paris, Venise : XVIe–XVIIIe siècle*, Paris : Gallimard, 1987.
- QUICCHEBERG Samuel. *The First Treatise on Museums: Samuel Quiccheberg's "Inscriptiones"*, 1565, trad. du latin par M. A. Meadow & B. Robertson, Los Angeles : Getty Research Institute, 2014.
- RESEARCH DATA ALLIANCE, « FAIR Data Maturity Model : Specification and Guidelines », disponible à l'adresse URL : https://www.rd-alliance.org/system/files/FAIR%20Data%20Maturity%20Model%20specification%20and%20guidelines_v0.90.pdf, consulté en ligne le 23 février 2026.
- RIKOWSKI Ruth (éd.), *Digitisation Perspectives*, Rotterdam : Sense Publishers, 2011.
- RIVIER Alexis, *Numérisation du patrimoine intellectuel genevois. Collections imprimées et iconographiques de la Ville de Genève*, 2014, document interne non publié, 92p.
- ROBERTS Andrew, « The Changing Role of Information Professionals in Museums », in : PARRY Ross (éd.), *Museums in a Digital Age*, Hoboken : Taylor and Francis, 2013.
- SANDERHOFF Merete, *Sharing Is Caring: Openness and Sharing in the Cultural Heritage Sector*, Copenhagen : Statens Museum for Kunst, 2014.
- SARASAN Lenore, « Why museum computer projects fail », in : FAHY Anne (dir.), *Collections Management*, London : Routledge, 2006.
- SCHÄFER Mirko Tobias et WELTEVREDE Esther (dir.), *The Datafied Society: Studying Culture through Data*, Abingdon ; New York : Routledge, 2019.

- SCHLÖSSER Magdalene, SCHÄFFER Johannes, VON HAGEL Frank et SCHÄFER Felix, *Überblick über das Forschungsdatenmanagement in Museen und Universitätssammlungen*, Zenodo, 2024, DOI : <https://doi.org/10.5281/zenodo.13789201>.
- SMITH Barry, WELTY Christopher, « Ontology : Towards a New Synthesis », in : *Formal Ontology in Information Systems*, 2001.
- SEMANTIC REFERENCE DATA MODELS, *Annexe 2 : Internal Alignment Architecture*, v1, document interne non publié, 28 janvier 2025.
- SMITHSONIAN INSTITUTION, SELGEM (Self-Generating Master File System), 1970. MUSEUM COMPUTER NETWORK, GRIPHOS (General Retrieval and Information Processor for Humanities Oriented Studies), 1968.
- SONDERGAARD Peter, « Data Is the New Oil, in the Telecom Industry as Well », 8 décembre 2011, disponible à l'adresse URL : <https://aronheller.com/articles/data-is-the-new-oil-in-the-telecom-industry-as-well/>, consulté en ligne le 23 février 2026.
- STABILITY AI, « Stable Image », disponible à l'adresse URL : <https://stability.ai/stable-image>, consulté en ligne le 23 février 2026.
- STAUFFER Laurène, SUISSE OFFICE FÉDÉRAL DE LA STATISTIQUE, *Paysage Muséal et Public Des Musées En Suisse : Situation en 2019 et Évolution Sur Cinq Ans*, Neuchâtel : Office fédéral de la statistique, 2021.
- SUBER Peter, *Open Access*, Cambridge Massachusetts : MIT Press, 2012.
- SWISS ART RESEARCH INFRASTRUCTURE, *Annexe 1 : Pipeline Design*, v1, document interne non publié, 28 janvier 2025
- SWISS ART RESEARCH INFRASTRUCTURE, *Project Proposal – Collections Patrimoniales de la Ville de Genève CPVG*, v. 2, document interne non publié, 28 janvier 2025
- TASOVAC Toma, CHAMBERS Sally et TÓTH-CZIFRA Erzsébet, « Cultural Heritage Data from a Humanities Research Perspective », A DARIAH Position Paper, 2020
- TERRAS Melissa, « Opening Access to Collections: The Making and Using of Open Digitised Cultural Content », in : BONACCHI Chiara (dir.), *Archaeology and Digital Communication: Towards Strategies of Public Engagement*, Londres / New York : Routledge, 2015.
- TURNER Hannah, *Cataloguing Culture: Legacies of Colonialism in Museum Documentation*, 2020.
- UNION EUROPÉENNE, « Règlement (UE) 2016/679 du Parlement européen et du Conseil du 27 avril 2016 relatif à la protection des personnes physiques à l'égard du traitement des données à caractère personnel et à la libre circulation de ces données (Règlement général sur la protection des données) », in : *Journal officiel de l'Union européenne*, 2016, disponible à l'adresse URL : https://www.cnil.fr/fr/reglement-europeen-protection-donnees?utm_source=chatgpt.com, consulté en ligne le 23 février 2026, consulté en ligne le 23 février 2026.

UNION EUROPÉENNE, Recommandation 2011/711/UE du 27 octobre 2011 relative à la numérisation et à l'accessibilité en ligne du matériel culturel et à la conservation numérique, *Journal officiel de l'Union européenne*, L 306, 2011, disponible à l'adresse URL : <https://eur-lex.europa.eu/legal-content/FR/TXT/PDF/?uri=CELEX:32011H0711&from=LV>, consulté en ligne le 23 février 2026.

UNION EUROPÉENNE, « i2010: Digital Libraries — Communication from the Commission of 30 September 2005 to the European Parliament, the Council, the European Economic and Social Committee and the Committee of the Regions (COM(2005) 465 final) », EUR-Lex, disponible à l'adresse URL : <https://eur-lex.europa.eu/EN/legal-content/summary/i2010-digital-libraries.html>, consulté en ligne le 23 février 2026.

VICQ D'AZYR Félix, *Instruction sur la manière d'inventorier et de conserver, dans toute l'étendue de la République, tous les objets qui peuvent servir aux arts, aux sciences, et à l'enseignement, proposée par la Commission temporaire des arts, et adopté par le Comité d'instruction publique de la Convention nationale*, Paris : an II [1793-1794], p. 1-16.

VILLE DE GENÈVE, DÉPARTEMENT DE LA CULTURE ET DE LA TRANSITION NUMÉRIQUE (DCTN), *Fiche projet — Numérisation des collections patrimoniales de la Ville de Genève*, réf. DCTN_2022_04_29_Fiche_projet_numerisation_vv_cauliez, 29 avril 2022, document interne non publié, pp. 1-2.

WASHBURN Wilcomb E., « Collecting Information, Not Objects », *Museum News*, vol. 62, no 3, 1984.

WATSON Brian M., « Advancing Equitable Cataloging », *Proceedings of the North American Symposium on Knowledge Organization*, vol. 8, 2021.

WIKIMEDIA COMMONS, « Commons: Bundesarchiv », disponible à l'adresse URL : <https://commons.wikimedia.org/wiki/Commons:Bundesarchiv>, consulté en ligne le 23 février 2026.

WILKINSON, Mark D. *et al.*, « The FAIR Guiding Principles for scientific data management and stewardship », *Scientific Data*, vol. 3, 2016.

WILLIAMS David, « A Brief History of Museum Computerisation », in : PARRY Ross (dir.), *Museums in a Digital Age*, Hoboken : Taylor and Francis, 2013.

WORLD WIDE WEB CONSORTIUM (W3C), « Data on the Web Best Practices », disponible à l'adresse URL : <https://www.w3.org/TR/dwbp/#quality>, consulté en ligne le 23 février 2026.